


2019 届研究生硕士学位论文

分 类 号: _____

学校代码: 10269

密 级: _____

学 号: 51164500130



華東師範大學

East China Normal University

硕士学位论文

MASTER'S DISSERTATION

论文题目:

基于深度学习的下一代车车通信列控
系统安全风险预测

院 系: 计算机科学与软件工程

专 业: 软件工程

研 究 方 向: 软件科学与技术

指 导 老 师: 刘静 教授

学位申请人: 张炎

2019 年 5 月

East China Normal University

Title:

Safety Risk Prediction based on Deep Learning
for Train-to-Train Communication Train
Control System

Department: School of Computer Science and Software Engineering

Major: Software Engineering

Research Direction: Software engineering and technology

Supervisor: Prof. Jing Liu

Candidate: Yan Zhang

Mar., 2019

华东师范大学学位论文原创性声明

郑重声明：本人呈交的学位论文《基于深度学习的下一代车车通信列控系统安全风险预测》，是在华东师范大学攻读硕士/博士（请勾选）学位期间，在导师的指导下进行的研究工作及取得的研究成果。除文中已经注明引用的内容外，本论文不包含其他个人已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中作了明确说明并表示谢意。

作者签名：张炎

日期：2019年5月27日

华东师范大学学位论文著作权使用声明

《基于深度学习的下一代车车通信列控系统安全风险预测》系本人在华东师范大学攻读学位期间在导师指导下完成的硕士/博士（请勾选）学位论文，本论文的著作权归本人所有。本人同意华东师范大学根据相关规定保留和使用此学位论文，并向主管部门和学校指定的相关机构送交学位论文的印刷版和电子版；允许学位论文进入华东师范大学图书馆及数据库被查阅、借阅；同意学校将学位论文加入全国博士、硕士学位论文共建单位数据库进行检索，将学位论文的标题和摘要汇编出版，采用影印、缩印或者其它方式合理复制学位论文。

本学位论文属于（请勾选）

() 1. 经华东师范大学相关部门审查核定的“内部”或“涉密”学位论文*，于
年 月 日解密，解密后适用上述授权。

(☒) 2. 不保密，适用上述授权。

导师签名：刘新

本人签名：张炎

2019年5月27日

* “涉密”学位论文应是已经华东师范大学学位评定委员会办公室或保密委员会审定过的学位论文（需附获批的《华东师范大学研究生申请学位论文“涉密”审批表》方为有效），未经上述部门审定的学位论文均为公开学位论文。此声明栏不填写的，默认为公开学位论文，均适用上述授权）。

张炎 硕士学位论文答辩委员会成员名单

姓 名	职 称	单 位	备 注
欧阳树生	高级工程师	上海宝信软件股份有限公司	主席
刘爱玲	高级工程师	上海外高桥造船有限公司	
范昌琪	高级工程师	普华基础软件有限公司	

内 容 摘 要

在传统的系统风险分析领域存在大量关于如何在设计阶段使用建模技术进行静态分析的研究。对于基于通信的列车控制（Communication-based train control, CBTC）系统，如何有效地判断、预测在系统运行时由不确定性所带来的随机风险，却少有人涉足。安全风险分析是一种使用定性或定量方法识别系统安全性的技术。对 CBTC 系统进行安全风险分析，提高系统安全性，既是长久以来国际技术标准所追求的目标，也是相关研究领域的热点之一。同时，当前 CBTC 系统在通信模式方面的冗余造成了系统不确定性风险增加，对轨旁设备依赖较高等问题，促使着下一代列车控制系统的不断研发。

本文以下一代 CBTC 系统的安全风险预测作为研究目标，从构建基于车车通信模式的列控系统方案开始，提出了面向下一代 CBTC 系统的智能安全风险预测方法。该方法通过建立安全风险预测特征集，设计基于循环神经网络的预测模型，深层探究了系统运行特征与安全风险状态之间的潜在联系。

本文的主要贡献体现在以下几点：

(1) 设计了基于车车通信模式的下一代 CBTC 系统方案，优化了新型系统下的移动闭塞技术。该方案加入了车车通信模式，对系统关键功能进行重新分配，将部分轨旁功能分散于车载系统上以减少轨旁设备，解决了移动闭塞技术对轨旁设备依赖较高的问题，极大提高了轨道利用率，从而有效降低系统运行风险。

(2) 构建了列车控制系统风险特征选择方法。该方法首先参考列控系统设计中建议的风险分析考虑因素并结合下一代 CBTC 系统方案，对特征进行初步选择。然后针对小概率特征项，提出了基于统计模型检验的求解算法。最后在此基础上，采用了主成分分析方法对预测特征集进行降维处理。该方法为列控领域建立风险分析特征提供了一套有效的方法。

(3) 提出了面向下一代车车通信 CBTC 系统的智能安全风险预测模型。该模型基于长短期记忆循环神经网络，将风险预测特征作为输入，寻找系统风险特征和列车运行状态之间的映射关系。为了克服不平衡类别的列车运行状态数据集对模型训练的影响，提出了采用 L2 正则化技术的模型优化方法，从而有效提高预测准确率，避免了模型训练的过拟合。该模型最终实现了系统动态运行中不确定性信息的学习和风险状态间关联捕获，达到了对列车运行状态做出预测分类和识别的目的。

本文使用合作方的系统样本数据集对所提出的模型进行了实验。多项实验结果验证了该模型在基于车车通信的下一代 CBTC 系统安全风险预测方面的有效性和实用性。

关键词: 风险预测, 深度学习, LSTM 循环神经网络, 基于通信的列车控制系统, 统计模型检验

ABSTRACT

Although there has been substantial research in system analytics for risk assessment in traditional methods which using static analysis in design phase, little work has been done for safety risk prediction in communication-based train control (CBTC) system, especially intelligently predicting risk caused by the uncertainty in the system operation. Safety risk analysis is a technique to measure system safety using qualitative or quantitative methods. Having safety risk analysis for CBTC system and improving its safety, it is not only the goal pursued by international technical standards for a long time, but also one of the hotspots in this research field. Meanwhile, redundancy in the communication mode of the CBTC system increases the uncertainty risk of system, which prompts the research on next generation train control system.

This dissertation proposes an intelligent safety risk prediction method based on a deep learning, from constructing a next generation train control system based on train to train communication. The method establishes safety risk prediction features and designs a predictive model based on recurrent neural network to deeply explores the potential link between system operation features and risk status.

The main contributions of the dissertation include:

(1) We put forward a next generation CBTC system paradigm based on train-to-train communication, and optimize the moving block principle. The paradigm adds train-to-train communication mode, re-allocate system critical functions, and optimize the moving block principle in the new system. It moves some functions in track-side equipment to vehicle-onboard system, for reducing the track-side equipment. It overcomes the problem that moving block principle has high dependence on the track-side system, improves the utilization rate of the track, and effectively reduces the system operation risk.

(2) We design a risk prediction features selection method for train control system. According to the recommended risk analysis considerations in IEEE1474.1 standard of CBTC system, the method selects some risk features preliminary. For the rare-probability features in this field, we propose a solve algorithm using statistical model checking. Based on this, we perform features extraction using principal components

analysis. This method provides an effective method for risk features establishment in train control system.

(3) We propose an intelligent safety-risk prediction model for train-to-train communication next generation CBTC system. The model is implemented by a deep recurrent neural network (RNN) called a long-short-term memory (LSTM) network, which takes into account safety risk prediction features. It predicts the occurrence probability of a hazard from datasets and classify them, through finding the mapping between system safety-risk features and train operation status. To reduce the influence of unbalanced datasets in training, the prediction model is optimized based on L2 regularization, which effectively improves the prediction accuracy and avoids over-fitting of model training. This model realizes the learning from system uncertainty information and the relevance caption among risk status, and achieves the purpose of predictive classification and identification of train operation risk status.

The model proposed in this dissertation has been successfully applied on a real sample dataset from cooperative corporation. Much experimental results verified the effectiveness and practicability of the model in the safety risk prediction of the next generation CBTC system based on train-to-train communication.

Keywords: Risk prediction, Deep learning, Long-short-term memory (LSTM), Communication-based train control system, Statistical model checking

目 录

摘要	i
Abstract	iii
第一章 绪论	1
1.1 研究背景与意义	1
1.2 难点与挑战	3
1.3 研究现状	4
1.3.1 基于通信的列车控制系统	4
1.3.2 系统安全风险预测技术	4
1.3.3 深度学习	6
1.4 主要研究内容	8
1.5 本文组织结构	9
第二章 基于车车通信的下一代列车控制系统方案	11
2.1 基于通信的列车控制系统	11
2.2 CBTC 系统现存问题	13
2.3 基于车车通信的下一代 CBTC 系统方案设计	13
2.4 基于车车通信的下一代 CBTC 系统移动闭塞技术	16
2.5 本章小结	18
第三章 系统安全风险预测特征建立方法	21
3.1 系统安全风险定义	21
3.2 安全风险预测特征选择	22
3.3 基于统计模型检验的小概率特征值生成	24
3.3.1 背景介绍	24
3.3.2 问题转化	27
3.3.3 小概率特征生成算法	28
3.4 基于主成分分析的风险特征预测集降维	30

3.5	本章小结	32
第四章	基于循环神经网络的安全风险预测模型	33
4.1	LSTM 循环神经网络	33
4.2	基于 LSTM 循环神经网络的风险预测模型	35
4.2.1	模型框架	36
4.2.2	预测流程	38
4.3	基于 L2 正则化的预测模型优化	40
4.3.1	系统安全风险预测中样本不平衡问题	40
4.3.2	针对不均衡样本的 L2 正则化优化	40
4.4	T2T-CBTC 系统安全风险预测模型训练过程	41
4.5	本章小结	43
第五章	实验设计与结果分析	45
5.1	实验环境	45
5.2	模型评价指标	45
5.3	实验数据集	46
5.4	风险预测特征集构建	49
5.4.1	小概率特征生成算法	49
5.4.2	基于 PCA 的预测特征集降维	52
5.5	基于 LSTM-RNN 的安全风险预测模型训练	53
5.5.1	预测模型 L2 正则化参数 λ 选取	53
5.5.2	模型参数选择	55
5.5.3	模型训练结果	56
5.6	基于 LSTM-RNN 的安全风险预测模型实验	57
5.6.1	预测模型实验结果	57
5.6.2	不同预测模型性能对比	59
5.7	本章小结	60
第六章	总结与展望	61
6.1	总结	61

6.2 展望	62
参考文献	63
致谢	69
攻读硕士期间研究成果	71

插图目录

1.1	主要研究内容示意图	8
2.1	基于通信的列车控制系统功能架构图	12
2.2	下一代车车通信 CBTC 系统方案设计	14
2.3	T2T-CBTC 系统下移动闭塞技术 UML 时序图	16
2.4	T2T-CBTC 系统中移动授权计算模块信息交互图	17
2.5	移动授权功能 EOA 生成算法流程图	19
3.1	模型检验流程图	25
4.1	循环神经网络单元基本结构	34
4.2	LSTM 网络神经元结构	34
4.3	基于 LSTM 循环神经网络的安全风险预测模型及展开图	36
4.4	基于 LSTM 循环神经网络的安全风险预测流程图	39
4.5	基于 LSTM 循环神经网络 +L2 正则化的风险预测模型训练过程	42
5.1	不平衡数据集总体样本类别分布	47
5.2	输入参数合法性检查模块	49
5.3	判断当前区块是否为搜索区块	50
5.4	判断当前区块长度是否大于搜索距离	50
5.5	获取下一个搜索区块的信息	50
5.6	判断已搜索距离是否等于输入搜索距离	51
5.7	判断下一个搜索区块是否合法	51
5.8	轨道线路迭代搜索模块	51
5.9	各特征项在 PCA 分析中对原始信息表达的贡献率	53

5.10 不同 L2 正则化参数取值下 c3, c4 类别的查准率	54
5.11 不同 L2 正则化参数取值下 c3, c4 类别的查全率	54
5.12 不同 L2 正则化参数取值下 c3, c4 类别的 F1 分数	55
5.13 训练过程中模型预测准确率和误差值变化图	56
5.14 单次试验下不同样本类别的各评价指标结果	57

表格目录

3.1	风险预测特征初步选择结果列表	23
5.1	风险类型，标签及输出示例	47
5.2	输入数据集举例	48
5.3	小概率预测特征计算结果	52
5.4	LSTM-RNN 风险预测模型训练超参数选择结果	55
5.5	单次实验下混淆矩阵结果	57
5.6	多次实验下各评价指标结果	58
5.7	模型比较实验评价指标结果	59

第一章 绪论

1.1 研究背景与意义

在中国经济腾飞的三十多年间，城市化程度加剧以及人口增长促使地铁成为了大都市生活中典型的大容量公共轨道交通工具。繁忙的城市轨道交通运营导致地铁服务提供商面临的主要挑战之一是如何在确保地铁运营容量稳定的情况下提高安全性，降低风险。根据调查统计，60%到70%的列车事故由列车碰撞造成。事故发生后会导致地铁运营大面积中断，严重时还会造成人员的生命危险，其发生风险的代价不可估量。可见，轨道交通列车控制系统是典型的安全关键系统（Safety critical system），即系统失效会导致人员伤亡或严重财产损失的软件，其安全性和可靠性与轨道交通运营安全有着不可分割的紧密关联。因此，分析列车控制系统的安全风险不仅仅是必要的需求，也是识别何种运行条件会导致系统进入风险状态的有效举措。

基于通信的列车控制（Communication based train control, CBTC）系统是世界上最新一代的自动列车控制（Auto train control, ATC）系统，被广泛应用于城市轨道交通的控制之中。不同于之前的轨道电路，CBTC系统拥有列车精准定位和双向连续的车地间数据通信能力，以实现自动列车保护，自动列车运行和自动列车监控功能。CBTC系统属于移动闭塞（Moving block）系统。该类系统下，列车将其位置信息提供给轨旁设备，轨旁设备为其计算移动授权（Movement authority, MA），即列车在设施和速度的限制下所能行驶到特定地点的授权信息，并传送给列车。CBTC系统使管理人员能够更精确地控制列车运行，使列车在有人或无人驾驶的情况下都能安全地、以更高的发车频率和速度在轨道上运行，极大地提高了地铁线路的运载能力、效率、可靠性及安全性，并减少了运营成本。作为工业级的控制软件，CBTC系统是典型的安全关键系统，其可靠性与列车安全运行有着不可忽视的关系。CBTC系统设计标准^[1]中提出必须确立科学高效的安全风险评估过程。因此，通过考虑系统中的危害事件，量化和分析主要风险，有助于更好地进行运营规划决策。通常，CBTC系统的风险分析需要考虑多个系统风险影响因素来探讨它们与安全风险状态之间的非线性关系。例如，与碰撞风险发生最关键和紧密的因素是MA计算失效，它可能为列车和轨旁设备提供错误的控制命令。所以，MA的正确性对于避免列车碰撞至关重要。

安全风险分析（Safety risk analysis）是系统安全管理的核心过程，指以定量或定性的方式来测定系统安全性。系统风险分析过程主要由三个步骤组成：（1）识别风险场景，（2）可能性分析，（3）影响分析。识别风险场景是为了探求危害事件的发展过程，以确定其在形成过程中的可能影响因素。可能性分析是估计这种危害事件发生的概率。定性或定量方式取决于研究中可用的数据。影响分析基于以上两个步骤为每个危害场景指定一个风险级别，根据其发生的可能性，以确定其是否可以被接受，通常采用风险矩阵（Risk matrix）实现。如若这些风险不能被接受，应增加相应安全措施，降低其发生可能性或所导致的后果。因此，有效可行的安全风险分析对于 CBTC 系统安全性有着质的提高，且具有重大意义。

尽管当前的 CBTC 系统是最先进的列车控制系统，但铁路事故，列车碰撞及脱轨事件仍在不断发生。这是由于现有的 CBTC 系统体系结构在很大程度上依赖于人为干预而导致误差产生。因此，开发下一代列车控制系统以尽可能减少事故的发生具有无可抗拒的必要性，也成为轨道交通领域的研究热点。欧盟于 2013 年提出了“下一代列车控制”（Next generation train control, NGTC）研究计划¹，由相关领域的重要机构参与研究，例如，国际公众运输联盟（Union Internationale des Transports Publics, UITP）、主营轨道交通基础设施的法国阿尔斯通公司（ALSTOM）和西门子公司（SIEMENS）等^[2]。该计划着力于分析欧洲列车控制系统（European Train Control System, ETCS）和 CBTC 系统在体系架构，系统设计及应用平台上的异同，以实现技术融合；应用无线通信技术和卫星定位技术提高交通运载能力，实现更高效的轨道控制^[2]。其中较为主要的研究方向有：减少移动闭塞技术对轨旁系统的依赖、基于 IP 的无线网络、卫星定位系统。通信技术的创新与进步促使车车通信技术在下一代列车控制系统中的应用逐渐成为研究者的关注点，促进了更安全，更高效的 CBTC 系统的出现。

深度学习（Deep learning）在近年来也逐渐融入到交通流预测^[3]、车辆自动驾驶故障预测^[4]、以及跟踪轨道电路故障预测^[5]等安全关键系统领域的安全风险分析及故障检测研究中。这些成功应用的主要原因是，与只有单个隐层的神经网络算法相比，深度学习算法受人类大脑结构的启发而产生的，由一个深度神经网络（Deep neural network, DNN）结构实现。该 DNN 结构由多个层次的非线性函数组合而成。深度学习算法将给定的系统相关数据在每一个处理层上都表示成一种抽象级别的特征集，从而在多个抽象级别上自动学习特征，生成将

¹<http://www.ngtc.eu>

输入直接从原始数据映射到输出类别的复杂函数，更深入且自动地捕获了不同输出类别之间的关联和差别。例如在分类识别任务中，算法模型会更加重视变化范围较大的特征信息，而无关的信息会被忽略。DNN 能够寻找到高维数据中的复杂信息，突破性地促进了语音识别、基因研究以及控制等许多领域难题的解决。在图像处理（Image Processing）和语音识别（Speech recognition）的比赛中，深度学习算法多次取得优秀的成绩^{[6][7]}。在自然语言处理（Natural Language Processing）的各种任务中，不论是分类文章主题^[8]、判断情感极性^[9]，还是语言翻译^[10]，DNN 都能优秀地解决。因此，这些独有的特征和突破性的成果表明，深度学习算法在 CBTC 系统的故障或风险预测方面具有良好的应用前景。

基于以上背景，本文着重考虑研究列车控制系统的安全风险预测问题，以深度学习技术为切入点，试图构建出一套智能的列控系统安全风险预测方法，为列车提供可靠安全的行驶保证。

1.2 难点与挑战

如何减少移动闭塞技术对轨旁系统的依赖 当前系统的列车控制命令的产生主要通过“列车提供信息—地面设备计算—传送至列车”模式实现。移动闭塞技术的实现严重依赖于轨旁系统可靠性。同时，列车之间非直接通信导致较大的信息传送延迟误差和系统性能低下。信息的集中处理也使得列车和驾驶员高度依赖地面控制系统的可用性，一旦地面系统发生故障，将促使不安全事件发生率的提高。CBTC 系统的现有结构在保证系统安全的情况下无法满足该目标的实现。

如何在风险分析中处理系统动态运行中的不确定性 运行环境的不同和系统组件的不可靠性会导致预定的运行状态出现较大偏差，而这种偏差在系统中无法避免，也无法估计。传统系统风险分析方法在该问题的解决上存在局限性。例如，故障树分析，失效模式及影响分析和贝叶斯网络等静态建模分析技术在分析过程中对不确定性的忽视，无法达到预期效果。

如何捕获系统风险状态之间的关联 为了探究系统处于何种风险状态，那么找到状态之间的区别和关联是尤为重要的。不同安全风险状态之间区别在于系统当时运行条件下状态参数的不同，而风险状态发生之间的关联存在参数变化趋势之

中。Petri 网建模等传统方法更关注系统运行时的动态变迁及所达独立状态。如果将安全风险状态进行相互独立的分析判断将导致非最优结果。

CBTC 系统的参数数据记录包含了系统不确定性信息，是系统随机行为的另一种表示。深度学习方法可以从这些数据中学习系统运行特性，有效地解决不确定性问题为安全风险预测分析设下的障碍，即第一个难点。DNN 的自动抽象特征学习能力可以捕捉到不同安全风险状态之间的相关性和差异性，从而解决了第二个难点。第三个难点的克服依赖于车车通信模式的引入。通过车车通信的加入和系统结构的优化，不仅可以减小系统移动闭塞技术对于轨旁设备的依赖，也能减少通信延迟和信息交互冗余问题，降低通信问题所带来的潜在风险。

1.3 研究现状

1.3.1 基于通信的列车控制系统

CBTC 系统的雏形最初起源于 20 世纪 80 年代中期的由 Alcatel SEL 公司为庞巴迪运输公司开发的自动高速运输 (Automated Rapid Transit, ART) 系统。世界上第一个基于无线电的 CBTC 系统是庞巴迪运输公司于 2003 年 2 月在旧金山机场启动运行的。作为全球最有名的轨道交通控制系统及服务的供应商之一，阿尔斯通公司于 2003 年 6 月在新加坡东北铁路线上也引入了无线电技术。CBTC 系统利用感应回路传输技术提供轨道和列车之间的通信，是之前基于轨道电路进行通信的一种替代方案。

CBTC 系统是当代基于通信的信号控制系统。利用无线通信，它能保证高分辨率和实时性的列车控制信息，通过缩短线路上相邻列车之间的安全距离来增加轨道线路的容量，最大限度地减少轨道设备的数量。CBTC 系统技术已被广泛地应用于多种铁路运输之中，不论是短程轨道，有限数量列车和较少运行模式的情况（如旧金山和华盛顿的机场运输系统），还是复杂铁路网，百万运输乘客和大量列车运行的情况（如马德里地铁 1 号线和 6 号线，深圳地铁 1 号线和 6 号线以及巴黎地铁的一些线路），都能有效地实现列车的安全运行管理。

1.3.2 系统安全风险分析技术

系统安全性及风险分析的有关研究在近些年不断涌现。本节从多种建模方法讨论其研究现状。

故障树, 失效模型与影响分析 故障树 (Fault tree analysis, FTA) 是一种自顶而下的推演系统失效的分析法^[11], 致力于找出系统顶层的失效事件和系统底层的基本元事件之间的逻辑关联。通过逻辑门模块将失效事件与基本事件相连接, 建立系统失效故障树, 可以识别顶层失效事件的发生与否, 或是使顶层事件的发生机率降低, 并验证系统是否达到安全状态。失效模式与影响分析方法 (Failure mode and effects analysis, FMEA) 则与故障树的分析过程相反, 它是一种自下向上的归纳分析方法^{[12][13]}。通过识别每个组件的失效模式, 从而对系统总体的失效模式做出判断。在实际应用中, 常常将两种方法相结合。FMEA 可以对 FTA 起到增强或补充作用, 发现和确定更多导致顶层症状的原因和失效模式。Mader 等人融合 FMEA 和 FTA 到一个故障风险分析模型中^[14], 并将其应用于混合动力汽车的设计与开发。Pan 等人在^[15] 中基于故障树技术提出了一种列车控制系统的安全风险分析方法, 并对改进系统提出了优化。Kloos 等人在^[16] 中描述了一种在构建测试模型时借助 FTA 结果的方法, 根据识别的风险严重程度和导致风险的基本事件的数量来派生、选择和优先化测试用例。该方法比常规模型测试方法在安全功能的覆盖率方面有显著的提高。

这两种分析方法都能提供定性或定量的系统失效分析, 但定量分析常依赖于领域专家知识和概率数据, 这限制了其在概率风险分析方面的应用。除此之外, 事件树分析 (Event tree analysis, ETA) 也常用于列控系统的安全分析中。

形式化建模 Liu 等人在^[17] 中实现了使用 AADL 模型进行定量风险分析的方法。该方法通过给出基于风险的失效模式效应分析 (Risk-based Failure Mode Effect Analysis, RFMEA) 表, 用于指导工程人员迭代或细化系统 AADL 模型。Mathieu 等人^[18] 发现使用严谨的形式化验证技术分析 CBTC 系统安全性是可行的。文章中主要总结了他们正在进行的工作。作者使用 Event-B 工具建模联锁功能系统, 并验证了系统运行中是否能符合所定义的安全关键属性。

Petri 网 Petri 网是研究各种混成系统的一种有效模型。它们可以有效地表达序列、并行性、同步启动和停止等各种现象。既可以用于静态结构的建模, 也可以用于动态行为的建模。Petri 网建模不仅可以检查系统架构, 还可以检查它的时间演化和系统反应, 这使得它们非常适合于可靠性、安全性和性能评价。胡少强结合了系统理论事故模型与过程 (STPA) 理论和有色 Petri 网, 提出了系统安全

风险形式化分析方法^[19]。通过建立系统功能需求和模型之间的关系,采用模型检验方法寻找风险的可达状态,实现危害风险的辨识。Boudi 等人提出了一种用于轨道交通系统安全关键场景的高级 Petri 网建模方法^[20]。该方法基于模块化的高级 Petri 网,建模了如安全监管程序、内部联锁等多数系统模块,特别是人为因素,使信息的收集更加多样化,并允许在同一个全局模型中研究各种可能性。

贝叶斯网络 贝叶斯网络 (Bayesian network, BN) 是一种概率图模型,被认为是概率知识表示和推理领域中最有用的模型之一^[21]。强大的概率统计推理能力使其广泛地被应用于故障诊断,风险分析领域。Cai 等人^[22]提出了一种基于动态贝叶斯网络的故障诊断方法,主要应用于电子系统。动态贝叶斯主要建模产品的动态退化过程,而马尔可夫过程用于对过渡状态建模,然后定义了两种判断规则来确定故障诊断结果。为了研究高速铁路牵引系统故障传播机理,准确预测部件级故障概率, Wu 等人在^[23]中建立了基于贝叶斯网络和键合图建模技术的故障预测方法。使用键合图模型表示铁路牵引系统的固有结构,并在此基础上建立多层贝叶斯网络进行故障传播分析和预测,有效地将贝叶斯模型推广到高速铁路系统的故障分享分析中。

1.3.3 深度学习

基于深度学习算法以推进各领域创新融合的研究方法层出不穷。主要原因是其深层网络结构比一般的单隐层神经网络能更好地学习数据中的抽象特征,根据这些特征对数据实现更深的分析。

BP 神经网络 Samia 等人最早将神经网络技术应用于铁路安全性预测^[24]。作者通过建立一个多隐层神经网络来预测铁路轨道上列车安全,同时使用了小波变换来压缩网络的高维输入。该研究的性能令人满意,能以较低的误差值预测出结果。在深度学习技术的启发下, Chen 等人在^[4]中提出了一种遗传算法优化的神经网络,通过综合考虑驾驶员、道路、车辆和外部环境等多种影响因素来预测车联网环境下的追尾碰撞概率。与传统的主要基于运动学方程的碰撞概率计算方法相比,该方法更加准确,适用于实际的碰撞场景和特定区域的交通。

在故障检测和交通安全性预测方面,深度学习算法突破了传统方法的局限,另辟蹊径,使得该研究问题得到了创新性地解决。

深度信念网络 Tamilselvan 等人^[25]构建出一种基于深度信念网络（Deep Belief Network, DBN）状态分类的多传感器健康诊断方法。定义系统健康状态和收集传感器数据是第一阶段，之后 DBN 将作为特征学习模型进行训练及诊断，该类型网络能以较好的性能实现故障诊断任务。Huang 等人提出了一种针对交通流预测的深度神经网络架构，该架构由 DBN 构成，输出层采用回归层来实现多任务处理（Multitask learning, MTL）。在没有人工设计的特征抽取和选择的情况下，该体系结构可以很好地学习数据特征表示。同时，MTL 的使用提高了模型的整体性能^[3]。Strickland 等人提出了一种基于深度预测模型的碰撞风险评估方法^[26]。该方法实现了一种贝叶斯 ConvLSTMs 网络，使用网络输出概率来评估预测中固有的不确定性，从而对视觉数据、本体感受数据和转向命令进行时空关系处理，以识别潜在的或即将发生的碰撞危险。

循环神经网络 在^[5]中，Bruin 等人提出了一种基于深度学习的轨道电路故障诊断方法，使用 LSTM-RNN 网络来实现。研究表明，该模型网络不需要将先验知识人工集成到网络中，就可以直接从电流测量值中学习到表示所考虑故障的时空相关性，预测准确率达 99.6%。作者也说明了，虽然他们的研究重点是铁路轨道电路，但 LSTM-RNNs 网络在其他故障诊断问题上也是一个很有发展方向的选择，尤其是在故障具有长期时间相关性的情况下。针对目前在驱动风险预测领域缺乏对时间序列数据无监督特征提取和类不平衡数据集情况下准确识别的研究，Chen 等人提出了一种新型基于非平衡自然驾驶数据集的代价敏感的 L1/L2-非负约束深度自编码器网络，用于预测驾驶安全风险概率^[27]。该模型通过三层 L1/L2-NCAE 网络选取了最优时序步长的大小，无监督的特征提取由深度神经网络实现；最后通过融合的 L1/L2 正则化技术，提高了分类模型的准确性，准确识别不同风险等级的驱动状态事件，只需较短的预测时间，同时具有较强的时效性。

除此之外，支持向量机（support vector machine, SVM）也常用于安全性预测分类。Yang 等人提出了一种基于 SFS-PCA-LSSVM 的运输安全区域分类和运输状态分类的方法^[28]。该方法主要融合了序列前向选择（Sequential forward selection, SFS），主成分分析（principal components analysis, PCA）和最小二乘支持向量机（Least squares support vector machine, LSSVM）。SFS 和 PCA 主要用于特征选择和特征提取，LSSVM 实现安全区域分类。实验得出，SFS-PCA-LSSVM 运输安

全区域评估系统的分类准确率均在合理的 88% 以上，具有较高的分类准确率。

1.4 主要研究内容

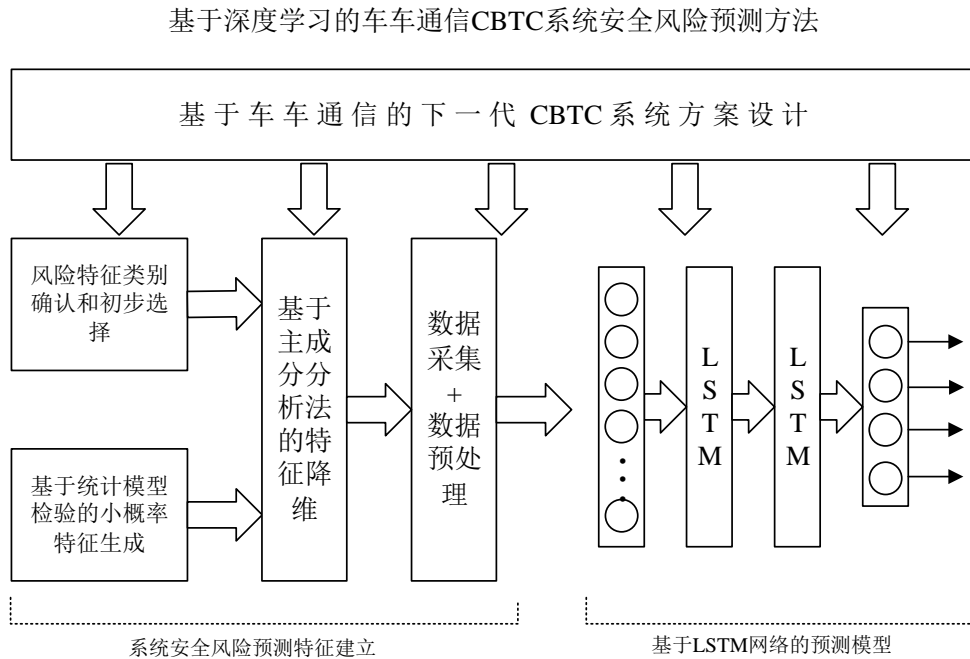


图 1.1 主要研究内容示意图

本文以下一代列车控制系统的安全风险预测为研究目标，以深度学习技术为切入点，提出了面向下一代车车通信 CBTC 系统的智能安全风险预测方法。本文从现有 CBTC 系统开始，结合车车通信模式，提出了基于车车通信的下一代 CBTC 系统设计方案，并优化了新系统下的移动闭塞技术。该智能安全风险预测方法包含风险预测特征建立和预测模型设计两个过程。本文提出了面向列控系统的安全风险预测特征建立方法。根据列控系统设计要求及下一代 CBTC 系统方案，首先从四类因素进行特征初步选择，然后提出基于统计模型检验的小概率特征生成算法，最后使用主成分分析对特征集进行降维。基于深度学习技术，本文提出了基于 LSTM 循环神经网络的安全风险预测模型，其中采用正则化技术优化模型以解决数据集的不平衡问题，实现了对于列车运行状态的识别和分类。

本文研究内容如图 1.1 所示。主要包括以下方面：

(1) 设计基于车车通信的下一代 CBTC 系统方案：基于 CBTC 系统研究趋势

和现存问题，提出了基于车车通信的下一代 CBTC 系统方案。该方案通过增加车车通信，将关键功能重新分配，新增多项功能模块，优化了下一代系统中的移动闭塞技术，达到了减少轨旁设备的目的，克服了移动闭塞技术对轨旁系统依赖较高的问题，有效降低了系统不可靠性和维护成本。

(2) **建立列控系统风险特征选择方法：**提出了面向列控系统的安全风险预测特征建立方法。该方法首先参考列控系统设计标准 IEEE1474.1^[1]，并结合下一代 CBTC 系统方案，初步选择了风险预测特征项，然后提出针对小概率特征值的生成算法，最后在此基础上采用了主成分分析方法对其进行降维处理以降低特征集维度，优化特征集的信息表达。

(3) **提出小概率特征生成算法：**为了克服“特定领域的特殊特征值生成困难”问题，提出了基于统计模型检验的小概率特征生成算法。通过对系统功能进行建模，采用形式化语言描述系统中的小概率失效事件，本文使用该算法求解了小概率特征值，有效地解决了列控系统安全风险预测中小概率特征生成的问题。

(4) **构建面向下一代车车通信 CBTC 系统的安全风险智能预测模型：**构建了基于 LSTM 循环神经网络的安全风险智能预测模型。该模型通过建立系统风险特征和列车运行状态之间的映射函数关系，以实现未知运行条件下列车所处风险状态的判断。同时，针对列车运行状态数据集的类别不平衡问题，设计了基于 L2 正则化的模型优化方案以提升预测性能，保证了模型充分有效地训练。

1.5 本文组织结构

本文主要围绕下一代车车通信列车控制系统的安全风险预测问题进行了研究，分为六章，组织架构如下：

(1) 第一章介绍了本文的研究背景与意义，同时从系统安全风险分析技术、深度学习和下一代列车控制系统三方面阐述现阶段的国内外研究现状。深度学习的快速发展和在故障检测领域的广泛应用给了本文许多启发。最后阐述了本文的主要研究内容和创新点。

(2) 第二章进行了下一代车车通信 CBTC 系统方案设计研究。本文首先介绍了 CBTC 系统，总结了现有 CBTC 系统的问题，通过引入车车通信模式，对系统功能进行重新分配，新增多个功能模块，精简了轨旁设备并给出新增模块的具体功能。同时还优化了新型系统下的移动闭塞技术的交互方式。

(3) 第三章建立了列控系统安全风险预测特征集。首先定义了本文所研究系统的安全风险和列车运行状态类别，之后参考 CBTC 系统技术标准并结合下一代 CBTC 系统方案，进行风险预测特征初选择；对于列控系统领域中特殊特征值，本文采用了基于统计模型检验的算法对小概率特征值进行求取，其严谨的数学过程也保证了结果的有效性。最后，采用主成分分析方法降维处理，得出了最终的预测特征集。

(4) 第四章提出了面向下一代车车通信列车控制系统的智能安全风险预测模型框架：基于 LSTM 循环神经网络的分类框架。本文首先介绍了 LSTM 循环神经网络的相关理论基础，然后设计了安全风险预测模型的每层网络结构和训练算法，以及使用该模型所实现的安全风险预测过程，同时提出了使用 L2 正则化改进模型以克服训练不平衡数据集所导致的分类误差大的问题，有效提高了预测准确性，最后本文给出了该模型的综合训练过程。

(5) 第五章是实验验证与结果分析部分。本文基于 Keras 框架实现了该预测模型，并使用合作方的样本数据集进行了相关实验。首先给出了系统风险特征集构建实验结果，然后探讨了模型的训练结果，最后给出了该模型在测试数据集上的实验结果及与不同模型方法进行性能对比的结果。

(6) 第六章总结了全文研究内容，并对待研究领域进行展望。

第二章 基于车车通信的下一代列车控制系统方案

由下一代列控系统的研究现状及当前系统风险分析的挑战可知，通信模式单一限制了 CBTC 系统的各项性能提升及危害风险的避免。车车通信模式在下一代 CBTC 系统中的集成是目前研究趋势。为此，本章提出了下一代车车通信列车控制系统（Train-to-train communication based train control, T2T-CBTC）的方案设计。该方案基于现有系统不足，通过增加车车通信以优化系统结构，对关键功能进行重新分配，克服了系统现存问题，是下一代 CBTC 系统的发展方向。同时本章还优化了下一代系统中移动授权技术。

2.1 基于通信的列车控制系统

作为当前世界最新一代的自动列车控制系统（Automatic train control, ATC），基于通信的列车控制系统（Communication Based Train Control, CBTC）拥有连续双向的数据通信能力和高效的列车精准定位技术，保证列车与轨旁设备能够即时交换控制信息。同时，车载和轨旁子系统能够实现许多安全关键功能，如列车自动运行（Automatic train operation, ATO），列车自动防护（Automatic train protection, ATP）和列车自动监控（Automatic Train Supervision, ATS）^[1]。

标准的 CBTC 系统主要由车站系统，轨旁系统和车载系统三部分组成，如图2.1所示。车站控制中心系统负责 ATS 功能，列车运行调度和线路的规划的实现，主要包括了 ATS 系统，维护中心，数据存储单元（Database Storage Unit, DSU）等。轨旁系统承担了确定列车位置，为每列列车计算其移动授权信息并控制运行的职能，主要包括区域控制器（Zone Controller, ZC），接入点（Access Point, AP），计算机联锁系统（Computer based Interlocking, CBI），信号机，信标等核心设备。车载系统包括车载控制器（Vehicle On-Board Controller, VOBC）和人机交互界面（Driver Machine Interface, DMI），以实现 ATO 和 ATP 功能。轨旁系统和车载系统之间的交互主要依靠数据通信系统（Data Communication System, DCS）来实现。

CBTC 系统以“移动闭塞”（Moving block）技术为其运行核心来保证列车之间的安全运行。在系统设定中，轨道以“区块”（block）为单位进行分割，这也

是一辆列车所占用的轨道区域，同时会安装轨道电路以确定列车是否在区块内。区块的长度由各种因素决定，包括轨道线路的繁忙程度，线路上的最大允许速度，不同列车的最大速度和制动能力，定位等。在传统的列车控制系统中，当列车在一个区块内行驶时，因为没有实时的方法确定其在区块内的确切位置，因此将整个区块声明为已占用，无论列车的具体速度和制动能力如何，其他列车都不允许进入该区块内行驶。由于这些区块的边界是固定的，这种类型的运行控制方式被称为“固定闭塞”（Fix block）。虽然列车能在这种模式下安全运行，但对轨道资源的极大浪费却不可避免。相比之下，在“移动闭塞”运行控制方法中，固定的分割点被取消，区块范围的确定是基于列车和轨道的实时信息。轨旁设备与列车之间可以实时交互信息，列车位置也被不断地更新。因此，区块会随着列车的前进而移动，并且反映列车的实际位置。一般情况下，每个区块由一个 ZC 负责。在其管辖的区域内，ZC 的核心功能是为负责的列车提供移动授权（Movement Authority, MA）信息，限定了列车可安全运行的最大距离。

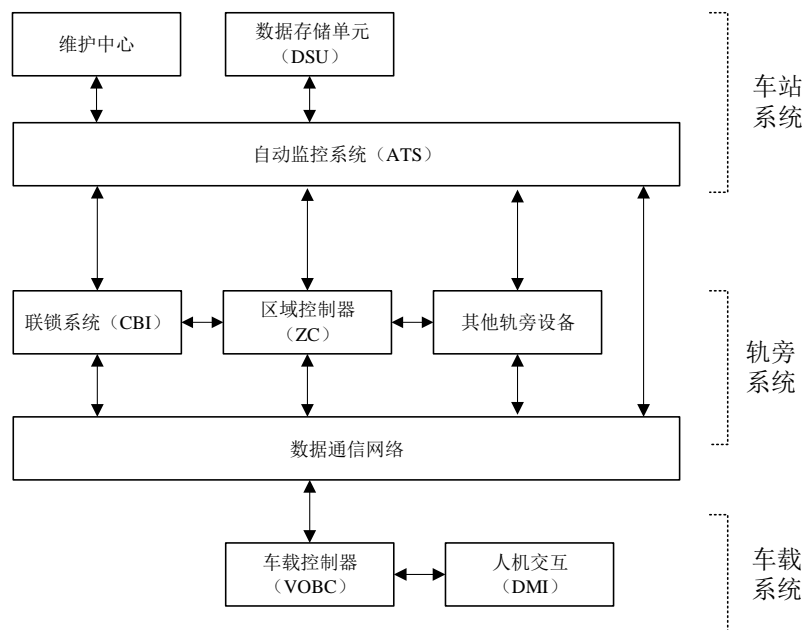


图 2.1 基于通信的列车控制系统功能架构图

2.2 CBTC 系统现存问题

“车—地—车”的通信方式是现阶段 CBTC 系统的主要通信模式，但对安全关键系统而言，这种通信方式存在着信息交互环节多，通信延迟长，不利于列车关键信息传送等问题。其中较为突出的缺点有以下几点：

(1) 信息交互环节多，增加运行风险。在两车保持安全距离运行的任务中，前方列车的信息对于当前列车来说是至关重要的，但后车获取前车信息的方式是间接的。后车执行命令的产生依赖于地面轨旁设备对于前车信息的获取，即后车并未直接与前车交互。前车将信息发送至 ZC，由 ZC 进行处理并生成移动授权 (Movement authority, MA)，该信息发送至后车以指导其运行。整个过程的数据流向为“前车—ZC—后车”，信息交互环节较多。如果其中任意一个环节出现故障，可能导致系统不可用，使得列车存在运行风险。

(2) 集中式列车控制管理，无法克服单点故障所带来的影响。如轨道或列车的信息维护，实时移动授权计算等与列车运行相关的关键功能都位于轨旁设备 ZC 中，VOBC 只负责根据移动授权信息产生控制命令指导列车运行。同时，ZC 需要管控负责范围内的多列列车。因此，ZC 系统负载较大，信息处理过于集中。一旦 ZC 发生故障，将影响管辖范围内多辆列车的运行。

(3) 设备众多，维护成本大。为了保证列车运行安全，必须配备充足甚至冗余轨旁设备以保障其故障发生时的可用性，尤其是轨旁系统中的 ZC 系统和 CBI 系统。过多的设备造成维护成本上升，也极大地限制了轨道利用率和列车运行效率的可提升性。

(4) 计算和存储能力有限。列车控制的集中式管理导致单个设备必须处理多列列车信息。单个设备可存储的列车信息受硬件和成本方面的限制，可提升性不大。设备的计算能力即使在多核多并行情况下也有其局限性和性能制约点。

(5) 通信广播模式易造成网络拥塞。列车与地面设备之间以广播的方式进行命令信息交互。当无线网络上传数据过多无法及时处理时，极易造成“广播风暴”问题，严重时导致性能下降，网络瘫痪。

2.3 基于车车通信的下一代 CBTC 系统方案设计

本节主要介绍下一代车车通信 CBTC 系统方案的设计，及是如何克服当前 CBTC 系统的现存问题。

本文提出了 T2T-CBTC 系统的方案设计。如图 2.2 所示。图中深色模块代表系统的新变更。主要的变化有：

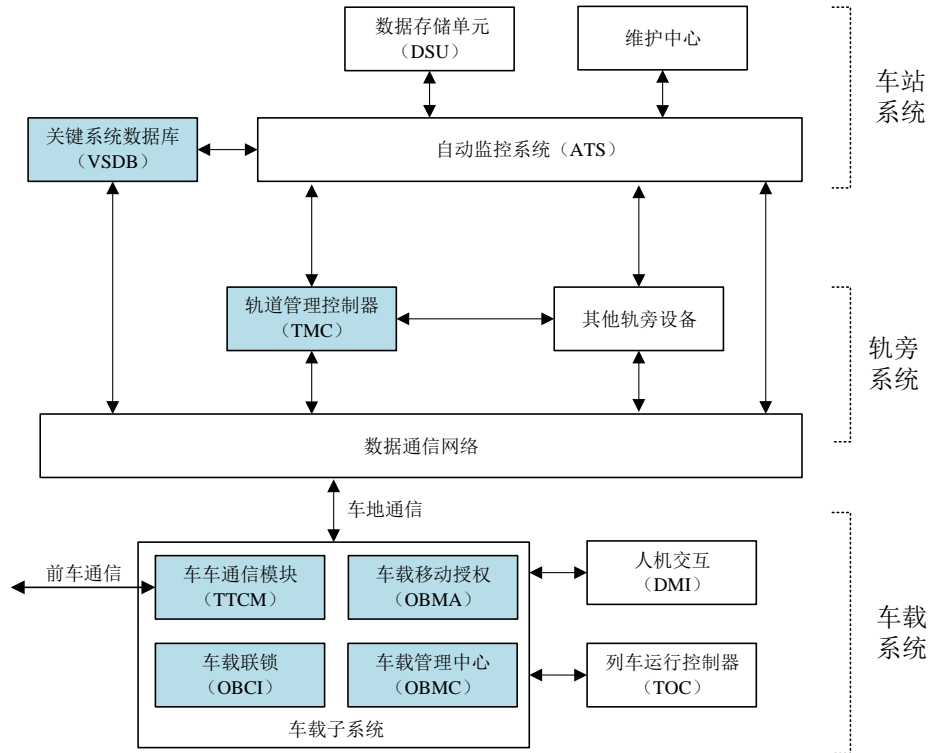


图 2.2 下一代车车通信 CBTC 系统方案设计

- (1) 系统既保留了原有的车—地通信模式，又新增了车—车通信模式。
- (2) 车站系统新增了关键系统数据库 (Vital system database, VSDB)。
- (3) 轨旁系统取消了 ZC 和 CBI 系统，新增轨道管理控制器 (Track manage Controller, TMC)。ZC 和 CBI 的部分功能集成于车载系统 VOBC 上，相邻列车信息的传送通过车车通信自主达成。
- (4) 车载系统的重要性和智能化得到扩展。VOBC 在原有功能的基础上，新增了车车通信模块 (Train-to-train communication model, TTCM)，车载移动授权 (On-board movement authority, OBMA)，车载联锁 (On-board computer interlocking, OBCI)，车载管理控制器 (On-board manage controller, OBMC)。因此，VOBC 可以主动探测前方障碍物，主动查询路线信息，协同完成移动授权计算，实现了“以列车为核心”的设计原则。

本文将详细介绍下一代 CBTC 系统下每个子系统及新变化的具体功能。

车站控制中心系统 车站控制中心系统是列车及轨旁设备的地面控制中心，除了保留原有功能之外，新增了 VSDB 模块。与 DSU 不同，VSDB 负责存储线路信息和线路上所有列车信息，接收并存储轨道上所有故障列车的信息，同时负责向车载设备和 ATS 系统提供多种障碍物信息，以帮助它们实现相关功能。同时，VSDB 还负责新上线列车的 ID 注册和登记。

车载系统 与传统的车载系统相比，除了固有的一些功能模块之外，VOBC 系统分别增加了 OBCI，OBMC，OBMA 和 TTCM 功能模块。

- OBCI 负责进路管理、进路排列和执行，以及道岔信息的管理，并且为车载其他模块提供进路信息。

- OBMC 是车载设备的重要模块之一，也是车载指令产生所需信息的存储和集合中心。例如，当前列车和相邻列车的 ID 和位置等信息由它管控，出现的故障也由它进行汇总。

- OBMA 是原 ZC 系统中移动授权计算功能的实现模块，根据 OBCI，OBMC 和 VSDB 提供的各种信息为列车生成移动授权，使得列车以最小的安全车间距进行行驶。

- TTCM 作为车车通信实现的关键，负责与相邻列车进行身份识别和通信建立，实现与线路上其他列车数据的交换，是系统外部通信接口。

轨旁系统 轨旁设备不再提供关键功能的计算和控制，主要取消了 ZC 和 CBI 设备，系统设备之间信息交互速度有效提高。同时，轨旁系统还新增了轨道管理控制器 TMC。TMC 是精简功能后的 ZC 和 CBI 的融合，负责了原 ZC 中与区域列车信息存储、查询、发送相关的功能和原 CBI 中轨道资源信息及状态管理的功能，但不进行任何控车管理，不属于安全关键相关设备。它负责与进入其管辖范围的列车建立通信，可避免不同 OBCI 对线路资源的抢占。

通信方式变革和软硬件技术的不断发展促使了车车通信模式的列车运行控制系统成为可能，而该系统通过以下几点解决了现存问题：

- (1) 列车间直接通信减少了控制信息的交互环节，也使得一个 AP 负责多辆列车而引发的广播风暴问题得到了解决，有效降低了因通信问题而导致的危害风险发生的可能性。

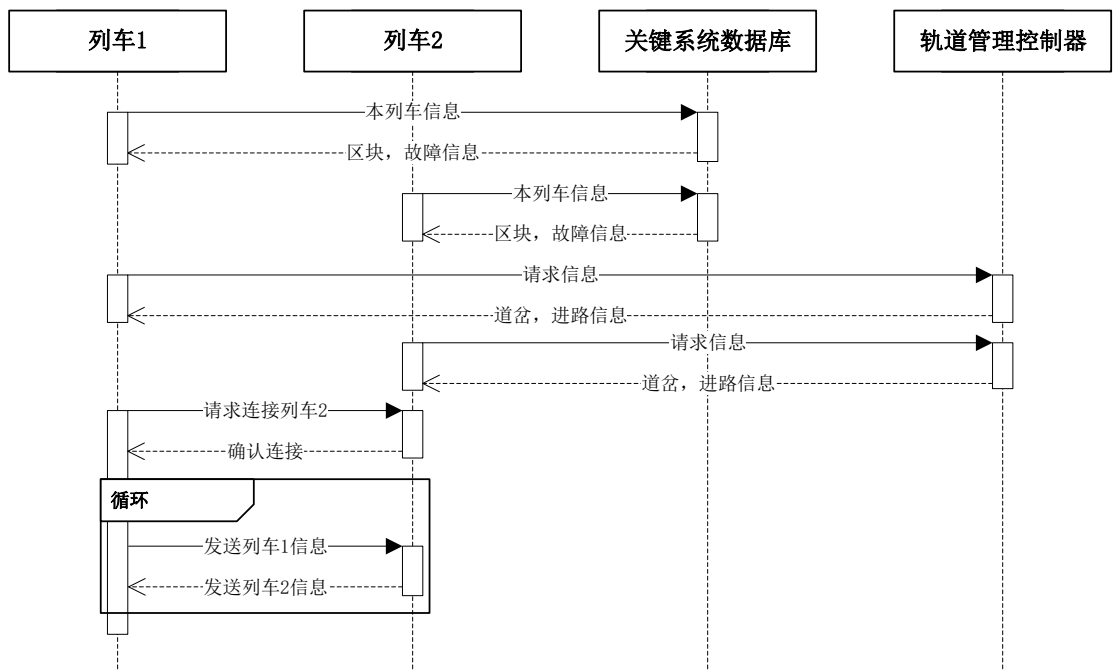


图 2.3 T2T-CBTC 系统下移动闭塞技术 UML 时序图

(2) “车地 + 车车”的通信方式将多种关键功能并行处理，提高系统效率，有效避免风险事件的发生。

(3) 移动授权功能和联锁功能的分布式管理，既解决了单个系统负载过大而容易失效的问题，也克服了设备计算和存储能力的局限。

(4) 系统的优化使得轨旁设备减少，整体可靠性提高，减小成本，可维护性提高。

(5) 系统在车车通信模式下能缩短信息交互时间，使得两相邻列车以最小的安全车间距运行，同一时间下轨道可运行的列车增多，提高了运输效率和负载量，轨道利用率和系统效率也得到了提升。

通过解决现有 CBTC 系统的问题，基于车车通信的下一代 CBTC 系统解决了对轨旁设备依赖较高的问题，拥有了更低的运行风险。

2.4 基于车车通信的下一代 CBTC 系统移动闭塞技术

本节主要描述了移动闭塞技术在下一代 CBTC 系统中的具体优化。

移动授权（Movement Authority，MA）是防止列车相互碰撞最核心的信息，也是移动闭塞技术中最关键的功能。MA 计算中信息交互繁琐是导致失效情况发

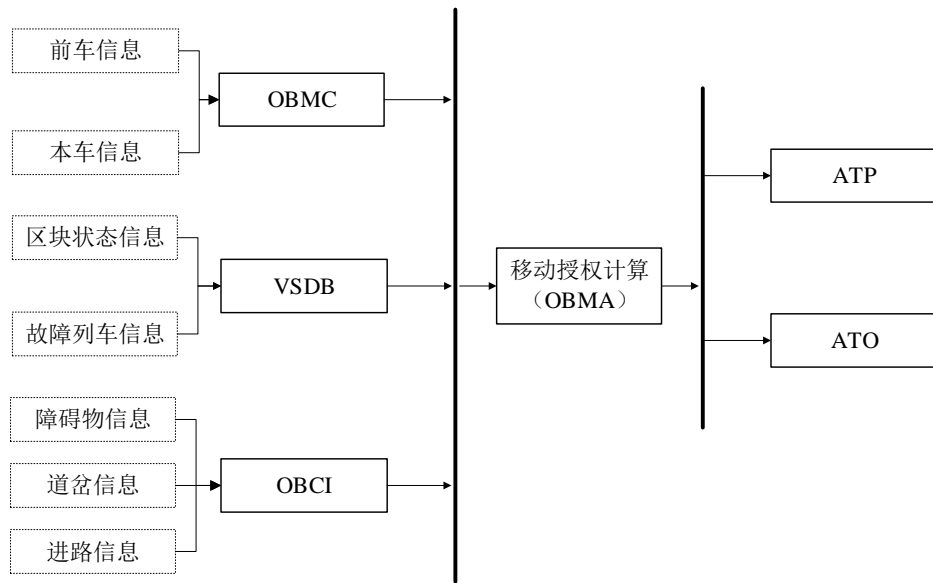


图 2.4 T2T-CBTC 系统中移动授权计算模块信息交互图

生的主要原因之一。移动闭塞技术在下一代 CBTC 系统中的变化体现在两方面：其一是列车与列车、地面设备之间通信方式的变化，其二是 MA 计算过程中信息交互的更新。

MA 的作用为，系统以列车头部作为授权起点，考虑当前轨道信息，各设备的状态和障碍物信息，计算列车最远能运行到的一个位置坐标，即授权终点（End of Authority, EOA）。EOA 表示列车在从目前的列车位置到这个终点的轨道区域是可以安全运行的，没有一列火车可以同时进入这个区域。该信息之后将被传送至车载系统，执行 ATP 和 ATO 功能以调整列车行驶行为。MA 直接决定了列车的行进距离，速度和方向，同时，也指导着 ATP 和 ATO 功能的执行，如计算列车紧急制动曲线。

在 T2T-CBTC 系统中，由于核心功能的再分配，MA 的计算功能迁移到 VOBC 系统中实现，信息的交互借助于车车通信而较少地依赖于轨旁设备。本文给出了在 T2T-CBTC 系统中，移动闭塞技术中车车通信交互的 UML 时序图（图 2.3）和 MA 计算实现的信息交互过程（图 2.4）。

如图 2.3 所示，列车 1 为当前列车，列车 2 为相邻前方列车。列车 1 和列车 2 需定时与 VSDB 和 TMC 交互以更新相关列车信息。列车与 VSDB 进行区块，故障信息的交互；与 TMC 进行道岔，线路信息的交互。当双方各自信息有更新

时才会触发列车与地面设备的交互。列车与相邻前方列车在通信连接建立之后进行一对一通信以实现列车间的信息交互。该过程因 MA 计算的需求使得更新频率要远高于列车与地面设备。该时序过程通过车地通信方式的降低和车车通信方式的增加以减少信息交互过程，提高了列车计算 MA 的频率，从而提高系统效率。

如图 2.4 所示，OBMA 与 3 个模块进行信息交互，分别为 OBMC，OBCI 和 VSDB。OBMC 提供了前方列车的速度，位置坐标，行车方向和当前列车的信息；OBCI 提供了进路信息，道岔信息以及障碍物和缓冲区等信息；而从 VSDB 可以获得线路故障列车信息和区块状态信息。基于以上信息，OBMA 可以计算出当前列车的移动授权终点 EOA，直接传送给 VOBC 中的 ATP 和 ATO 设备进行列车的安全运行控制，而无需更多的信息交互。

在移动授权生成过程中，系统是以一种迭代搜索的方式来计算 EOA。首先需要规定搜索线路的终点，然后根据搜索起点，搜索方向和搜索距离来进行 EOA 的计算。本文在图 2.5 中给出了 EOA 生成算法的流程图。

算法的开始需要判断输入参数的合法性，如果不合法则直接结束算法。接着，检查列车当前所在区块的长度是否大于给定的搜索距离，如果是，那么以当前区块终点作为 EOA，否则向前迭代搜索线路。每次搜索后需要进行判断：如果已搜索的距离到达了需要搜索的距离点，那么算法结束，以该距离所对应的区块位置作为 EOA，否则进入下一个区块进行迭代搜索，同时获取下一个区块信息验证其合法性，；如果迭代次数达到了当前考虑的区块数量的上限，则算法结束，以搜索线路终点区块作为 EOA。

在基于车车通信的下一代 CBTC 系统中，通信方式的改变极大优化了移动闭塞技术。MA 计算中信息交互繁琐是导致失效情况发生的主要原因之一，由通信方式变化所带来的系统架构优化，促使了列车信息交互方式的优化和核心功能的可靠性提高。更少的信息交互带来的是更可靠的信息传送，从而提高了 MA 功能的可靠性，降低了系统风险。

2.5 本章小结

针对现有单一车地通信模式下 CBTC 系统的问题，本章提出了基于车车通信模式的下一代列车运行控制系统 T2T-CBTC 的方案。本章首先介绍了 CBTC

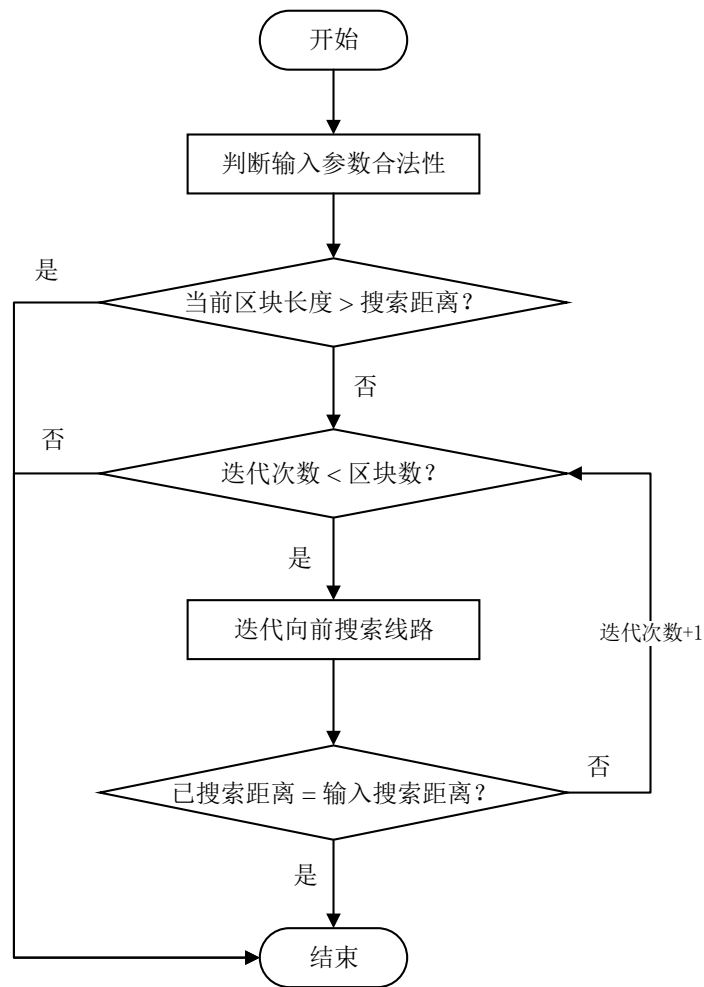


图 2.5 移动授权功能 EOA 生成算法流程图

系统，分析了 CBTC 系统的现存问题。然后围绕这些问题，提出了下一代车车通信列车控制系统 T2T-CBTC 的整体功能结构方案。该方案增加了车车通信模式，基于“精简系统架构，减轻轨旁负载”的原则对传统系统做出功能改善，将部分轨旁功能分散到车载系统上，新增多项功能模块，同时优化了下一代系统方案下移动闭塞技术执行过程。

第三章 系统安全风险预测特征建立方法

本章将研究系统安全风险预测方法中的第一部分，即列控系统风险预测特征的选择和处理。本章提出了面向下一代列控系统的安全风险预测特征建立方法。该方法包含特征初步选择，特殊特征值生成，特征集降维三个步骤。特征初步选择步骤基于 IEEE 标准 1474.1-2004^[1] 进行预测特征类别的判定和初步选择。对于列控系统领域，小概率值特征项与其他特征的生成采样方法不同，本章提出了采用统计模型检验算法来解决小概率特征生成问题。特征降维作为特征集建立的最后一个过程，以主成分分析为方法，最大程度保留了包含原始信息的有效特征值。

3.1 系统安全风险定义

面向 CBTC 系统的 IEEE 标准 1474.1-2004^[1] 中规定：对于 CBTC 系统，建立完善的系统安全风险分析是非常必要的，主要目的是识别运行中的危险和预防事故发生。T2T-CBTC 系统被定义为一类安全关键系统，具有系统组成复杂，信息交互多，不确定性强的特点。系统中常见的危害事件有：列车间碰撞，列车与建筑物相撞，列车脱轨，列车与高速路车辆相撞，车门关闭时乘客发生拥挤，列车与障碍物碰撞等。为了达到识别危险事件，预防故障发生的目的，本文通过预测在一定系统运行条件下列车会处于的某种风险状态，来评估系统的安全风险。

本文考虑的风险事件是：列车碰撞。

在考虑碰撞危险的情况下，本文定义了列车运行可能的 4 种状态：

定义 3.1 (列车运行状态 y) 列车运行状态可以被如下定义：

$$y = \begin{cases} c1 & \text{无碰撞，列车稳定运行，不会发生碰撞事件} \\ c2 & \text{紧急停车，列车将要发生碰撞但及时进行了紧急制动} \\ c3 & \text{轻微碰撞，列车发生了碰撞，未造成人员伤亡} \\ c4 & \text{严重碰撞，列车发生了碰撞，车体受损，造成人员伤亡} \end{cases}$$

定义 3.2 安全风险 (Safety risk, SR) 是指在一定系统运行条件下，列车处于 $c3$

或 $c4$ 运行状态的概率。

$$SR = P(y = c3 \text{ 或 } c4) \quad (3.1)$$

假设样本数据集的形式为 (\mathbf{F}, y) ，其中 \mathbf{F} 为安全风险预测任务的特征向量， y 是在当前系统状态参数下的列车运行状态，即 $c1$ ， $c2$ ， $c3$ 和 $c4$ 。因此，该问题转化为，需要寻找一个函数 f ，能够建立风险预测特征 \mathbf{F} 和列车运行状态 y 间的映射关系：

$$f : \mathbf{F} \rightarrow y \quad (3.2)$$

接下来，本文将分别介绍预测特征 \mathbf{F} 的选择过程和函数 f 的构建过程，其中函数 f 即是本文所研究的智能预测模型，主要通过深度学习来实现。

3.2 安全风险预测特征选择

本文从现有 CBTC 系统设计标准出发，结合下一代 CBTC 系统方案设计，对进行安全风险分析的预测特征进行初步选择。IEEE1474.1^[1] 标准中提出，风险分析过程的特征应考虑构成系统及其环境的主要要素，包括设备（equipment）、能力（facilities）、程序（procedures）、人员（people）四类。本文从这四类因素入手对系统进行分析。

设备 设备间的交互合作构成了 T2T-CBTC 系统的正常运行。由2.1节介绍可知，CBTC 系统主要包含三类设备：地面控制中心设备，轨旁设备，车载设备。本文综合考虑后选择的相关预测特征为：设备已运行的生命周期，设备平均故障时间，列车速度，最大速度限制值，定位测量误差，列车速度测量误差，设备间最大交互时间的累计误差，移动授权更新后车载配置更新时间等。

能力 能力主要指与系统运行有关的性能及配置，例如，列车长度，轨道区块长度，轨道运行行驶方向，可允许处理的最大列车数等。不同的运行配置会导致不同的运行结果。

程序 列控系统的关键功能依赖着程序计算以处理相关请求和命令。程序运行最关心的是算法的效率和错误率。例如，移动授权算法故障率，移动授权计算周期，制动速度曲线计算故障率，制动速度曲线计算时间，自动速度管理算法故障率。

表 3.1 风险预测特征初步选择结果列表

类别	预测特征	特征变量范围值	特征变量描述
能力	车车通信延迟	$0.5\text{ s} \sim 1\text{ s}$	车车通信模式下的延迟时间
	车地通信延迟	$0.7\text{ s} \sim 1.5\text{ s}$	车地通信模式下的延迟时间
	最大列车数	$10 \sim 40$	单个区块内最大可运行列车数
	列车运行定位误差	$\pm 5\text{ m} \sim \pm 10\text{ m}$	列车在正常运行下定位的误差
	列车位置计算误差	$\pm 0.25\text{ m} \sim \pm 6.25\text{ m}$	列车在计算移动授权时车辆位置误差
	列车速度误差	$\pm 3\text{ km/h}$	列车运行速度测量误差
设备	列车速度	$0\text{ km/h} \sim \pm 80\text{ km/h}$	列车运行速度
	列车加速度	$0\text{ m/s}^2 \sim 2\text{ m/s}^2$	列车运行加速度
	轨道方向	Up or Down	当前区块轨道方向
	车载设备响应时间	$0.07\text{ s} \sim 0.75\text{ s}$	车载系统的设备响应时间
	轨旁设备响应时间	$0.07\text{ s} \sim 1\text{ s}$	轨旁系统的设备响应时间
	已运行时长	$0\text{ h} \sim 10\text{ h}$	列车已运行时长
人员	人流量	$3 \sim 4\text{ w/h}$	每小时人流量
	平均工作年限	$0 \sim 20\text{ y}$	该列车乘务人员的平均工作年限
	司机持续工作时间	$0\text{ h} \sim 8\text{ h}$	工作人员持续工作时间
	运行模式	自动/人工	列车运行模式
程序	移动授权失效概率	$< 10^{-8}$	移动授权功能在计算授权终点时的失效概率
	移动授权计算时间	$0.07\text{ s} \sim 1\text{ s}$	移动授权计算授权终点时时间周期
	制动曲线计算失效概率	$< 10^{-8}$	制动曲线计算的失效概率
	制动曲线计算时间	$0.07\text{ s} \sim 1\text{ s}$	制动曲线计算时的时间周期
	自动速度管理算法失效概率	$< 10^{-8}$	自动速度管理程序的失效概率

人员 复杂系统运行中不可忽略人的影响。一定数量的事故原因与人有关。其中较为突出的影响有，系统运行模式，人工模式下工作人员数，人流量，司机持续工作时间等。

综上所述，本文根据 4 类因素进行初步选取后的预测特征共有 21 个，如表 3.1 所示。表中的系统特征变量取值范围值来自于本文的合作方公司，主要参考现有 CBTC 系统设计标准和下一代方案进行综合考虑所得。

3.3 基于统计模型检验的小概率特征值生成

本节提出了基于统计模型检验的 T2T-CBTC 系统的小概率预测特征生成算法。具体来说，是计算了在系统传感器数据不可靠的情况下，该小概率特征功能发生失效的概率是多少。首先进行了小概率特征生成问题的转化，之后提出了基于统计模型检验的小概率特征值生成算法的具体实现。

3.3.1 背景介绍

统计模型检验

模型检验（Model Checking）是一种基于计算机辅助的动态分析系统的验证技术，属于形式化验证方法的一种。它结合了数理逻辑、编程语言、硬件设计和理论计算机科学等方面的知识，广泛地应用于工业界软硬件的验证问题中。模型检查器通常以蛮力的方式搜索系统所有可能状态，如深度搜索和广度搜索。这种方式可以证明给定系统模型是否满足某些属性。通常采用状态转移系统（Transition System）对系统进行建模，用属性定义语言对系统属性进行描述。模型检验的方法流程如图 3.1 所示。但遍历系统所有空间状态导致了传统的模型检验方法在验证复杂系统时会出现空间爆炸的问题，同时复杂系统存在着组件性能的不确定性。这些问题使得对其进行模型验证变得不可行。统计模型检验方法在该挑战上是一种突破性的解决方法。

统计模型检验（Statistical Model Checking, SMC）技术属于模型检验方法的一种，常适用于随机系统相关安全属性验证。与数值的模型检验方法不同，SMC 是根据对系统模型进行多次模拟运行的结果来计算模型满足给定系统属性的概率。这种方法的理论依据在于，随机系统的模拟运行根据系统定义的分布所呈

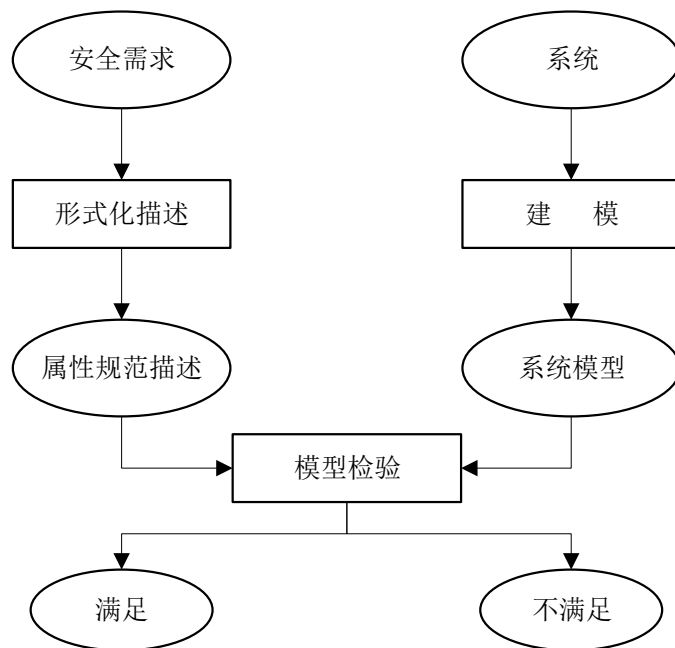


图 3.1 模型检验流程图

现。因此该模拟结果可用于估计系统某个运行动作的概率，也常用于验证某个小概率事件发生的可能性。

统计模型检验的形式化定义如下：

定义 3.3 (统计模型检验) 给定随机系统模型 M ，系统需要验证的属性为 ϕ ，那么统计模型检验是验证：模型 M 满足属性 ϕ 的概率为多少，同时该概率是否大于或等于阈值 θ ，即， $M \models P_{\geq \theta}(\phi)$ 。

统计模型检验方法包含以下三个过程：

- (1) 系统模拟：模拟运行系统模型 M 并采样模型执行路径（Trace） σ ；
- (2) 属性公式验证：验证每一条路径 σ 是否满足属性公式 ϕ ；
- (3) 统计分析：根据执行路径 σ 满足属性公式 ϕ 的采样结果来计算模型 M 满足属性公式 ϕ 的概率 p 。

统计分析过程会通过产生更多的模型执行路径 σ ，以使得概率 p 的值在一个可接受误差 θ 的范围内。虽然基于系统模拟的方法得到的输出并不一定精确无误，但是统计分析可以保证误差在一个可接受的范围内。

SMC 实现验证的原理是蒙特卡洛方法。蒙特卡洛 (Monte Carlo method) 方法, 又称统计模拟方法, 在 19 世纪 40 年代由物理学家 Stanislaw Ulam 和 Von Neumann 在中子链式反应的模拟实验中提出^[29]。蒙特卡洛方法的基本思想是, 利用重复随机抽样实验获得的结果来接近问题的最优解。蒙特卡洛方法的一般流程如下:

- (1) 对系统模型进行随机模拟采样, 可以获得 N_{MC} 个系统执行样本 X_1, \dots, X_n
- (2) 根据定义域 B 指定指示函数 $I_B(X) \in \{0, 1\}$, 如果 $X_i \in B$, 则 $I_B(X) = 1$, 否则 $I_B(X) = 0$
- (3) 样本 X_i 属于 B 的概率为:

$$E = \frac{1}{N_{MC}} \sum_{i=1}^{N_{MC}} I_B(X_i) \quad (3.3)$$

SMC 方法的优点在于, 直接检验目标系统的安全约束而不用分析其复杂的内部逻辑; 同时, 以数理逻辑和统计学作为理论基础, 通过严谨的推理过程保证了算法在安全关键系统领域应用的可靠性。

有界线性时态逻辑

有界线性时态逻辑 (Bounded linear temporal logic, BLTL) 属于时态逻辑语言的一种, 用于描述系统中的约束属性。其中的“界”定义为时间步或时间单元, 表示 BLTL 公式必须运行的时长^[30]。

定义 3.4 给定一个模型 M 和实值状态变量集 Var_s , Var_s 上的布尔谓词是 $y \sim v$ 形式的约束, 其中 $y \in Var_s$, $\sim \in \{\geq, \leq, =\}$, $v \in \mathbb{R}$ 。BLTL 逻辑公式 ϕ 的语法可以定义为:

$$\phi ::= y \sim v | (\phi_1 \vee \phi_2) | (\phi_1 \wedge \phi_2) | \neg \phi_1 | (\phi_1 \mathbf{U}^t \phi_2) | \mathbf{F}^t \phi_1 | \mathbf{G}^t \phi_1 \quad (3.4)$$

BLTL 公式描述的是模型执行路径所满足的约束, 即 $\sigma \models \phi$ 。 σ^m 是指从第 m 步开始的执行路径。因此, 路径 σ 的定义和 BLTL 逻辑公式的相关语义分别为:

定义 3.5 (路径 σ) 路径 σ 是一个序列 $(s_0, t_0), (s_1, t_1), \dots$, 表示系统在状态 s_i 停留时间 t_i 后, 转移到了状态 s_{i+1} , 并停留了时间 t_{i+1} 。

定义 3.6 (有界线性时态逻辑公式语义) 对于路径 σ^m :

- $\sigma^m \models AP$ 当且仅当 AP 在状态 s_m 成立
- $\sigma^m \models \phi_1 \vee \phi_2$ 当且仅当 $\sigma^m \models \phi_1$ 或者 $\sigma^m \models \phi_2$
- $\sigma^m \models \phi_1 \wedge \phi_2$ 当且仅当 $\sigma^m \models \phi_1$ 并且 $\sigma^m \models \phi_2$
- $\sigma^m \models \neg\phi_1$ 当且仅当 $\sigma^m \models \phi_1$ 不成立
- $\sigma^m \models \phi_1 \mathbf{U}^t \phi_2$ 当且仅当 存在 $i > 0$ 满足以下条件:
 - a. $\sum_{0 < l < i} t_{m+l} \leq t$
 - b. $\sigma^{m+i} \models \phi_2$
 - c. 对每个 $0 \leq j \leq i$, $\sigma^{m+j} \models \phi_1$
- $\sigma^m \models \mathbf{F}^t \phi_1$ 当且仅当 $\text{true} \mathbf{U}^t \phi_1$, 即在时间 t 内, ϕ_1 最终会被满足
- $\sigma^m \models \mathbf{G}^t \phi_1$ 当且仅当 $\neg \sigma^m \mathbf{F}^t \neg \phi_1$, 即在时间 t 内, ϕ_1 总是被满足的

3.3.2 问题转化

对安全关键系统的行为进行自动验证存在的一个主要障碍是系统组件或外部环境的不确定性造成的验证结果不稳定。例如, 飞行控制系统需要处理那些来自传感器的不可靠读数, 或者在高海拔受到随机宇宙辐射时能够正确进行识别和反应。一般系统验证方法无法处理这种随机性所带来的影响, 而导致结果不准确。列控系统也存在着同样的问题。

如表 3.1 所示, “程序”类别中功能失效概率存在着随机效应, 其生成会因系统不确定而无法通过一般方式获得, 而统计模型检验方法在该问题上是一种突破性的解决方法。统计模型检验基于抽象的系统模型和简约严谨的约束表达, 同时融入统计理论, 有效地将系统中的随机效应考虑进计算中。在统计模型检验中, 计算功能失效概率的问题可以转换成对系统的相关安全属性进行验证的问题。例如, 若要计算“移动授权功能失效概率”, 可以通过验证“系统移动授权功能不会发生错误”这一安全属性进行实现, 即“功能失效概率计算 \Rightarrow 安全属性验证”。

然而, 与一般系统不同, 列车控制系统具有较高的安全完整性等级 (Safety Integrity Level), 一般达到了 4 级, 即系统的失效概率要求在 $10^{-6} \sim 10^{-8}$ 之间。毋庸置疑的是, 安全关键系统中的这类小概率失效情况对于系统安全是非常重要的, 但若使用基于模拟的统计模型检验算法去验证它将会是一个不小的挑战。主要原因是为了要获得小概率失效情况发生的样本, 必须对系统模拟指数级别

的次数，需要大量的仿真时间，这大大降低了算法实行的效率。例如，规定 0.01 的相对误差（Relative error, RE）下，为了估计 10^{-8} 数量级的失效概率 p ，将大约需要 $N = \frac{1}{p \cdot RE^2} = 10^{12}$ 个样本数，以此进行系统模拟将是不可行的。因此，减少模拟所需样本数，增大小概率失效样本数是解决该问题的关键。

3.3.3 小概率特征生成算法

将 SMC 应用于小概率安全属性验证需要解决的关键问题是，减少产生具有给定置信度的样本所必需的模拟次数，增大小概率失效情况发生的次数。采用重要性采样和交叉熵方法对原始统计模型检验方法进行优化可以实现这个目的。

重要性采样（Importance Sampling）是蒙特卡洛方法中常用的减少样本模拟量的方法，已经在 20 世纪 40 年代末得到了广泛应用^[31]。重要性采样的工作原理是，使用有利于小概率属性事件发生的加权模拟来估计失效概率，然后对权重进行补偿。加权模拟是通过权重函数 $W(X_i)$ 来实现的，它可以增大小概率样本发生的次数，有效减少仿真所需样本数量和仿真时间，得到较高精确度的仿真结果。根据重要性采样的原理，对原分布做如下变换，其中 $b(X)$ 是原 $f(x)$ 分布下的采样结果， $W(x) = \frac{f(x)}{f_*(x)}$

$$\begin{aligned}
 p &= E[b(X)] \\
 &= \int b(x)f(x)dx \\
 &= \int b(x)\frac{f(x)}{f_*(x)}f_*(x)dx \\
 &= \int b(x)W(x)f_*(x)dx \\
 &= E_*[b(x)W(x)]
 \end{aligned} \tag{3.5}$$

由式 (3.5) 可以得知， $W(x)$ 使得原本对 $f(x)$ 采样所得的 $E[b(X)]$ 变成了对 $f_*(x)$ 采样所得的 $E_*[b(x)W(x)]$ ，而 $f_*(x)$ 是一个宜于采样的概率密度函数，达到了减少仿真样本数量的目的。

因此，基于重要性采样的概率估计值为：

$$p_{IS} = \frac{1}{N_{IS}} \sum_{i=1}^{N_{IS}} I_B(X_i)W(X) \tag{3.6}$$

其中指示函数 $I_B(X) \in \{0, 1\}$ ， $N_{IS} \ll N_{MC}$ 。

现在问题转化为找到一个最优的概率密度函数 $f_*(x)$ 进行采样，但由(3.5)可以发现：

$$f_*(x) = \frac{b(x)f(x)}{p} \quad (3.7)$$

$f_*(x)$ 的计算取决于要求得的 p ，因此，无法以一种准确的方法找到 $f_*(x)$ ，需要在概率密度函数参数族中进行搜索，选择一个密度函数来“接近”最优概率密度函数。

交叉熵算法（Cross-entropy method），又称 Kullback-Leibler 散度，是能够评估概率分布之间距离的唯一正确度量^[32]。同时，它也已经常用于寻找重要性采样中的最优分布函数^{[33][34]}。两个概率密度函数 $g(x)$ 和 $h(x)$ 之间的交叉熵可以表示为：

$$\begin{aligned} CE(g, h) &= \int g(x) \log \frac{g(x)}{h(x)} dx \\ &= \int g(x) \log g(x) - \int g(x) \log h(x) dx \end{aligned} \quad (3.8)$$

概率密度函数族为 $f(\cdot, \tau)$ ，其中 $\tau \in \Gamma$ 是一个参数向量，以区分族中不同的概率密度函数。假设最接近最优概率密度函数的另一个函数为 $f(x, \tau_*)$ ，则

$$\begin{aligned} \tau_* &= \operatorname{argmin} CE(f_*(x), f(x, \tau)) \\ &= \operatorname{argmin} \int f_*(x) \log f_*(x) - \int f_*(x) \log f(x, \tau) dx \\ &= \operatorname{argmax} \int f_*(x) \log f(x, \tau) dx \\ &= \operatorname{argmax} \int b(x)f(x) \log f(x, \tau) dx \\ &= \operatorname{argmax} \int b(x)W(x, w)f(x, w) \log f(x, \tau) dx \\ &= \operatorname{argmax} E_w[b(x) \log f(x, \tau)] \end{aligned} \quad (3.9)$$

其中 $W(x, w) = \frac{f(x)}{f(x, w)}$ ， $w \in \Gamma$ 。 w 为倾斜函数，可以为任意值。

因此，最优参数 τ_* 的求取需要以概率密度函数 $f(x, w)$ 对系统进行采样。即，

$$\tau_* = \frac{\sum_{i=1}^{N_{CE}} b(X_i)W(X_i, w)X_i}{\sum_{i=1}^{N_{CE}} b(X_i)W(X_i, w)} \quad (3.10)$$

算法 3.1 是小概率特征生成算法伪代码。

算法 3.1 基于统计模型检验的小概率特征生成算法**Input:** 模型 M , 小概率属性 ϕ **Output:** $M \models \phi$ 的概率值 p

```

1:  $sat_{CE} = 0, sat_{IS} = 0$ 
2: for  $i = 1$  to  $N_{CE}$  do    // 1. 模拟系统以求得最优参数
3:    $\sigma = \text{Simulate model } M \text{ with } f(x, w)$ 
4:   if  $\sigma \models \phi$  then
5:      $sat_{CE}++$ 
6:   end if
7: end for
8: 根据式 (3.10) 求得  $\tau_*$ , 从而确定  $f(x, \tau_*)$ 
9: for  $j = 1$  to  $N_{IS}$  do    // 2. 模拟系统计算小概率属性发生概率
10:   $\sigma = \text{Simulate model } M \text{ with } f(x, \tau_*)$ 
11:  if  $\sigma \models \phi$  then
12:     $sat_{IS}++$ 
13:  end if
14: end for
15: 根据式 (3.6) 求得小概率属性的概率值

```

3.4 基于主成分分析的风险特征预测集降维

较多的数据特征输入会使得神经网络模型的学习能力下降, 训练时间过长, 非常容易达到过拟合的危险状态; 同时, 由于系统复杂, 状态参数多, 过多的特征不一定对列车运行分类有帮助^[35]。人工智能领域采用特征工程的方法来解决此类问题, 主要包括特征选择和特征降维。特征选择重点关注对训练任务有较大贡献的特征项。常用的有过滤法, 包装法和嵌入法^[36]。特征降维解决的是冗余信息和噪声信息对网络训练的影响, 将高维的数据向量映射到低维空间中, 构建出对任务最有效的特征向量。常用的特征降维算法有主成分分析法和线性判别分析^{[37][38]}。本节中将依据主成分分析的原理对预测特征进行降维再处理。

主成分分析 (Principal components analysis, PCA)^{[39][40]} 属于特征工程中的降维技术一类。与线性判别方法不同, PCA 属于无监督特征降维, 在执行过程中忽略对样本标签的考虑。利用它, 可以将一个 n 维的特征空间降低为 k 维的特征空间, 其中 $k < n$ 。降维后的数据集会尽可能多地保证来自原始数据集的信息。该过程实际上是对原始数据集进行了压缩。从另一种角度理解, PCA 是对原始数

数据集特征的编码过程 $f(x) = c$ ，该过程需要满足的约束为 $g(c) \approx x$ ，即解码后的信息与原始数据集相似。

本文首先给出基于 PCA 的 T2T-CBTC 系统安全风险预测特征降维模型。

特征降维模型 假设有 p 个数据样本，每个存在 q 个系统风险特征值，则原数据集为：

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1q} \\ x_{21} & x_{22} & \cdots & x_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ x_{p1} & x_{p2} & \cdots & x_{pq} \end{bmatrix} \quad (3.11)$$

其中， x_{ij} 表示第 i 个样本中第 j 个风险特征值，并且 $1 < i < p$ ， $1 < j < q$ 。

对 \mathbf{X} 进行特征降维是指，通过主成分分析方法，将原特征集融合抽取成 m 个关键特征，其中 $m < q$ ，同时满足：

- 新的 m 个特征能够以最小的损失误差来表现原 q 个特征的信息
- m 个特征之间不相关

特征降维步骤 接下来，本文根据上述模型，给出基于 PCA 对特征向量进行降维的步骤：

(1) 对原始数据进行去量纲化和零均值化的预处理步骤。数据预处理是让不同量纲和范围的特征之间在数值上有一定比较性，避免了量纲、取值范围和单位为降维带来的不便，有利于特征降维，也可在后续的训练中大大提高模型的准确性，避免模型在训练中过拟合。本文使用标准化（Standardization）进行数据集预处理。公式如下：

$$x = \frac{x_i - \mu(x)}{\sigma(x)} \quad (3.12)$$

经标准化处理后的数据均值为 0，方差为 1，符合标准正态分布。其中， $\mu(x)$ 为均值， $\sigma(x)$ 为方差。

(2) 求解特征集中各特征之间的协方差矩阵。 q 个原始特征之间的协方差矩

阵为 \mathbf{C} :

$$\mathbf{C} = Cov(\mathbf{X}, \mathbf{X}) = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1q} \\ c_{21} & c_{22} & \cdots & c_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ c_{q1} & c_{q2} & \cdots & c_{qq} \end{bmatrix} \quad (3.13)$$

(3) 执行协方差矩阵 \mathbf{C} 的特征分解过程。根据公式

$$\mathbf{C} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1} \quad (3.14)$$

对协方差矩阵 \mathbf{C} 进行特征分解, 其中 $\mathbf{\Lambda}$ 是由 q 个特征值 λ_i 作为对角线上的元素所组成的特征值对角矩阵, \mathbf{V} 为特征向量矩阵, 其中每一列 v_i 都为特征向量。 v_i 与 λ_i 相对应。

(4) 排序特征向量。按矩阵 \mathbf{C} 的特征值 λ_i 大小, 将其对应的风险特征向量进行排序。根据需求选取前 k 个形成转换矩阵 \mathbf{D} 。

(5) 确定降维后的矩阵 \mathbf{Y} 。

$$\mathbf{Y} = \mathbf{X}\mathbf{D} \quad (3.15)$$

通过 PCA 方法, 本文实现了 T2T-CBTC 系统风险预测特征的降维过程, 构建好了可用于模型预测的特征集。

3.5 本章小结

本章详细介绍了 T2T-CBTC 系统安全风险预测特征集的建立过程。在定义了本文所研究的列车通信下一代列车控制系统安全风险和列车运行状态类别之后, 本章参考列控系统技术标准且结合下一代 CBTC 系统方案, 确定了预测特征选择的范围类别, 并进行了初步选择。之后, 对于系统风险预测特征中的小概率特征值, 本章将概率求解问题转化为属性验证问题, 并提出了基于统计模型检验的小概率特征生成算法。最后, 本章采用了主成分分析法进行特征降维处理, 优化了特征的信息表达, 有助于减少数据维数的影响, 提高预测性能。

第四章 基于循环神经网络的安全风险预测模型

本章解决了下一代列车控制系统安全风险预测问题中的第二部分，即 T2T-CBTC 系统安全风险预测模型的建立。鉴于系统发生风险事件的时空相关性，本章提出了采用 LSTM 循环神经网络来建立该模型。首先介绍了 LSTM 循环神经网络的基本理论背景。之后，给出了基于 LSTM 循环神经网络的风险预测模型一般框架，设计了模型中每一层的网络设计和基于此模型进行风险预测的流程。受列车运行状态数据集类别不平衡的影响，一般的训练算法会导致模型效果过差且无法充分地判断少量样本，本章使用 L2 正则化方法优化训练误差函数以提高少量样本的识别程度。最后给出了该预测模型的总体训练流程。

4.1 LSTM 循环神经网络

循环神经网络（Recurrent Neural Network, RNN）作为人工神经网络的一种，由 Elman 等在 1990 年提出^[41]。它是具有循环结构的神经网络，能够将信息长久地存储下来，所以比一般神经网络在时间序列数据的学习上有较难超越的优势。除了基本的手写识别^[42]和语音识别^[43]等任务，RNN 还能胜任与上下文理解相关的任务，例如判断情感极性^[44]和处理短文本和长文本理解^[45]方面。图 4.1 是基本 RNN 单元，左半部分展示了 RNN 网络单元的架构，右半部分边展示了按照输入序列展开的 RNN 神经单元。形象地说，一个 RNN 神经单元可以按时序复制出多个神经单元节点，而各个复制节点之间存在信息的不断传递，即前一个节点的输出会成为下一个节点的输入。虽然从理论的角度来说，RNN 可以处理任何序列长度的信息，但在实际训练的过程中无法达到理想效果。尤其在语音识别或翻译中需要根据上下文来做出判断时，RNN 只能记住近距离的序列信息，从而会导致对整句理解的偏差。导致这种问题的主要原因是 RNN 使用的基于时间的反向传播（Back Propagation Through Time, BPTT）训练算法。该算法在误差反向传播时，梯度的更新会随着往前传播而发生指数级的衰减或放大，从而使得 RNN 的训练结果不理想。这个局限性因 1997 年长短时间记忆（Long Short Term Memory, LSTM）神经网络的出现而得到了解决^[46]。

LSTM 是一种学习长期和短期依赖关系的变异 RNN，擅长处理随机长度序




图 4.1 循环神经网络单元基本结构

列数据。Hochreiter 和 Schmidhuber 于 1997 年提出^{[46][47]}。与 RNNs 不同的是，除了拥有神经网络单元外部基本循环，它还拥有内部记忆单元的循环，即自循环。LSTM 网络单元结构如图 4.2 所示。其中细胞（cell）组件 c_t 就是 LSTM 的特别

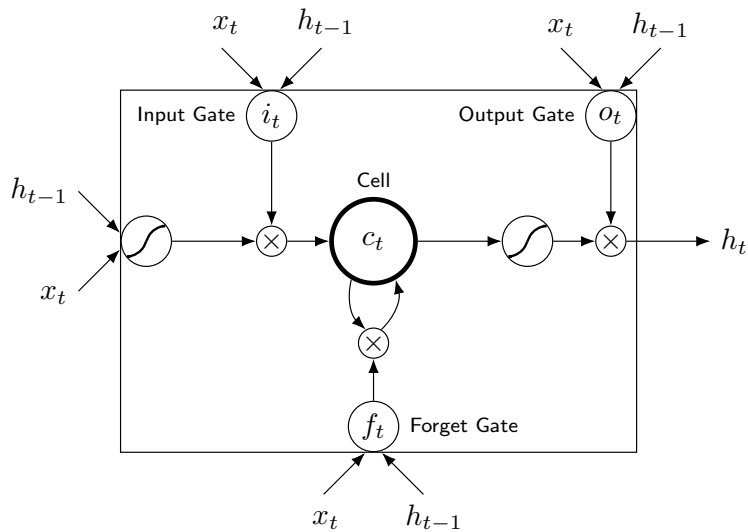


图 4.2 LSTM 网络神经元结构

之处，这个自循环可以保持细胞状态，并且保持更长时间的记忆，这也是 LSTM 结构解决消失梯度问题的关键。同时，LSTM 单元结构还增加了多个“门”结构（gate）来控制信息流在处理过程中的通过比例，从而实现了可控的、能够学习长期记忆的功能。它们分别为输入门（Input gate），输出门（Output gate），遗忘门

(Forget gate)，三个门结构的控制公式分别为：

$$\begin{aligned} \mathbf{f}_t &= \text{sigm}(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \\ \mathbf{i}_t &= \text{sigm}(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \\ \mathbf{o}_t &= \text{sigm}(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \end{aligned} \quad (4.1)$$

其中激活函数使用 *sigmoid* 函数。*sigmoid* 函数的输出在 $[0,1]$ 区间内，是常见的阈值函数。当输出为“0”时表示信息完全不通过，输出为“1”时表示信息完全通过。 $\mathbf{W}_f, \mathbf{W}_i, \mathbf{W}_o$ 分别是每个门的权重函数， $\mathbf{b}_f, \mathbf{b}_i, \mathbf{b}_o$ 分别是每个门的偏置。

LSTM 网络单元的输入由两部分组成，分别为：当前时刻的输入 x_t ，上一时刻的输出 h_{t-1} ，对这两部分进行综合处理才能得到神经元的输出。接下来，本文分别介绍三种门在 LSTM 网络神经元中对信息的处理过程。

当前输入 x_t 和上个时刻的输出 h_{t-1} 首先经过 *tanh* 激活函数的融合得到临时信息 $\hat{\mathbf{C}}_t$ ：

$$\hat{\mathbf{C}}_t = \text{tanh}(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \quad (4.2)$$

\mathbf{W}_C 和 \mathbf{b}_C 分别为权重和偏置。

接着，临时信息 $\hat{\mathbf{C}}_t$ 经过“输入门”以确定其进入细胞 c_t 的程度：

$$\mathbf{C}_t = \mathbf{C}_{t-1} + \mathbf{i}_t \otimes \hat{\mathbf{C}}_t \quad (4.3)$$

其中 \otimes 表示按位乘， \mathbf{C}_{t-1} 代表上一时刻细胞 c 的状态， \mathbf{C}_t 代表当前时刻的。但输入门持续的“1”状态会导致细胞饱和，“遗忘门”可遗忘过去的一部分信息来防止此类问题。受两个门控制后的细胞输出为：

$$\mathbf{C}_t = \mathbf{f}_t \otimes \mathbf{C}_{t-1} + \mathbf{i}_t \otimes \hat{\mathbf{C}}_t \quad (4.4)$$

最后，“输出门”确保仅有与当前任务相关的信息输出而防止无用信息。LSTM 网络单元的整体输出为：

$$\mathbf{h}_t = \mathbf{o}_t \otimes \text{tanh}(\mathbf{C}_t) \quad (4.5)$$

4.2 基于 LSTM 循环神经网络的风险预测模型

本节首先介绍了基于 LSTM 循环神经网络 (LSTM-RNN) 的风险预测模型框架，分别设计了其每层网络构成，训练算法和目标误差函数；然后给出了面向该模型的系统安全风险预测流程。

4.2.1 模型框架

列车碰撞风险的发生与这一时期的列车运行参数有着紧密联系。具体地说， T 时刻发生碰撞的系统运行参数变量是不同于正常运行状态下的，列车长时间的运行会使得其各部分发生故障的可能性提高；同时，碰撞发生前后时段内的系统运行变量也会存在时间相关性。因此，要建立有效的安全风险预测模型，必须从时间角度对特征数据进行提取和划分，处理系统状态参数时间序列数据，这对于提高列车风险运行状态预测分类的准确度至关重要。

一般的神经网络因不具备长时间记忆功能而对时序数据的分类判断呈现较差结果。因 LSTM 其自身独有的循环结构能够对长时间记忆进行存储预测，因此采用 LSTM 循环神经网络对此类数据进行分析是一个很好的选择。本文采用 LSTM 循环神经网络，构建了 T2T-CBTC 系统安全风险预测模型，模型框架如图 4.3 (a) 所示。

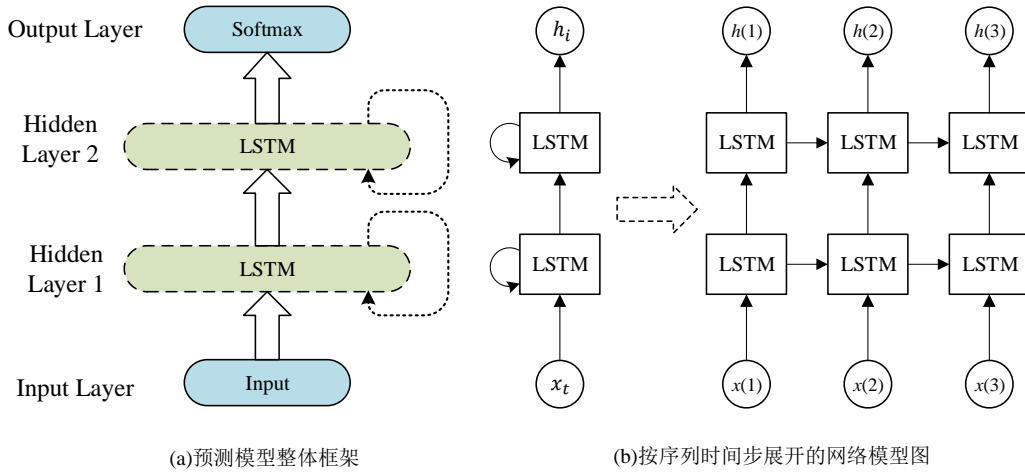


图 4.3 基于 LSTM 循环神经网络的安全风险预测模型及展开图

本文中的预测模型采用两层 LSTM 网络作为隐藏层 (hidden layer)，同时包含一个输入层 (input layer) 和一个输出层 (output layer)。

输入层 输入层神经元对应着风险预测特征序列向量 $F(t)$ 各维度，

$$F(t) = \{f_i(t) | i = 1, 2, \dots, m\} \quad (4.6)$$

输入样本的形式为一组时间序列数据样本

$$\mathbf{X} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\} \quad (4.7)$$

对于每一个时间序列样本有 t 个观测点，

$$\mathbf{x}_i = \{\mathbf{x}(1), \mathbf{x}(2), \dots, \mathbf{x}(t)\} \quad (4.8)$$

其中每个观测点包含多个系统特征数据

$$\mathbf{x}(t) = F(t) = [f_1(t), f_2(t), \dots, f_n(t)] \quad (4.9)$$

输出层 输出层神经元对应着列车运行状态向量各维度，为 4 个神经元，以实现运行状态预测分类的目标。

$$\mathbf{Y} = \{y_i | y_i = c1, c2, c3, c4\} \quad (4.10)$$

输出层神经元采用 *softmax* 函数作为输出，该函数常用于实现多分类任务。

$$y = \text{softmax}(W_s h_2 + b) \quad (4.11)$$

其中， W_s 代表输出层权重矩阵， b 代表输出层偏置值， h_2 代表最后一层 LSTM 网络隐藏层的输出。*softmax* 将所有神经元的输出都压缩在 $(0, 1)$ 之间，并保证它们相加之和为 1。因此，每个神经元的输出就是它们被划分为该类的概率值：

$$p_j = \frac{e^{z_j}}{\sum_{k=1}^4 e^{z_k}} \quad (4.12)$$

其中 $z_k \in \mathbf{z}$ ， \mathbf{z} 是该层的输入向量。

该值是指在当前系统运行条件下，列车状态会被判定为哪一类的概率值。根据 *softmax* 设置的分类阈值，模型给出列车状态分类结果。

隐藏层 隐藏层采用两层 LSTM 循环神经网络结构。LSTM 网络按照序列顺序接收风险特征样本集作为网络的序列化输入，实现挖掘系统运行参数 \mathbf{F} 与列车运行状态 y 之间深层联系的目的，从而可以将稳定的模型应用于未知风险分类的 T2T-CBTC 系统预测特征样本集中。因其特有的循环结构，每个 LSTM 网络单元的总输入是由当前时间步的系统风险特征向量 $x(t)$ 和神经元上一个时间步的输出 $h(t-1)$ 共同构成的。在本文的两层 LSTM 网络模型中，第一层 LSTM 的

输入由输入层确定，为 $x^1(t) = [f_1(t) \dots f_n(t)]$ ；第一层 LSTM 的输出作为第二层 LSTM 的输入，即 $x^2(t) = h^1(t)$ ；输出层的输入由第二层 LSTM 的输出确定，即 $o(t) = h^2(t)$ 。权重和偏置的不断更新使得风险预测模型最终达到稳定，同时模型对于系统特征向量中的风险信息进行了有效地掌握。

误差函数 误差函数（Error function）是神经网络模型学习过程中用于更新权重和偏置的目标函数，是对输入和输出之间关系能力进行错误程度估计的一种度量。模型训练的最终目标就是要最小化误差函数，从而促进模型收敛，达到稳定。

本文使用的误差函数为交叉熵误差函数（Cross-entropy error function）^[48]：

$$Loss_0 = - \sum_j (p_j \log q_j) \quad (4.13)$$

其中， j 指 j 个分类， p_j 是预测结果概率，服从预测列车状态分布 $\hat{\mathbf{Y}}$ ， \hat{q}_j 为原始结果概率，服从原始列车状态分布 \mathbf{Y} 。信息论中，交叉熵常用于度量两个概率分布函数之间的距离。作为误差函数，它用于表示模型认为的输出分布和原始输入分布之间的距离，常用于 *softmax* 分类器的误差函数。本文的模型训练目标是使得原始的列车运行状态分布 \mathbf{Y} 和模型从风险特征数据集中学习的状态分布 $\hat{\mathbf{Y}}$ 之间的距离最小，即

$$J = \min(Loss_0) \quad (4.14)$$

训练算法 本文使用的训练算法为 Adam 算法。传统随机梯度下降算法的学习率是预先设定且不变的^[49]。过小的学习率使得模型训练初期的参数更新较慢，训练周期和时间过长；而过大的学习率会导致模型训练不充分。Adam 训练算法的提出改进了这一问题。Adam 算法根据一阶矩估计和二阶矩估计动态地调整梯度值，从而使得学习率自适应地动态更新^[50]。

4.2.2 预测流程

基于 LSTM-RNN 的 T2T-CBTC 系统安全风险的预测流程为：

(1) 建立预测特征，进行数据预处理。根据第四章所提出的安全风险预测特征选择方法构建预测特征集，并进行数据标准化预处理。

(2) 设计训练样本数据集。将样本数据集随机划分为 3 部分，其中 70% 为训练样本，用于调整网络结构参数，使模型效果最优；15% 为验证样本，用来验证

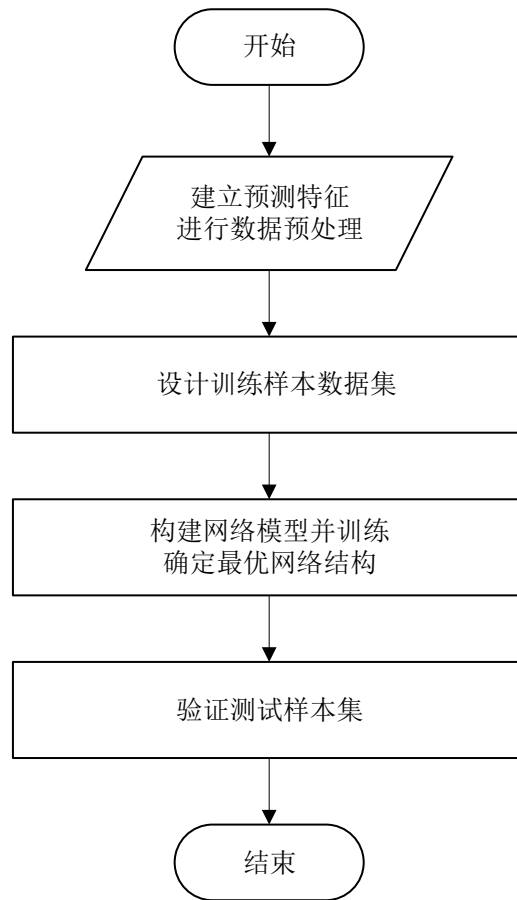


图 4.4 基于 LSTM 循环神经网络的安全风险预测流程图

网络泛化能力，并且在该能力不再提高时终止网络训练；15% 作为测试样本以检测模型对于未知分类样本集的判断性能。

(3) 构建预测模型并训练，确定最优网络结构。本文的模型采用 4 层神经网络结构，一层输入层，一层输出层，两层 LSTM 网络隐含层。本文采用随时间反向传播（Backpropagation through time, BPTT）算法对模型进行多次训练，以调整网络的超参数和确定最优网络结构。本文预先设定初始训练次数（Epoch），采用提前终止（early stopping）策略来判断是否需要停止训练。该策略通过比较误差是否到达规定的精度来决定是否继续进行迭代训练，防止训练模型的过拟合。验证数据集用来验证模型的泛化能力。

(4) 验证测试样本集。将测试样本集输入训练好的安全风险预测模型进行预测分类，得到分类结果，并评价模型的预测性能。

4.3 基于 L2 正则化的预测模型优化

本节以4.2.1节所提出的模型为基础，针对本文研究问题中数据集样本不均衡问题，使用正则化技术进行模型优化改良。首先分析了预测样本中所存在的不平衡问题，进而提出了采用 L2 正则化方法优化模型的训练误差函数的方法，达到克服该问题，提高预测效率的目的。

4.3.1 系统安全风险预测中样本不平衡问题

鉴于多数情况下列车处于正常运行状态而发生严重碰撞情况是极少的。因此，本文所探讨的 T2T-CBTC 系统的列车安全风险预测问题所涉及的数据集具有样本不平衡特征，每个类别的样本数在总样本中的分布不均等。该类数据集极易形式模型训练中的“过拟合”，降低泛化能力，从而无法充分学习到少数样本类别的数据特征^[51]。该问题的解决方法主要分为两类，第一类从数据集角度出发，通过采样对样本集进行补充优化，主要有随机采样，合成少数类重采样；第二类从算法方面进行提升，对误差函数增加一个“惩罚”项以提高模型对少数样本的关注。

4.3.2 针对不均衡样本的 L2 正则化优化

本文使用 L2 正则化来解决模型在不均衡样本中的问题。正则化（Regularization）技术属于第二类解决方法，是机器学习中常用的训练优化技术。它的加入使得模型的训练目标由误差函数最小化变成了结构风险最小化，而结构风险由误差函数和模型的复杂度组成，模型复杂度相当于“惩罚项”。即：

$$C(w; X, y) = C_0(w; X, y) + \lambda \Omega(w) \quad (4.15)$$

其中， X, y 为训练样本和类别， w 为权重系数向量， $C(\cdot)$ 为误差函数， $\Omega(w)$ 是惩罚项， λ 参数控制正则化的强弱。

L2 正则化属于正则化中的一种，也称为权重衰减，其“惩罚项”为：

$$\Omega_2(w) = \sum_i w_i^2 \quad (4.16)$$

是所有权重特征值的平方和。如果某个权重的值越高，其贡献度也就越高。

因此，应用 L2 正则化技术优化的风险预测模型的误差函数更新为：

$$\begin{aligned} Loss &= Loss_0 + \lambda \Omega_2(w) \\ &= Loss_0 + \lambda \sum_i w_i^2 \end{aligned} \quad (4.17)$$

使用 BPTT 算法对预测模型进行训练时，每个神经元权重更新的梯度值为：

$$\nabla w = \frac{\partial Loss}{\partial w} = \frac{\partial Loss_0}{\partial w} + \lambda w \quad (4.18)$$

因此权重更新方式为：

$$\begin{aligned} w' &= w - \eta \frac{\partial Loss_0}{\partial w} - \eta \lambda w \\ &= (1 - \eta \lambda) w - \eta \frac{\partial Loss_0}{\partial w} \end{aligned} \quad (4.19)$$

其中 η 为学习率。

通过控制参数 λ 的大小以实现调节权重更新的大小。当 λ 值设置为较小时会使权重更新较大，促使模型对少数样本类进行更侧重地学习，从而克服了分类不准确的问题。

4.4 T2T-CBTC 系统安全风险预测模型训练过程

本节将详细介绍基于 LSTM-RNN 的风险预测模型的训练过程。图 4.5 为基于 LSTM-RNN 的 T2T-CBTC 系统安全风险预测模型的训练过程。

(1) 输入训练样本。已预处理好的训练样本集作为模型训练的输入，同时设置模型训练迭代次数（Epoch），每批次训练的样本数（Batch size）和最小误差阈值。训练数据集为 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_l\}$ ，对应的输出为 $\mathbf{Y} = \{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_l\}$ 。

(2) 初始化神经网络模型的权重和偏置。模型的权重初始化使用 Glorot 均匀分布初始化算法，即 Xavier 均匀初始化。该随机初始化算法使得 DNN 中的输入输出都服从标准高斯分布，不会趋于 0。偏置一般初始化为 0。

(3) 前向传播：按时间步展开 LSTM 网络，计算隐藏层，输出层的神经元输出。对于每一个 LSTM 单元的输入 \mathbf{x}_i ，都包含有 t 个时间观测点，因此需要按照图 4.3（b）所示将一个 LSTM 单元展开成 t 个如此连接的 LSTM 单元。经过 LSTM 单元计算的输出为

$$\mathbf{s}_i = f_{LSTM}(\mathbf{x}_i, \mathbf{h}_{i-1}) \quad (4.20)$$

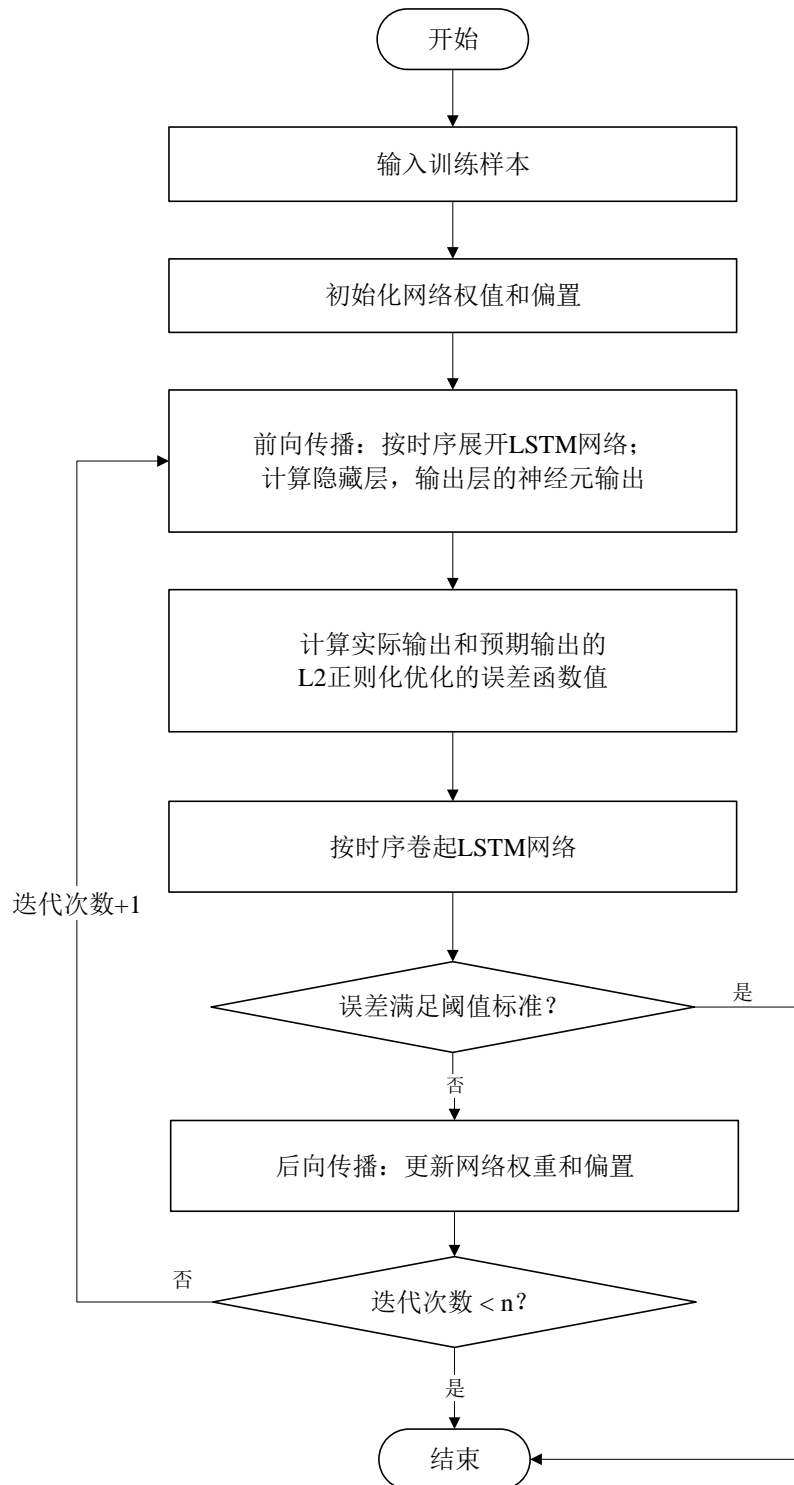


图 4.5 基于 LSTM 循环神经网络 +L2 正则化的风险预测模型训练过程

其中, $f_{LSTM}(\cdot)$ 为该神经元定义的计算输出函数。两层隐藏层之间相连, 上层输出为下层输入。同时, $softmax$ 输出层的输出如式 (4.11) 所示。

(4) 计算实际输出与预期输出的 L2 正则化优化的误差函数。按照式 (4.17) 计算误差值。

(5) 卷起 LSTM 网络。

(6) 误差反向传播: 更新权重和偏置。通过计算实际输出与理论输出之间误差值, 从输出层向输入层方向, 按照式 (4.19) 反向更新模型的权重值和偏置值。模型通过参数更新学习训练数据集中的数据特征, 促使计算误差不断下降。

(7) 当达到训练次数或误差满足精度时停止训练。

4.5 本章小结

本章提出了基于 LSTM-RNN 的 T2T-CBTC 系统安全风险预测模型, 及面向样本集不平衡问题的模型优化方法。本章首先介绍了 LSTM 循环神经网络的相关理论基础。预测模型以第四章所建立的预测特征集而形成的样本数据集为输入, 以 LSTM-RNN 作为隐藏层, 以 $softmax$ 层作为输出层, 详细设计了预测模型的每一层结构及含义。同时本章构建了基于该模型的系统安全风险预测流程。面对数据集中样本类别的不平衡问题, 本章提出了选择 L2 正则化进行误差函数优化, 达到了克服数据集不平衡, 提高预测性能的目的。最后本章给出了完整的预测模型训练过程。

第五章 实验设计与结果分析

本章将使用合作方样本数据集对上述理论方法进行实验验证。首先，本章给出了实验实施环境，对模型的评价指标和实验数据集。在风险预测特征集的建立过程中，探讨了小概率特征生成实验结果和基于 PCA 的特征降维结果。然后，探讨了 L2 正则化参数的选取过程和模型整体参数选择。最后，本章研究了测试样本数据集在本文模型中的多次实验的各项评价指标结果，及该模型与其他常见模型方法之间的性能比较。

5.1 实验环境

本文的实验环境设计如下：

- (1) 操作系统：Windows 10（64 位）操作系统
- (2) 硬件环境：处理器 Intel Core(TM) i5-6200U CPU @ 2.30GHz；内存 8GB；显卡 Intel(R) HD Graphics 520 (1024 MB)
- (3) 开发环境：集成 python 开发环境 Anaconda3；PyCharm python 开发工具；
- (4) 开发语言：Python
- (5) 开发框架：Keras，Tensorflow

5.2 模型评价指标

机器学习中通常采用准确率（Accuracy），查准率（Precision），查全率（Recall）和 F1 分数（F1-score）来对模型的性能进行评价，其各有不同的评价侧重点。本文侧重于考查模型的查全率和 F1 分数。

准确率（Accuracy）

$$Accuracy = \frac{1}{n} \sum_{k=1}^m \mathbb{I}(f(\mathbf{x}_k) = y_k) \quad (5.1)$$

其中 \mathbb{I} 是指示函数， y_k 实际类别， $f(\mathbf{x}_k)$ 是预测类别。它是机器学习算法中最基础，最简便的评价指标。识别正确的数量占总体数的比值是准确率关注的重点，

但其也有着不小的缺点，即准确率在不均衡数据集上无法充分反映算法模型的能力。考虑更多指标来探究模型算法的性能十分必要。

查准率 (Precision)，查全率 (Recall)

$$Precision = \frac{TP}{TP + FP} \quad (5.2)$$

$$Recall = \frac{TP}{TP + FN} \quad (5.3)$$

其中 TP 指真正例 (true positive)，即被预测为正类别，实际上也是正类别；FP 指假正例 (False positive)，即被预测为正类别，实际上是负类别；TN 指真反例 (true negative)，即被预测为负类别，实际上也是负类别；FN 指假反例 (false negative)，即被预测为负类别，实际上是正类别。

在实际评价模型中，查准率矛盾于查全率，它们分别侧重评价分类任务模型的不同角度。一般查全率高时，查准率就低，反之亦然。查准率注重在预测结果中真正正确的样本率，而查全率则更关注所有正类别被预测出来了多少，即使有负类别被预测为正类别也无所谓，但不允许有漏网之鱼。

F1 分数 (F1-score)

$$F1 = \frac{2 \times TP}{\text{样本总数} + TP - TN} \quad (5.4)$$

F1 分数能够综合考虑查准率和查全率这两类指标的结果，是它们的加权调和平均值，可以为模型选择做出指导。当 F1 分数值较高时说明该模型较为理想。

5.3 实验数据集

本文实验数据集来自于合作方的 T2T-CBTC 系统模拟运行参数和列车状态数据集，共有 15000 个序列样本，随机分配为 3 个部分，训练数据集含有 12825 个样本，验证数据集含 1425 个样本，测试数据集含有 750 个样本。每个序列含有 100 个时间步。图 5.1 是本文所使用样本数据集的样本类别分布情况，其中有 9057 个无碰撞样本，3749 个紧急停车样本，1534 个轻微碰撞样本，712 个严重碰撞样本。列车运行风险状态样本在数据集中是少数的，其中 60% 属于无碰撞类别的样本，而严重碰撞类别的样本只占了 5%。




图 5.1 不平衡数据集总体样本类别分布

表 5.1 风险类型，标签及输出示例

标签	类型	输出示例
1	无碰撞（c1）	0 0 0 1
2	紧急停车（c2）	0 0 1 0
3	轻微碰撞（c3）	0 1 0 0
4	严重碰撞（c4）	1 0 0 0

对于本文中的任务类型和数据集来说，单纯考查模型分类准确率是不合适的。图 5.1 显示，样本集中 c1 类所占比例最大，促使模型多次学习该类别样本特征而提高对其的识别率，甚至可达 100%。存在一种模型整体准确率很高的情况，即模型对 c1，c2 类别的高分类准确率掩盖了其在 c3 和 c4 类别上的低分类能力。该情况下的模型不符合本文要求。主要原因是它偏离了本文的研究初衷，即尽可能准确而全面地判断出碰撞风险状态的发生。即使错判了正常运行状态样本，也可通过后续人工程序鉴别；但遗漏一个，则可能提高严重灾难发生的可能性。因此，在后续实验中，本文更多地考虑 c3 和 c4 类别的样本是否会被准确而全面地识别出来，需要充分地探讨每一类的识别情况，这也是不平衡列车运行状态数据集所要求的。从而，本文侧重于关注模型的查全率和 F1 分数。

本文的风险状态类型、对应标签及相应的网络层的输出示例如图 5.1 所示。

表 5.2 输入数据集举例

序号	车车通 信延 迟/s	车地通 信延 迟/s	最大 列 数/列	轨道方向	已运行 时长/h	人流量/h	平均工 作 年限/y	...	移动授权失效 概率	移动授 权计算 时间/s	制动曲 线计算 时间/s
$\mathbf{x}_1(1)$	0.805	0.875	19.567	1	3.698	37590	8.25	...	6.39×10^{-8}	0.274	0.769
$\mathbf{x}_1(2)$	0.649	1.334	17.647	1	6.102	30460	2.919	...	4.47×10^{-8}	0.719	0.239
...
$\mathbf{x}_1(t)$	0.500	1.176	35.884	0	3.501	35347	1.987	...	5.14×10^{-8}	0.876	0.654
$\mathbf{x}_2(1)$	0.702	1.458	27.423	0	6.317	32419	3.505	...	4.58×10^{-8}	0.447	0.542
$\mathbf{x}_2(2)$	0.568	0.892	35.748	0	4.073	30704	3.489	...	6.78×10^{-8}	0.310	0.156
...
$\mathbf{x}_2(t)$	0.844	0.987	36.712	1	2.942	33664	9.521	...	8.75×10^{-8}	0.826	0.846
$\mathbf{x}_3(1)$	0.687	1.061	20.723	0	7.489	31999	13.289	...	9.78×10^{-8}	0.739	0.645
$\mathbf{x}_3(2)$	0.697	0.774	28.22	0	4.719	32133	8.536	...	5.32×10^{-8}	0.163	0.1666
...
$\mathbf{x}_3(t)$	0.729	0.738	15.743	1	2.885	37410	19.554	...	5.74×10^{-8}	0.708	0.257

模型的输入数据集示例如表 5.2 所示。

5.4 风险预测特征集构建

5.4.1 小概率特征生成算法

实验目标 为了说明 3.3 节中的算法在系统小概率特征求解方面的有效性和可行性，本小节将基于算法 3.1，使用 BLTL 语言描述系统安全属性，计算移动授权功能中的失效概率。

实验过程 使用基于统计模型检验的小概率特征值的生成过程如下：

(1) 建立系统功能模型 M 。

本文基于 MATLAB 构建移动授权功能模型。给定模块的输入为，搜索起点 (sPosSrc)，搜索方向 (iDirSrh)，搜索距 (iDistance)。模型的输出为计算错误标志 OUTbError，如果出现计算错误，则 OUTbError=true，否则为 false。具体的系统模型如图 5.2 至图 5.8 所示。

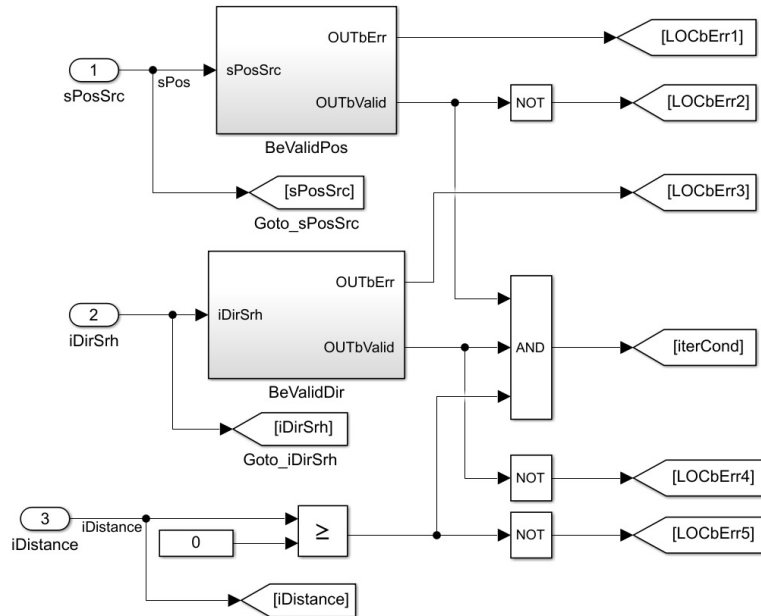


图 5.2 输入参数合法性检查模块

(2) 定义安全约束，并使用时态逻辑语言 BLTL 描述。

针对 2.4 节中分析和讨论的 T2T-CBTC 系统移动授权功能计算应用场景，采用 BLTL 语法进行相关小概率安全属性的描述。本文考虑的系统安全属性为：

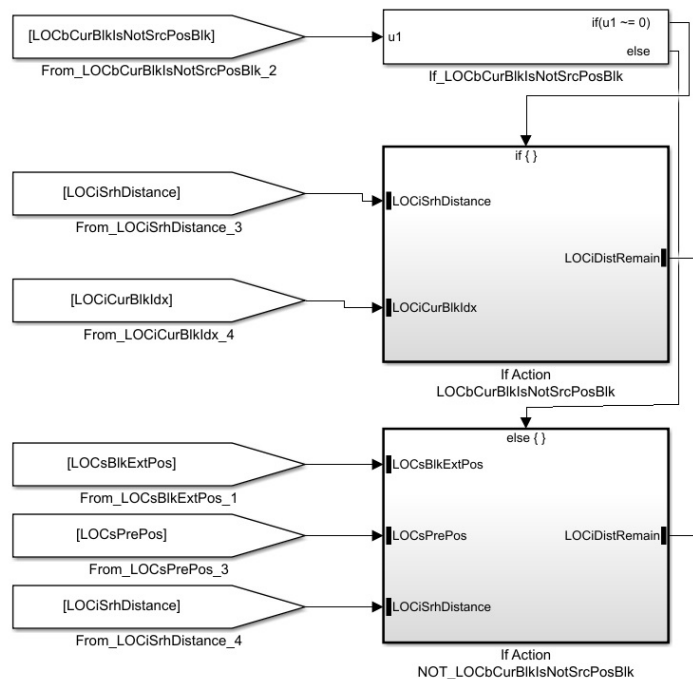


图 5.3 判断当前区块是否为搜索区块

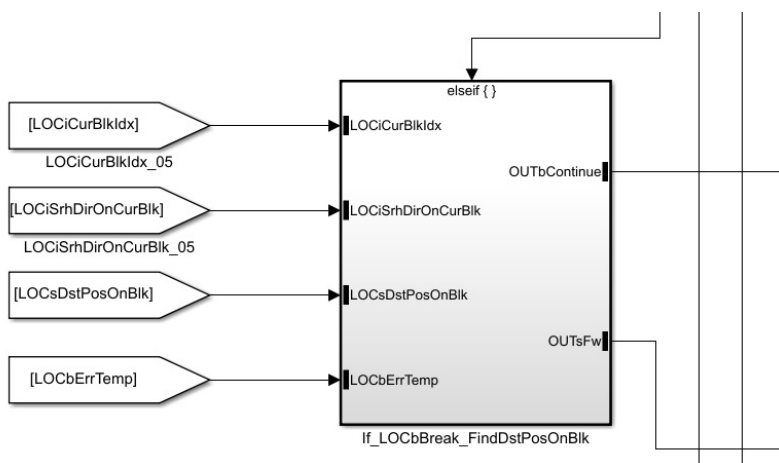


图 5.4 判断当前区块长度是否大于搜索距离




图 5.5 获取下一个搜索区块的信息

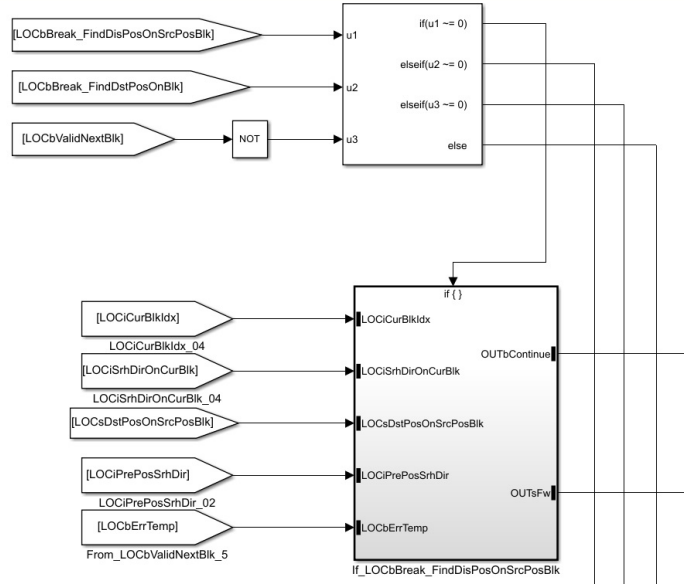


图 5.6 判断已搜索距离是否等于输入搜索距离

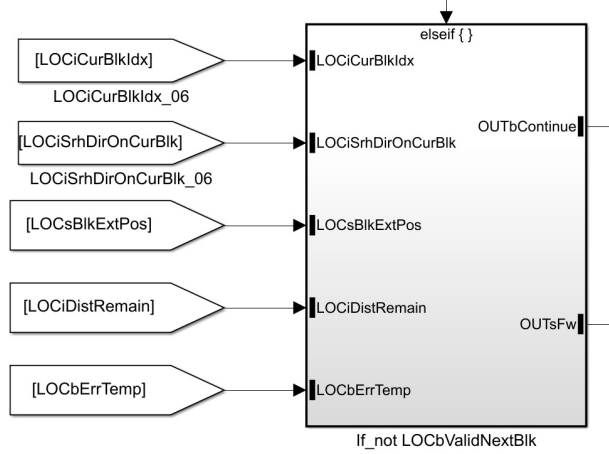


图 5.7 判断下一个搜索区块是否合法

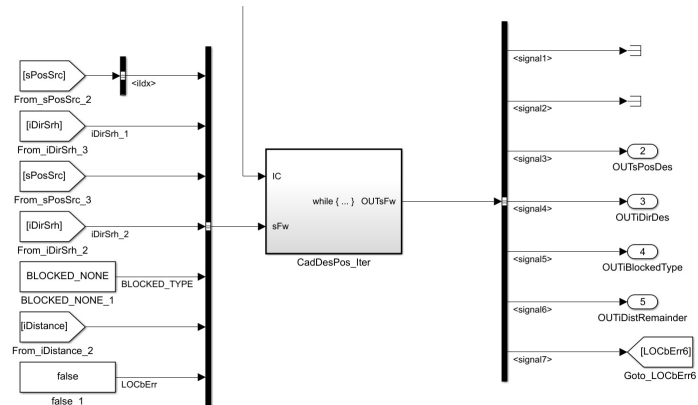


图 5.8 轨道线路迭代搜索模块

- 移动授权功能计算模块不会出现 OUTbError

该约束用 BLTL 语法表示为：

$$\phi = F^{100}G^1(OUTbError = false) \quad (5.5)$$

即，在之后的 100 个时间步中，系统不会出现 OUTbError=true 的状态。因此，模型检验需要验证的问题就是，系统发生 OUTbError=true 的概率为多少，即：

$$P(\neg F^{100}G^1(OUTbError = false)) = ? \quad (5.6)$$

(3) 将 M 和 ϕ 作为算法 3.1 的输入，进行统计模型验证，获得满足概率。

本文的实验设定如下：通过在系统中引入传感器随机故障，可以得到系统移动授权功能失效的概率。为了便于计算，假设系统中存在 3 个传感器发生随机故障，根据算法 3.1，系统的故障率即为所求的概率密度函数的参数。首先初始化一个倾斜参数 w ，取值范围是 0.1-0.01。该参数的意义在于通过加大故障率来产生更多的故障样本，从而能更快地找到最优参数。

实验结果及分析 实验验证结果如表 5.3 所示。本文共进行了 3 次实验，每次实验

表 5.3 小概率预测特征计算结果

样本数量	估计概率	相对误差 (RE)
$N_{CE} = 100$ $N_{IS} = 1000$	6.39×10^{-8}	0.47
$N_{CE} = 1000$ $N_{IS} = 10000$	4.83×10^{-8}	0.25
$N_{CE} = 10000$ $N_{IS} = 100000$	4.35×10^{-8}	0.16

的样本次数为上一次的 10 倍。从表 5.3 可以看出，在 1000 次的系统模拟后，估计的失效概率值已经达到了 10^{-8} 级别。如若根据历史数据进行估算，很难达到目的。

5.4.2 基于 PCA 的预测特征集降维

实验目标 为了说明 3.4 小节中主成分分析方法在风险预测特征降维中的有效性和可应用性，将基于 3.4 小节中的降维模型实现特征集降维。

实验方法 基于3.4小节中所提出的降维模型和步骤。




图 5.9 各特征项在 PCA 分析中对原始信息表达的贡献率

实验结果及分析 图 5.9 表示每一种处理后的新特征在原始信息表达中的贡献率。可以看出，前 15 个特征的信息贡献率达到了 95% 以上。因此，使用这前 15 个特征即可充分表现原始特征数据中的全部信息，同时，这 15 个特征向量之间相互正交，满足了3.4节定义的两个约束。降维后的特征数也确定了本文预测模型输入层的神经元数。

5.5 基于 LSTM-RNN 的安全风险预测模型训练

本节主要探讨了预测模型训练过程中的相关参数选择，并展示了训练结果。参数选择包括 L2 正则化参数选取结果及模型其他超参数的选择。

5.5.1 预测模型 L2 正则化参数 λ 选取

本小节展示了4.3节中 L2 正则化参数的选取结果。L2 正则化的 λ 参数是正则化处理过程中一个较为关键的数值。探讨模型在不同 λ 参数下的性能变化有助于寻找到最优解。

本文通过多次实验确定了 L2 正则化参数的最优取值为 0.001。

本文分别选择了 $\lambda = [0.02, 0.015, 0.01, 0.003, 0.001, 0.0008]$ 进行实验，

着重关注轻度碰撞（c3）和严重碰撞（c4）类别下的三种评价指标的变化结果。实验结果如图 5.10，5.11，5.12 所示。




图 5.10 不同 L2 正则化参数取值下 c3，c4 类别的查准率

在图 5.10 中，c3 类别的查准率在不同的 λ 值下的变化并不大，但是 c4 类别的查准率却随着参数的减小而增大。这是因为存在其他类别的样本被预测为 c4 类别，从而导致查准率计算中的分母变大，使得查准率变小。

在图 5.11 中，可以明显观察到的是两种类别下的查全率随着 λ 的变化有了显著提升。尤其对于 c4 类别，比较 $\lambda = 0.01$ 和 $\lambda = 0.001$ 的情况，正则化参数的指数级别下降导致了查全率有了 0.31 的提升，并在该点达到最高。

图 5.12 是 F1 分数的变化情况。可以看出，c3 和 c4 类别下的 F1 分数随着正则化参数的减小都有所提高，同时 c4 类别下的 F1 分数在 0.001 取值时达到了最高。这说明了适当的 L2 正则化项对于识别少数类别样本，处理不平衡数据集是




图 5.11 不同 L2 正则化参数取值下 c3，c4 类别的查全率




图 5.12 不同 L2 正则化参数取值下 c3, c4 类别的 F1 分数

非常有效的；也说明了，正则化参数的选择影响着模型的分类性能。

基于以上实验结果，本文选择的 L2 正则化参数的为 0.001。

5.5.2 模型参数选择

表 5.4 LSTM-RNN 风险预测模型训练超参数选择结果

参数	取值
输入层单元数	15
输出层单元数	4
隐藏层单元数	256
Epoch	100
Dropout	0.2
Batch	10
正则化参数	0.001

在实验中，本文预测模型的超参数如表 5.4 所示。输入层单元数与特征维度数相对应，取值为 15，这是特征降维处理后的结果。输出层单元数对应列车运行状态分类维度，取值为 4。LSTM 隐藏层单元数的选取参考了相关故障诊断模型，对于该类问题，选择 256 单元数最为合适。本文的训练过程采用分批次（Batch）多次迭代训练。Batch 是指每次训练所使用的样本数，以少量多次形式进行训练有助于提高模型的泛化能力。Epoch 是训练次数总数，取值为 100 次。本文使用提早结束（Early Stopping）策略来避免模型过拟合的训练状态，一旦训练误差达到可接受的误差范围就停止训练。同时，在两层 LSTM 隐藏层之间使用 Dropout

技术。Srivastava 和 Hinton 等人在 2013 年提出的 Dropout 技术能够使一些神经元在训练迭代中失效，避免了过拟合的发生^[52]。

5.5.3 模型训练结果

图 5.13 展示了模型在训练过程中准确率和误差值的变化过程。模型经过 16 次训练后达到了误差最小化状态。训练过程的准确率和误差值的变化先快后慢是由于在训练初期模型学习率较大，而后学习率变慢，导致权重和偏执更新程度的变化。

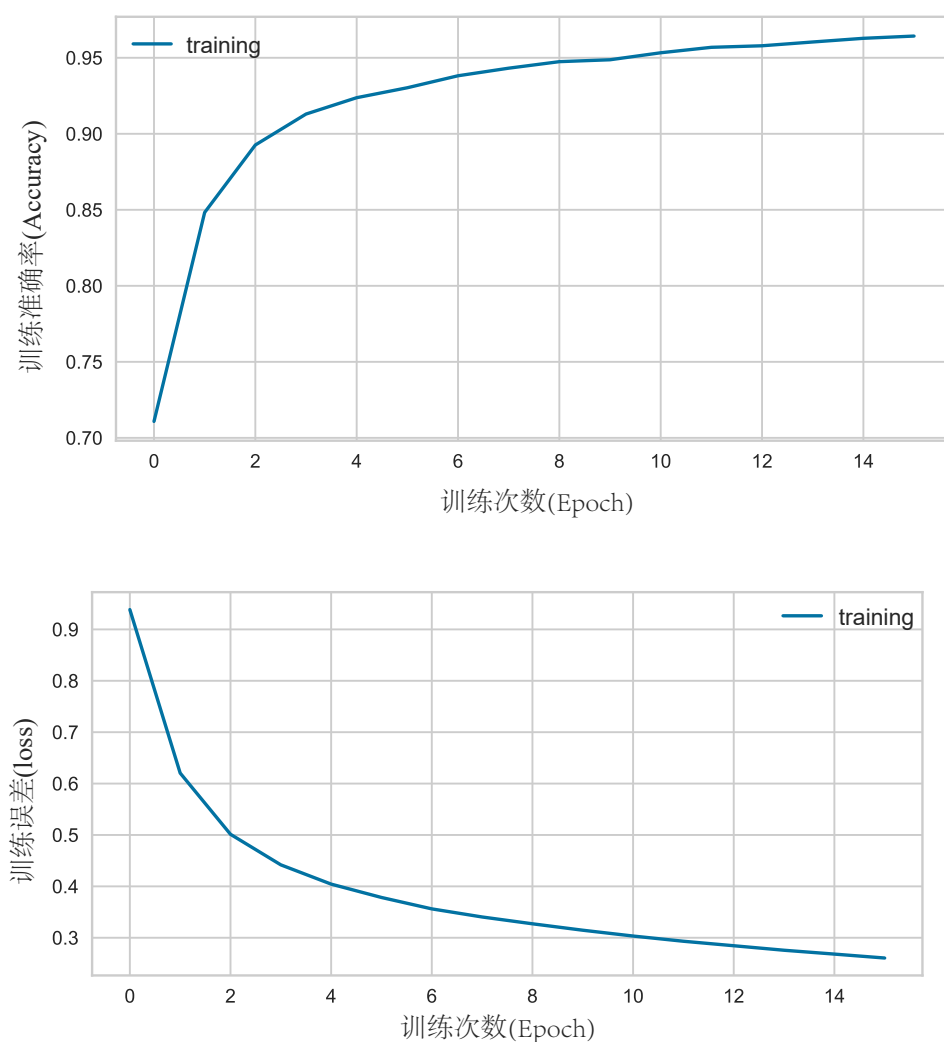


图 5.13 训练过程中模型预测准确率和误差值变化图

5.6 基于 LSTM-RNN 的安全风险预测模型实验

本节首先采用多个测试样本集进行实验验证分析，然后探讨了常见神经网络模型在测试样本上的表现。

5.6.1 预测模型实验结果

表 5.5 单次实验下混淆矩阵结果

真实分类 \ 预测分类	c1	c2	c3	c4
c1 (无碰撞)	425	4	1	7
c2 (紧急停车)	4	181	0	2
c3 (轻微碰撞)	1	10	75	5
c4 (严重碰撞)	2	2	2	29




图 5.14 单次试验下不同样本类别的各评价指标结果

实验目标 验证本文提出的基于 LSTM-RNN 的预测模型在下一代 CBTC 系统安全风险状态预测中的有效性。

表 5.6 多次实验下各评价指标结果

评价指标 组数	准确率	查准率	查全率	F1 分数
1	95.2%	88.2%	89.8%	89.3%
2	94.8%	88.6%	90.1%	88.2%
3	93.5%	88.9%	89.7%	88.5%
4	94.3%	87.7%	90.2%	89.2%
5	94.6%	89.3%	89.6%	88.9%
平均值	94.6%	88.4%	89.8%	88.8%

实验方法 本文进行了 5 次实验，每次实验的测试数据集大小相同，同时满足上述的数据集类别分布。为叙述简便，本文使用 c1, c2, c3, c4 分别代替无碰撞，紧急停车，轻微碰撞和严重碰撞这四种状态。测试样本数据集中 c1, c2, c3 和 c4 的真实样本数分别为 437, 187, 91, 35。

实验结果及分析 本文分别给出了单次实验下的混淆矩阵结果（表 5.5）和不同样本类别下各评价指标结果（图 5.14）。多次实验各评价指标的结果展示在表 5.6 中。

表 5.5 展示了单次实验下模型的混淆矩阵结果。混淆矩阵是通过矩阵形式来展示算法结果的一种形式，主要适用于监督学习^[53]。矩阵的横行代表了样本真实类别数目，竖列代表了预测为该类别的数目。对角线则代表着每一类的 TP 值，即有多少正类别被真正地预测出来。如表 5.5 所示，c1 类别中共有 425 例被预测正确，c2 类别有 181 例被预测正确，c3 和 c4 分别有 75 和 29 例被预测正确。对于 c4 类别而言，在 35 例中 83% 被正确预测出来，但是还是存在一些不足，其中有 2 例被预测为无碰撞。

图 5.14 展示了每种样本类别下的各性能指标的结果。由图中可知，模型在对 c1 和 c2 类别进行预测时的指标结果优秀，对 c3, c4 这种少数类别也同样具有令人满意的结果。c4 类别下的 F1 分数为 0.81，查全率为 0.83。这说明本文的模型在经过多次训练学习后在不平衡数据集上呈现了优秀的结果，多个运行之间的不同被有效地区分开。

表 5.6 给出了 5 次实验下模型总体的各评价指标结果。就准确率来看，本文模型的性能是较为优秀且结果稳定的，平均准确率达到 94.6%。预测模型在测试集上的泛化能力较好，充分学习了每种列车运行状态的数据特征。查准率，查全

率和 F1 分数结果分别达到 88.4%，89.8%，88.8%，较为平稳，没有出现异常点。这表明基于 LSTM-RNN 的预测模型所判定的列车运行状态是可靠的。

5.6.2 不同预测模型性能对比

表 5.7 模型比较实验评价指标结果

评价指标 模型	准确率	查准率	查全率	F1 分数
本文模型	94.6% ± 0.4%	88.4 % ± 0.3%	89.8% ± 0.3%	88.8% ± 0.4%
DBN	90.2% ± 1.3%	89.1% ± 0.8%	82.1% ± 0.9%	83.7% ± 1.1%
DCNN	90.3% ± 0.9%	88% ± 1%	83.5% ± 1.2%	84% ± 1.2%
MLP	85.3% ± 1.2%	82.1% ± 0.9%	67.5% ± 1.5%	72.2% ± 1.6%
贝叶斯网络	76.2% ± 1.5%	74.2% ± 1.1%	60.7% ± 1.2%	65.2% ± 1.4%

实验目标 与其他网络模型比较以体现本文模型的有效性和优越性。

实验方法 本文主要使用了以下几种广泛使用的模型作为比较对象：

- 深度信念网络 (Deep belief network, DBN)^[54]
- 深度卷积神经网络 (Deep convolutional neural network, DCNN)^[55]
- 多层感知器 (Multi-layer perceptron neural network, MLP)^[56]
- 贝叶斯网络 (Bayesian network model)^[57]

该实验中所用实验数据集如 5.3 小节所示，上述模型采用相应的训练算法进行训练。本文分别从准确性，查准率，查全率和 F1 分数指标方面进行了方法比较。

实验结果及分析 各类别评价指标结果如表 5.7 所示。从表中可以得到以下观察结果：

(1) 从总体来看，在表 5.7 的结果中，本文的智能预测模型在准确率，查全率和 F1 分数方面都优于其他所有的方法，数值波动范围较小。即使在查准率结果不是最优，但偏差变化范围低于最优值所在的模型。

(2) DBN 的查准率是所有模型中最好的，但是 DBN 在查全率指标上与本文模型之间的差距并不小，相差了 7.7%，准确率也低于本文模型。这说明 DBN 在

分类预测中漏掉了一些严重风险状态样本，使得查全率较低，其在不平衡数据集上的表现并不是太理想。

(3) 比较模型之间的性能排名为： $\text{DBN} \approx \text{DCNN} > \text{MLP} > \text{贝叶斯网络}$ 。神经网络模型明显优于静态分析方法，如贝叶斯网络。主要是因为这些方法没有考虑列车在系统运行过程中产生的不确定性。

综上所述，本文所提出的智能预测模型考虑了多种影响因素，并采用深度学习的方法，在 T2T-CBTC 系统风险预测中是有效且优于其他方法的。

5.7 本章小结

本章使用 Keras 框架实现了基于 LSTM-RNN 的安全风险预测模型，并对本文研究的理论方法进行了相关实验。首先，本章介绍了实验环境设置，模型的评价指标和实验数据集。然后，本章给出了风险预测特征集的构建结果，包括小概率特征求解结果和基于 PCA 的特征降维结果。之后，探讨了模型训练中超参数的设置，比较了不同 L2 正则化参数对于模型预测性能的影响。最后，本章展示了预测模型在测试集上的实验表现，及该模型与其他几种常见方法模型的对比实验。实验表明，本文提出的基于 LSTM-RNN 的安全风险预测模型在 T2T-CBTC 系统的风险预测问题上有很好的适应性，同时在该类问题上的性能整体优于其他方法。

第六章 总结与展望

6.1 总结

本文研究了面向下一代车车通信 CBTC 系统的智能安全风险预测方法。其中，本文构建了基于车车通信模式的下一代 CBTC 系统方案，即 T2T-CBTC 系统，设计了针对列控系统的安全风险特征选择方法，构建了面向 T2T-CBTC 系统的基于 LSTM-RNN 的安全风险预测模型。

本文的工作主要有以下几点：

(1) 设计了基于车车通信模式的下一代 CBTC 系统方案，并定义为 T2T-CBTC 系统。该方案通过增加车车通信模式，以重新分配系统关键功能，实现了系统优化。为了解决移动闭塞技术对轨旁系统依赖较高的问题，将部分轨旁系统复杂功能转移到车载设备上以减少轨旁设备，降低维护成本和系统不可靠性。本文还优化了下一代 CBTC 系统中移动闭塞技术，从而有效降低系统运行风险。

(2) 构建了列车控制系统安全风险预测特征选择方法。在定义了 T2T-CBTC 系统的安全风险和相应列车运行状态之后，本文首先参考 CBTC 系统设计标准 IEEE1474.1^[1] 且结合下一代 CBTC 系统方案，进行了特征初步选择；然后提出了针对小概率特征值的求解算法，最后在此基础上采用了 PCA 方法进行特征降维以优化特征集的信息表达。该方法为列控领域建立风险分析特征提供了一套有效方法。

(3) 提出了基于统计模型检验的小概率特征值生成算法。针对 CBTC 系统这一特定研究领域，存在着小概率数值的特征值无法以一般的方法去获取的问题。本文提出了基于统计模型检验的小概率特征值生成算法。通过对系统功能进行建模，采用 BLTL 语言描述系统中的小概率失效事件，本文使用该算法求解了小概率特征值，有效地解决了 CBTC 系统中小概率特征生成的问题。

(4) 提出了面向下一代车车通信 CBTC 系统的智能安全风险预测模型。该模型基于 LSTM-RNN 实现，根据系统的风险特征集对列车运行状态做出预测分类和识别。其中，针对列车运行状态这一不平衡数据集，以 L2 正则化方法改进了训练误差函数表达式，使得预测准确值得到优化，也避开了训练中产生较差拟合度的可能。最终解决了无法处理系统动态运行中不确定性和难以捕获风险状态

关联的问题，也达到了对列车运行状态做出预测分类并进行风险判定的目标。

6.2 展望

本文的研究工作初步完成了面向 T2T-CBTC 系统的安全风险预测的目标，然而在研究中仍然存在可以改进的地方，主要有以下几个方面：

(1) 本文研究了以列车碰撞作为风险事件的运行状态预测分类，接下来的研究侧重于系统中更多风险事件的考虑，将开展定义包含多种风险事件的列车运行状态，同时改进该模型框架以实现目标。

(2) 本文在特征初选择方面采用人工选择，受人为因素的影响较大，为了支持更多特征的筛选，将在未来开展自动化抽取风险预测特征的研究，力求设计模型或工具以实现特征自动处理。

(3) 本文的预测模型在实验中存在少量误分类情况，接下来的研究会尝试解决这种误分类情况。对样本数据集进行更细致的状态分类，从而细化风险状态之间的差距以解决误分类。同时，本文将对多种神经网络进行深入研究，以实现网络模型融合，从而使模型各项预测性能有效提高，更好地向“零误差”分类目标努力。

参考文献

- [1] Ieee standard for communications-based train control (cbtc) performance and functional requirements[J]. IEEE Std 1474.1-2004 (Revision of IEEE Std 1474.1-1999), 2004: 0_1–45.
- [2] GURNÍK P. Next generation train control (ngtc): More effective railways through the convergence of main-line and urban train control systems[J]. Transportation Research Procedia, 2016, 14: 1855–1864.
- [3] HUANG W, SONG G, HONG H, et al. Deep architecture for traffic flow prediction: Deep belief networks with multitask learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15: 2191–2201.
- [4] CHEN C, XIANG H, QIU T, et al. A rear-end collision prediction scheme based on deep learning in the internet of vehicles[J]. Journal of Parallel and Distributed Computing, 2018, 117: 192–204.
- [5] DE BRUIN T, VERBERT K, BABUŠKA R. Railway track circuit fault diagnosis using recurrent neural networks[J]. IEEE transactions on neural networks and learning systems, 2017, 28(3): 523–533.
- [6] TOMPSON J, JAIN A, LECUN Y, et al. Joint training of a convolutional network and a graphical model for human pose estimation[C]//Advances in Neural Information Processing Systems. Montreal, Quebec, Canada: Curran Associates, Inc.: 1799–1807.
- [7] DENG L, DAHL G, RAHMAN MOHAMED A, et al. Deep neural networks for acoustic modeling in speech recognition[C]//volume 29. [S.l.]: IEEE: 82–97.
- [8] COLLOBERT R, WESTON J, BOTTOU L, et al. Natural language processing (almost) from scratch[J]. Journal of Machine Learning Research, 2011, 12: 2493–2537.
- [9] BORDES A, CHOPRA S, WESTON J. Question answering with subgraph embeddings[C]//[S.l.]: Association for Computational Linguistics, 2014.
- [10] JEAN S, CHO K, MEMISEVIC R, et al. On using very large target vocabulary for neural machine translation[J]. Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), 2015.
- [11] Lee W S, Grosh D L, Tillman F A, et al. Fault tree analysis, methods, and applications : A review[J]. IEEE Transactions on Reliability, 1985, R-34(3): 194–203.
- [12] STAMATIS D H. Failure mode and effect analysis: Fmea from theory to execution [M]. [S.l.]: ASQ Quality Press, 2003.

- [13] LIU H C, LIU L, LIU N. Risk evaluation approaches in failure mode and effects analysis: A literature review[J]. *Expert systems with applications*, 2013, 40(2): 828–838.
- [14] MADER R, ARMENGAUD E, LEITNER A, et al. Computer-aided pha, fta and fmea for automotive embedded systems[C]//International Conference on Computer Safety, Reliability, and Security. [S.l.]: Springer, 2011: 113–127.
- [15] PAN H, TU J, ZHANG X, et al. The fta based safety analysis method for urban transit signal system[C]//Reliability, Maintainability and Safety (ICRMS), 2011 9th International Conference on. [S.l.]: IEEE, 2011: 527–532.
- [16] KLOOS J, HUSSAIN T, ESCHBACH R. Risk-based testing of safety-critical embedded systems driven by fault tree analysis[C]//Software Testing, Verification and Validation Workshops (ICSTW), 2011 IEEE Fourth International Conference on. [S.l.]: IEEE, 2011: 26–33.
- [17] LIU Y, SHEN G, HUANG Z, et al. Quantitative risk analysis of safety-critical embedded systems[J]. *Software Quality Journal*, 2017, 25(2): 503–527.
- [18] COMPTIER M, DEHARBE D, PEREZ J M, et al. Safety analysis of a cbtc system: a rigorous approach with event-b[C]//International Conference on Reliability, Safety and Security of Railway Systems. [S.l.]: Springer, 2017: 148–159.
- [19] 胡少强. 基于 stpa 和有色 petri 网的列控系统安全分析[D]. [出版地不详]: 北京交通大学, 2018.
- [20] BOUDI Z, COLLART-DUTILLEUL S, KHADDOUR M, et al. High level petri net modeling for railway safety critical scenarios[C]//10th FORMS-FORMAT symposium, Formal Methods for Automation and Safety in Railway and Automotive Systems. Braunschweig, Germany: [s.n.], 2014: p65–75.
- [21] JENSEN F V, et al. An introduction to bayesian networks: volume 210[M]. [S.l.]: UCL press London, 1996.
- [22] CAI B, LIU Y, XIE M. A dynamic-bayesian-network-based fault diagnosis methodology considering transient and intermittent faults[J]. *IEEE Transactions on Automation Science and Engineering*, 2017, 14: 276–285.
- [23] WU Y, JIANG B, LU N, et al. Bayesian network based fault prognosis via bond graph modeling of high-speed railway traction device[C]//volume 2015. [S.l.]: Hindawi, 2015.
- [24] NEFTI S, OUSSALAH M. A neural network approach for railway safety prediction[C]//Systems, Man and Cybernetics, 2004 IEEE International Conference on: volume 4. [S.l.]: IEEE, 2004: 3915–3920.
- [25] TAMILSELVAN P, WANG P. Failure diagnosis using deep belief learning based health state classification[J]. *Reliability Engineering & System Safety*, 2013, 115:

- 124–135.
- [26] STRICKLAND M, FAINEKOS G E, AMOR H B. Deep predictive models for collision risk assessment in autonomous driving[J]. 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018: 1–8.
 - [27] CHEN J, WU Z, ZHANG J. Driving safety risk prediction using cost-sensitive with nonnegativity-constrained autoencoders based on imbalanced naturalistic driving data[J]. IEEE Transactions on Intelligent Transportation Systems, 2019.
 - [28] YANG Y, QIN Y, JIA L, et al. Traffic safety region estimation based on sfs-pca-lssvm: An application to highway crash risk evaluation[J]. International Journal of Software Engineering and Knowledge Engineering, 2016, 26(09n10): 1555–1570.
 - [29] CAFLISCH R E. Monte carlo and quasi-monte carlo methods[C]//volume 7. [S.l.]: Cambridge University Press, 1998: 1–49.
 - [30] YOUNES H L S, SIMMONS R G. Statistical probabilistic model checking with a focus on time-bounded properties[J]. Inf. Comput., 2006, 204: 1368–1409.
 - [31] SRINIVASAN R. Importance sampling: Applications in communications and detection[M]. [S.l.]: Springer Science & Business Media, 2013.
 - [32] KULLBACK S. Information theory and statistics[M]. [S.l.]: Courier Corporation, 1997.
 - [33] RUBINSTEIN R. The cross-entropy method for combinatorial and continuous optimization[J]. Methodology and computing in applied probability, 1999, 1(2): 127–190.
 - [34] RIDDER A. Importance sampling simulations of markovian reliability systems using cross-entropy[J]. Annals of Operations Research, 2005, 134(1): 119–136.
 - [35] GUYON I, ELISSEEFF A. An introduction to variable and feature selection[J]. Journal of machine learning research, 2003, 3(Mar): 1157–1182.
 - [36] CHANDRASHEKAR G, SAHIN F. A survey on feature selection methods[J]. Computers & Electrical Engineering, 2014, 40: 16–28.
 - [37] JOLLIFFE I. Principal component analysis[M]. Berlin, Heidelberg: Springer Berlin Heidelberg, 2011: 1094–1096.
 - [38] F.R.S. K P. Liii. on lines and planes of closest fit to systems of points in space [J]. The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science, 1901, 2(11): 559–572.
 - [39] DUNTEMAN G H. Principal components analysis: number 69[M]. [S.l.]: Sage, 1989.
 - [40] PRICE A L, PATTERSON N J, PLENGE R M, et al. Principal components analysis corrects for stratification in genome-wide association studies[J]. Nature ge-

- netics, 2006, 38(8): 904.
- [41] ELMAN J L. Finding structure in time[J]. Cognitive science, 1990, 14(2): 179–211.
 - [42] GRAVES A, LIWICKI M, FERNÁNDEZ S, et al. A novel connectionist system for unconstrained handwriting recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2009, 31(5): 855–868.
 - [43] SAK H, SENIOR A, BEAUFAYS F. Long short-term memory recurrent neural network architectures for large scale acoustic modeling[C]//Fifteenth annual conference of the international speech communication association. Singapore: ISCA.
 - [44] WANG J, YU L C, LAI K R, et al. Dimensional sentiment analysis using a regional cnn-lstm model[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers): volume 2. Berlin, Germany: ACL, 2016: 225–230.
 - [45] NALLAPATI R, ZHOU B, DOS SANTOS C, et al. Abstractive text summarization using sequence-to-sequence rnns and beyond[C]//CoNLL. [S.l.]: Association for Computational Linguistics, 2016.
 - [46] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735–1780.
 - [47] GREFF K, SRIVASTAVA R K, KOUTNÍK J, et al. LSTM: A Search Space Odyssey[J]. IEEE Transactions on Neural Networks and Learning Systems, 2017, 28(10): 2222–2232[2018-12-22].
 - [48] NASR G E, BADR E, JOUN C. Cross entropy error function in neural networks: Forecasting gasoline demand.[C]//FLAIRS conference. [S.l.]: AAAI Press, 2002: 381–384.
 - [49] BOTTOU L. Stochastic gradient descent tricks[C]//Neural Networks: Tricks of the Trade: Second Edition. Berlin, Heidelberg: Springer Berlin Heidelberg, 2012: 421–436.
 - [50] KINGMA D P, BA J. Adam: A method for stochastic optimization[J]. CoRR, 2015, abs/1412.6980.
 - [51] CHAWLA N V, JAPKOWICZ N, KOTCZ A. Editorial: Special issue on learning from imbalanced data sets[J]. ACM Sigkdd Explorations Newsletter, 2004, 6(1): 1–6.
 - [52] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The Journal of Machine Learning Research, 2014, 15(1): 1929–1958.
 - [53] POWERS D M. Evaluation: from precision, recall and f-measure to roc, informed-

- ness, markedness and correlation[Z]. [S.l.]: Bioinfo Publications, 2011.
- [54] HINTON G E. Deep belief networks[J]. Scholarpedia, 2009, 4: 5947.
- [55] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[M]//PEREIRA F, BURGESS C J C, BOTTOU L, et al. Advances in Neural Information Processing Systems 25. [S.l.]: Curran Associates, Inc., 2012: 1097–1105.
- [56] RUMELHART D E, HINTON G E, WILLIAMS R J. Parallel distributed processing: Explorations in the microstructure of cognition, vol. 1[M/OL]//RUMELHART D E, MCCLELLAND J L, PDP RESEARCH GROUP C. Cambridge, MA, USA: MIT Press, 1986: 318–362. <http://dl.acm.org/citation.cfm?id=104279.104293>.
- [57] FLAMMINI F, MARRONE S, MAZZOCCA N, et al. Modelling system reliability aspects of ertms/etcs by fault trees and bayesian networks[C]//Proc. European Safety and Reliability Conference, ESREL. [S.l.]: Reliability Engineering & System Safety, 2006: 2675–2683.

致谢

研究生的岁月，如流水的一般过去。记得匆匆奔走在数学馆，教书院和理科大楼之间，好像还是昨日的事。可如今实验里的人已全换了模样，原来是要毕业了。三年前孤身来沪的我，正是有了许多人的陪伴与帮助，才能在师大中学习，在师大中成长。在此，我想向他们表达我最真诚的感谢。

感谢我的导师刘静教授，与刘老师初相识就有一种亲切的感觉，谢谢她在形式化建模研究方面为我打开了新的大门，让我领略了形式化方法的魅力。傍晚时刘老师的办公室总亮着灯，有时走的比学生还晚，她在学术上认真严谨，一丝不苟的工作方式不断影响，教育着我。不论是在辅导我的本科毕设还是探讨的各种学术问题，刘老师总能为我拨开迷雾，指引我走向问题的终点。记得刘老师总是爱说“我一直都在，你随时来”，感谢刘老师是我学术研究道路上坚强的后盾，让我充满勇气，无畏无惧地走下去。在生活上，刘老师也如母亲般细心，她时常提醒我天冷时记得添衣，学习时也别忘了休息，也时常问问我们还需要什么，是我在这偌大的都市中的依靠。在此，再次对刘静老师表示衷心感谢！

与此同时，我还要感谢课题组的陈小红副教授，杜德慧副教授以及孙海英老师。感谢她们在课题讨论时给予我的建议，在有新想法时对我的鼓励和引导，也感谢她们指出我研究工作中的欠缺。

感谢在研究生阶段帮助过我的同学，以及相互鼓励奋斗在实验室的师兄师姐，师弟师妹们，他们在我有成绩时和我一起欢笑，在我失望时站在我的身后。感谢师兄袁正恒，李腾飞，师姐安东东和张娟，在我有新想法时一起分享，探讨，也在我迷惑时为我开导梳理；感谢师弟师妹侯则辰，韩佳程，张兆迪，感谢我的同学张贤、赵慧，陪我度过生活学习中的种种困难，一起成长。

最后想感谢我的家人。儿行千里母担忧。我取得如今的成绩离不开他们的支持，陪伴与帮助。感谢母亲这么多年的无私奉献，陪伴我从小城市走到了现在；无论我的选择是如何的，她总会永远支持与帮助我，她是我在黑暗中的灯塔，是我永远的依靠。

张炎

二零一九年五月

攻读硕士期间研究成果

■ 已完成学术论文

- **Yan Zhang**, Jiazhen Han, Jing Liu, et al. Safety prediction of rail transit system based on deep learning[C]//2017 IEEE/ACIS 16th International Conference on Computer and Information Science (ICIS). IEEE, 2017: 851-856. (EI 检索, 已公开发表)

- Jing Liu, **Yan Zhang**, Jifeng He, Junfeng Sun, Tingliang Zhou et al. Intelligent Hazard-risk Prediction Model for Train Control System. IEEE Transactions on Intelligent Transportation Systems. (SCI 一区, CCF B 期刊, 已投稿且在三审中)

- **Yan Zhang**, Jing Liu, Junfeng Sun. Intelligent-prediction Model of Safety-risk for CBTC System by Deep Neural Network. CollaborateCom 2019. (CCF C 类, 已录用)

■ 参与科研课题

- 卡斯柯有限公司与华东师范大学合作项目: 列车运行控制系统形式化建模与验证 (二期)