

2020 届硕士专业学位论文

分类号: _____

学校代码: 10269

密 级: _____

学 号: 71174500107



華東師範大學

East China Normal University

硕士专业学位论文

MASTER'S DISSERTATION

论文题目: 基于运动想象的脑机
接口中 EEG 信号
分类算法研究

院 系: 软件工程学院

专业学位类别: 工程硕士

专业学位领域: 软件工程

论文指导教师: 杜育根副教授

论 文 作 者: 齐俊丽

2020 年 10 月 02 日

Dissertation for master degree in 2020

Student ID:71174500107

University code:10269

East China Normal University

Title: Research on EEG Signal Classification
Algorithm Brain-Computer Interface Based on Motor
Imagery

Department:	<u>Software Engineering Institute</u>
Type:	<u>Master of Engineering</u>
Domain:	<u>Software Engineering</u>
Supervisor:	<u>A.P. Yungen Du</u>
Candidate:	<u>Qi Junli</u>

Oct,2020

华东师范大学学位论文原创性声明

郑重声明：本人呈交的学位论文《基于运动想象的脑机接口中 EEG 信号分类算法研究》，是在华东师范大学攻读硕士/博士（请勾选）学位期间，在导师的指导下进行的研究工作及取得的研究成果。除文中已经注明引用的内容外，本论文不包含其他个人已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中作了明确说明并表示谢意。

作者签名：齐俊丽 日期：2020 年 11 月 05 日

华东师范大学学位论文著作权使用声明

《基于运动想象的脑机接口中 EEG 信号分类算法研究》系本人在华东师范大学攻读学位期间在导师指导下完成的硕士/博士（请勾选）学位论文，本论文的研究成果归华东师范大学所有。本人同意华东师范大学根据相关规定保留和使用此学位论文，并向主管部门和相关机构如国家图书馆、中信所和“知网”送交学位论文的印刷版和电子版；允许学位论文进入华东师范大学图书馆及数据库被查阅、借阅；同意学校将学位论文加入全国博士、硕士学位论文共建单位数据库进行检索，将学位论文的标题和摘要汇编出版，采用影印、缩印或者其它方式合理复制学位论文。

本学位论文属于（请勾选）

- ☐ 1. 经华东师范大学相关部门审查核定的“内部”或“涉密”学位论文*，
于 年 月 日解密，解密后适用上述授权。
- ☒ 2. 不保密，适用上述授权。

导师签名：杜彦根

本人签名：齐俊丽

2020 年 11 月 05 日

* “涉密”学位论文应是已经华东师范大学学位评定委员会办公室或保密委员会审定过的学位论文（需附获批的《华东师范大学研究生申请学位论文“涉密”审批表》方为有效），未经上述部门审定的学位论文均为公开学位论文。此声明栏不填写的，默认为公开学位论文，均适用上述授权）。

齐俊丽硕士学位论文答辩委员会成员名单

姓名	职称	单位	备注
江建慧	教授	同济大学	主席
陈铭松	教授	华东师范大学	
程鹏	青年研究员	华东师范大学	

内容摘要

脑机接口（Brain Computer Interface, BCI）技术是直接和外部设备建立起连接的技术，其不经过正常的神经或肌肉通路。现代社会残障人士众多，为帮助残障人士恢复或助力至正常人运动能力水平，脑机接口技术正受到越来越多的重视以帮助残障人士进行康复训练或重获运动能力。

在脑机接口或脑科学技术研究中，脑电（Electroencephalogram, EEG）信号的获取和解码是 BCI 的关键环节。脑电信号作为非侵入式、可直接获取的外部生理信号，包含大量的人类思维和情感信息，对脑电信号进行解码可精确捕捉到被试个体的思维意图和喜怒哀乐等信息。基于此，本文重点开展 EEG 信号的解码研究，试图从非线性、非平稳和具有较强时变特性的脑电信号中获取到被试的运动意图信息，对 EEG 信号预处理后进行了特征构建和分类，达到了良好的解码效果。本文的主要研究内容如下：

首先，为了提高脑电信号的信噪比，本文通过获取运动想象脑电信号相关节律，采用独立成分分析的方法对运动想象 EEG 进行多种伪迹的去除。

其次，本文针对脑电信号维度高的特点，研究了其在黎曼空间的数据拓扑特性，提出了黎曼空间本征模态函数平均法。对高维特征向量进行特征选择研究，经单因素方差校验和加权错误发现率排序，最终获得的特征分布优于经典的 EEG 滤波算法，共空间模式算法。

最后，本文研究了多类运动想象的分类识别问题。提出了一种决策树分类框架。该分类框架的每个节点均构造一个分类器来实现二分类任务识别，在决策树的最后节点构造多分类器识别多类运动想象任务，并将该分类框架与 SVM、费舍尔线性判别分析、决策树和 4 种卷积神经网络进行了结果比对分析。

综上所述，本文通过传统机器学习的方式对脑电信号的解码进行了多种方式的探索，不仅研究了深度学习技术在脑电信号解码中的应用潜力，还揭示了传统的统计分析方法在小数据集中的优势地位。基于统计学习和基于深度学习的脑电信号解码算法依然有较大的研究价值和进步空间。

关键词：脑机接口，运动想象，特征提取，黎曼几何，决策树

ABSTRACT

Brain computer interface (BCI) technology refers to the technology of directly establishing connection with external devices without normal nerve or muscle channels. There are many disabled people in modern society. In order to help the disabled people to recover or help to reach the level of normal people's sports ability, brain computer interface technology is getting more and more attention to help the disabled people to carry out rehabilitation training or regain their sports ability.

In the research of brain computer interface or brain technology, the acquisition and decoding of EEG signal is the key link of BCI. EEG signals, as a non-invasive and directly available external physiological signal, contains a lot of human thought and emotional information. Decoding EEG signal can accurately capture the thinking intention, emotions and other information of the subjects. Based on this, this paper focuses on the decoding of EEG signals, trying to obtain the motion intention information of subjects from the nonlinear, non-stationary and time-varying EEG signals. After the EEG signals are preprocessed, features are constructed and classified, and good decoding effect is achieved. The main research contents of this paper are as follows:

Firstly, the relative rhythm of motion image EEG signals was obtained, and various artifacts were removed by independent component analysis to improve the signal-to-noise ratio of motion image EEG signals.

Secondly, according to the characteristic of high dimension of EEG signal, the data topology characteristic of EEG signal in Riemann space is studied, and the Riemann space eigenmode function averaging method is proposed. The feature selection of high-dimensional feature vectors was studied, and the feature distribution obtained by single-factor variance check and weighted error discovery rate ranking was superior to the classical EEG filtering algorithm and the common-space mode algorithm.

Finally, this paper studies the classification and recognition of multi-class motion imagination. A decision tree classification framework is proposed. The classification framework of each node are constructing a classifier recognition to achieve binary classification task, at the end of the decision tree node structure classifier to identify classes more exercise to imagine more tasks, and the classification framework and support vector machine (SVM), fisher linear discriminant analysis, decision tree and 4 convolution neural network are analyzed in the result comparison.

To sum up, this paper explores various ways of decoding EEG signals through traditional machine learning, not only studying the application potential of deep

learning technology in DECODING EEG signals, but also revealing the dominant position of traditional statistical analysis methods in small data sets. The eeg decoding algorithms based on statistical learning and deep learning still have great research value and progress space.

Keywords: Brain computer interface ,Motor imagery, Feature extraction , Riemannian geometry, Decision tree

目录

内容摘要.....	1
ABSTRACT.....	III
目录.....	V
第 1 章 绪 论	1
1.1 课题的背景及研究意义	1
1.2 课题国内外研究现状	2
1.2.1 国内外脑机接口和 EEG 信号处理方法现状	2
1.2.2 国内外发展现状解析	6
1.3 本文结构	7
第 2 章 脑机接口基础知识与信号采集系统	9
2.1 EEG 信号的介绍	9
2.1.1 大脑的结构	9
2.1.2 EEG 信号的特点以及分类	10
2.2 脑电信号数据集和采集流程	12
2.3 信号预处理	13
2.2.1 数字滤波器	13
2.2.2 独立成分分析	15
2.4 本章小结	20
第 3 章 基于黎曼空间的 EEG 信号特征提取方法研究	21
3.1 黎曼空间本征模态函数平均法	21
3.1.1 黎曼流形	21
3.1.2 经验模态分解	22
3.1.3 黎曼空间本征模态函数平均法	24

3.2 实验验证	25
3.3 本章小结	28
第 4 章 脑电信号分类识别研究	29
4.1 决策树分类框架	29
4.2 决策树框架-支持向量机	31
4.3 决策树框架-费舍尔线性分类器	34
4.4 浅层卷积神经网络	37
4.5 不同分类方法的结果对比	40
4.6 本章小结	42
第 5 章 总结与展望	43
5.1 总结	43
5.2 展望	43
参考文献	45
致 谢	51

第1章 绪论

1.1 课题的背景及研究意义

柳叶刀 2019 年 6 月 24 号发布中国脑卒中难治报告，报告中提到 2018 年中国有脑卒中患者 1242 万，幸存者中有接近 70% 的患者为身体残障人士。由脑卒中引起的肢体功能患者，只有不到 15% 的患者恢复了 50% 的手部功能，仅仅不足 3% 的患者恢复了 70% 的手部功能，完全恢复的患者更是寥寥无几。如何提升患者的康复效果一直是医学界的难题，脑机接口（Brain Computer Interface, BCI）技术为患者的康复治疗带来了更大的希望，脑机融合感知能更好的促进大脑的可塑性变化，帮助患者进行功能重建或者提高自理能力。BCI 技术同时具有高强度、重复性、针对性、互动性的康复训练优势，是当前研究的热点话题。公开数据显示我国肢体残障的人群占残疾人总数的百分之三十以上^[1]。为帮助残障人士有效的进行康复训练，基于脑机接口技术的康复训练是采用脑和机器相结合的方式进行康复治疗。即大脑发出指令，由外部辅助装置完成对应的功能指令，从而逐步改善受损神经或替代部分肢体的功能。

近几年，随着计算机技术、信号处理技术和微电子等技术的不断发展，现实生活中 BCI 技术的应用范围越来越广。这些技术不断地将一些核心的信号处理单元与信号采集单元小型化，做到了真正意义上的便携、廉价和低功耗，因此基于脑电（Electroencephalogram, EEG）的便携式 BCI 设备层出不穷，在一定程度上促进了 BCI 技术在群众中的传播。BCI 技术可认为 BCI 技术提供了一种不需要完善的神经通路即可建立起大脑和肌肉间通信关系的方法，可由大脑发出控制指令来控制外部单元，或者通过外界反馈以微电流的形式刺激被试大脑的特定脑区以唤醒受损的脑区功能单元^[2,3]。脑机接口系统可分为主动式脑机接口和被动诱发式的脑机接口。而按照 EEG 信号不同的节律进行划分又可区分为基于感知运动节律的 BCI 系统、稳态视觉诱发电位的 BCI 系统及基于 P300 的 BCI 系统。

基于运动想象的脑机接口系统作为主动式 BCI 系统，其驱动源来自于被试的自发想象，更加接近于现实生活中的脑机接口系统，而诱发式的脑机接口系统则需要一定的外部装置作为靶刺激获取特定频段或时间段的脑电信号，其实用性受到一定的外部限制。在生物医学工程和康复医疗中，BCI 的典型应用常见如助力外骨骼、脑控电动轮椅、脑控键盘打字等^[4]。此外，BCI 技术的进一步发展还在启迪着人工智能和医用设备的进步，如无人驾驶、人工耳蜗、视皮层视觉假体、先进机器人控制技术等^[5,6]。在日常生活领域之外，BCI 技术还在航空航天、军事等领域有着巨大的发展潜力，可在一定程度上代替人类完成危险任务^[7,8]。

本课题关注 BCI 技术体系中的核心环节，预处理后脑电信号的特征提取和分类识别的过程，即为信号解码的过程，通过深入研究脑电信号的解码机理以及不同的信号解码方法实现特定类型运动想象脑电信号的精准识别，并对 BCI 系统的应用前景进行了展望。

1.2 课题国内外研究现状

1.2.1 国内外脑机接口和 EEG 信号处理方法现状

自从 1929 年德国精神学科教授 Ham Berger 首次成功地记录了有规则的脑电图以来，科研人员对于 BCI 的研究热情持续增长。1870 年左右，脑-机接口的概念的首次提出者是加州大学的 J.J.Vidal，并对其加以论述，讲解了多种 EEG 信号，涵盖 α 节律，mu 节律，以及诱发电位等，J.J.Vidal 的开创性工作为基于脑电信号的 BCI 系统研究提供了良好的开端。20 世纪 90 年代，全球研究 EEG 的小组仅有六个，自从 1999 年举办第一届脑-机接口大赛以后，先后 4 次 BCI 竞赛期间，全球范围内的脑-机接口研究小组发展到数百个，有关 BCI 技术的文章数量也在大幅增长^[9,10]。

国内研究学者崔燕利用基于运动想象的脑机接口这一原理，设计了一个手臂运动功能康复的脑机接口在线系统，如图 1.1，脑机接口康复系统的试验成功也表明其可行性^[11]；来自浙江大学的袁盛成功设计了可操纵的机器鼠，如图 1.2，这一实验表明人类可通过想象控制大鼠机器人，使其顺利的走出迷宫^[12]。



图 1.1 基于运动想象的机械手臂控制




图 1.2 基于运动想象的机器鼠

希腊的 Arfaras G 和 Pandria N 等人曾做过一个实验，他们把多名健康人作为实验对象，采用视觉和动觉想象运动进行运动想象训练，并通过想象左右手的运动来控制左右机械手臂的运动。实验显示，动觉想象运动在图像训练中有更突出的优势，而视觉观察想象运动在控制机械手臂时获得更高的成功率。实验结果表明：不同个体训练的结果相差很大。因此训练过程中也要考虑到不同个体的差异性^[13]。

Donati 等通过 BCI 与虚拟现实技术相结合的方法，设计了一种全新的康复训练辅助系统^[14]。系统的康复训练模式如图 1.3，对患者经过一年的训练，8 名完全瘫痪脊髓损伤患者变为不完全瘫痪状态^[15]。




图 1.3 患者的神经康复训练模式

现在主流的 BCI 系统按照 EEG 信号的记录方式可分为侵入式 BCI 和非侵入式 BCI。侵入式 BCI 的主要方法是在人的大脑皮层植入电极贴片，这使采集到的信号有强度大、分辨率高以及风险高等特点。非侵入式信号采集通过将电极贴片贴附于头皮记录 EEG 信号，风险较小，但是采集过程中由于经过头皮信号质量减弱，且包含多种噪声，需对脑电信号进行预处理才可使用。由于局限性，本文只研究非侵入式 BCI 脑电信号。

BCI 系统的核心是脑电信号的处理过程，该过程包括：信号预处理、特征提取和分类识别。高效的脑电信号识别算法对 BCI 系统有重要的实际意义，而且可以快速、精准识别多类运动特征。

脑电信号预处理可采用空间滤波方法和时间滤波算法。对于空间滤波方法，

Brunner C 等一起使用空间滤波器和快速 ICA 的方法,对脑电信号进行预处理,得到较好的去噪效果;罗志增等运用最大信噪比盲源分离算法,也得到了可观的效果^[16]。在时间滤波方面,为了提高信号的信噪比,可以使用带通滤波器和陷波滤波器,比如通过一个特定的频段(如 8-30Hz),可以滤除掉 50Hz 的工频信号。Hsu W Y、李松、伏云发和陈健等为了提高原信号的信噪比,采用巴特沃兹滤波器进行带通滤波^[17,18]。

基于运动想象相关识别,各国研究学者针对特征值的提取陆续提出了很多算法。提取方案有多种,作用域的不同可大致分为以下几种:时域、频域、时频域、空间域等。上海交通大学的学者李洁、张丽清等人提出了判别张量分解、非负张量分解和正则化判别张量分析等分解方法,通过这些方法可以从 EEG 信号的幅度信息提取特征值^[19]。

频域特征包括:自适应自回归模型系统特征、自回归模型系数特征以及以快速傅里叶变换为基础的功率谱特征^[20,21];Guger 等人通过 AAR 模型提出了 ERD/ERS 的时域特征;Anderson 等人利用多变量与单变量 AR 模型提取了脑电特征^[22]。

时域分析方法有多种,目前主要的分析方法包括希尔伯特-黄变换(HHT)、基于小波变换分析(WT)、小波包变换分析(WPT)、短时傅里叶变换(Short-term fourier transform,STFT)等^[23]。目前已有学者基于 DTCWT 和 CSP,提出了脑电信号的提取方法,主要是余青山、陈希豪、席旭刚等人^[24];孙会文、伏云发、熊馨等人提出了基于希尔伯特-黄变换的运动想象脑电模式识别的研究方法^[25]。

在脑电信号的空间域对脑电信号进行特征提取是一种较为常见且分类效果较好的特征工程方法。目前在空间域特征提取上比较常见的有独立成分分析和共空间模式以及基于非欧几何的特征提取方法。共空间模式具有较强的抗扰动能力,能够较好的去除伪迹和噪声对于脑电信号的影响,在这方面比较常见的分析方法有频率选择共空间模式、不变共空间模式等^[26,27]。随着传统的时频方法信号处理方式瓶颈的到来,众多学者对非欧几何变换做了大量的研究。在这些研究中,黎曼几何和格罗斯曼流形脱颖而出,成为最新的卓有成效的处理方法,又以黎曼几

何应用较为广泛^[28-32]。别的研究如联合时域、频域、空间域进行联合特征提取的方法也取得了较高的识别率^[33]。

分类算法在脑电信号处理中肩负着重要的输出职责。在这个环节，来自大脑的脑电信号终于能够以我们所能理解的额开量的形式进行输出，并相应的控制一些外部设备从而实现人与机器的互动。识别算法的识别率高低也就在一定程度上决定了最终整个 BCI 系统的性能。

1.2.2 国内外发展现状解析

目前国内外对脑电信号解析的研究均取得客观的效果。在 BCI 系统中，单一的分类方法如线性分类器、支持向量机等虽然简单易用，在离线的识别任务上表现也很好，但是不适用于在线的同步或者异步系统，其不能满足实时环境下密集的指令输出需求^[34]。深度学习因端到端的训练和识别过程大大降低了手动特征提取的难度而广受欢迎，已在所有类型的 BCI 系统得到应用，如 P300、视觉诱发电位、运动想象，情感识别及工作负荷检测。多数研究基于卷积神经网络展开，主要应用于 SSVEP，P300 和运动想象。然而在系统实用化方面，仍存在大量的问题，主要是下面几个方面：

（1）EEG 信号的分类准确率比较低、传输速率低。脑电信号中包含丰富的原始信息，其中很多冗余信息，不仅增加信号提取难度、增强运算能力，而且制约分类识别率和速率的提高。

（2）提高系统的实时性。BCI 系统研究过程中，对 EEG 信号的处理往往需要复杂、大量的计算，会消耗一定的时间，而且需要实时探测伪迹等。

（3）因个体差异的存在，产生的 EEG 信号差异较大。一种固定的脑机接口系统，很难满足不同个体的需求，即使是同一个个体，也会因其情绪变化、身体原因等因素导致原先设计的 BCI 系统无法继续使用。因此提高系统的自适应性是目前需要解决的一个难题。

从以上三方面可知，EEG 信号分类解码依然是 BCI 系统的核心部分，本课题致力于从准确率和个体适应性上改进 EEG 分类算法，同时力争通过标准化的

信息处理流程提高计算的效率。

1.3 本文结构

一个完整的脑机接口系统从信号采集到末端执行器执行具体任务，其中最为核心的环节依然是脑电信号的处理环节，在信号处理环节中，信号的解码方法和精度能够直接决定一个系统的成败。本文研究的重点在于脑电信号的解码方法上，预处理之后的脑电信号通过对特征工程以及分类方法进行研究，力争提高脑机接口系统的分类精度。下图 1.4 展示了运动想象脑机接口系统 EEG 信号解码流程图，本文研究的重点在于 EEG 信号处理。

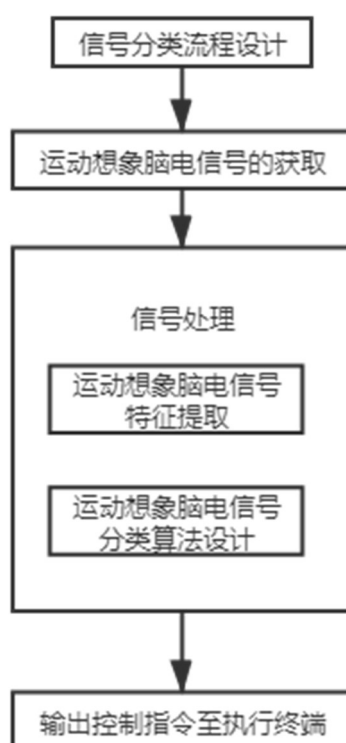


图 1.4 运动想象脑机接口系统 EEG 信号解码流程图

围绕多类运动想象脑电信号解码，本文的主要研究内容如下：

- (1) 阅读相关文献分析大脑皮层区域功能以及运动想象脑电信号变化规律，明确本文要研究的 EEG 节律范围。
- (2) 脑电信号预处理技术研究。由于脑电信号具有较强的背景噪声，受到心电、肌电、眼电以及周围工频噪声的影响，必须对 EEG 信号进行去噪处理。

借鉴在脑电信号处理领域效果较好的方法,例如带通滤波器和共平均参考方法进行脑电信号去噪。去噪后根据实际需要,对脑电信号进行线性校正,防止因线性漂移带来伪迹产生影响。

(3) 脑电信号特征提取与状态识别研究,选择在时域、频域、时频域和空间域分析效果较好的方法,如小波包变换、集成经验模态分解、希尔伯特黄变换、信息熵以及共空间模式等多种算法为理论基础进行特征提取,对比分析各自的处理结果,选择或者组合出最佳运动想象脑电特征。采用 LDA、SVM 及神经网络多种分类器对比分析最优分类结果,选择最具效率的信号处理方法。

具体的章节安排如下:

第一章绪论部分:介绍课题的背景意义,国内外脑机接口和 EEG 信号处理方法研究现状。

第二章脑机接口基础知识与信号采集系统:首先介绍了关于脑电以及脑机接口的基础知识,其次介绍了本文所用的公开数据集的数据详情以及数据采集流程。最后对脑电信号进行预处理,并展示了信号预处理的结果。

第三章基于黎曼空间的 EEG 信号特征提取方法研究:介绍了本文所采用的脑电特征提取方法,并对数据进行了处理以展示特征提取的效果。

第四章脑电信号分类识别研究:该章节介绍了本文所提出的一种决策树分类框架,并将其与多种分类方法进行了对比,证明其有效性。

第五章总结和展望:对本论文的工作进行总结,同时分析了工作中的不足以及今后需要继续深入探究的方向。

第2章 脑机接口基础知识与信号采集系统

2.1 EEG 信号的介绍

EEG 信号产生于大脑的神经元集群，并透过颅骨、皮质等传递至人类大脑头皮表面，携带丰富的生理和病理信息。但是 EEG 信号也具有随机性和微弱性等特征，很容易被外界噪声淹没。以下将对大脑的结构和具体的脑电信号节律特点进行介绍。

2.1.1 大脑的结构

大脑作为人体的一个器官，在处理和学习一些新信息时，具有独特的自我调节能力。大脑是与众不同的，它在一个人的一生中不断发展和演变。即使是此时此刻在阅读这段文字时，新的信息正在以惊人的速度被处理，储存在短期或长期的记忆中。大脑有巨大记忆容量可存储经验和信息。遗憾的是，大脑一直是个谜。如果不了解大脑的内部工作，很难绘制或创建大脑模型。这个非常复杂的器官被各种神经科学家和神经生理学家分析研究，他们进行大量的实验以找出大脑结构和行为背后的主要障碍和科学理论。通过检验和证明（或反驳）一个假设，整个谜题开始变得清楚了。有很多问题阻碍了大脑深层分析，问题在于大脑的可变性，尽管每个人都拥有大脑这样一个器官，但每个人的大脑在结构和功能上都是独一无二的。新出现的问题和困难并没有阻止人们对脑功能分析的兴趣，许多科幻电影给科学家们带来了巨大的灵感，将科幻小说带入现实生活。通过开发和使用新创建的方法分析大脑的结构和行为，将有可能找出隐藏在大脑中的秘密。

大脑的解剖结构有助于理解大脑内发生的一些过程，为了分析与运动行为相关的大脑功能，需要对这个结构进行回看，这一精神器官主要由许多相互连接、呈电活性的细胞组成，这些细胞被称为神经元(约 1000 亿个)和神经胶质细胞，它们不携带任何神经冲动。大脑细胞中，除了少量的神经元之外，胶质细胞占比高

达 90%。不像大多数其他细胞，神经元损伤后不能再生。神经胶质细胞提供生理上的，同时为神经元提供营养和消化支持髓鞘。

人脑主要由大脑，小脑和脑干三部分组成。小脑负责平衡，姿势和心脏功能。脑干创造了通向整体的运动和感觉通道的身体。最大的部分是大脑，由白质和灰质组织组成，它从中轴线分裂为两个大脑半球^[35,36]。大脑的外层，也就是灰质组织折叠的地方，叫大脑皮层。皮质由枕叶、颞叶、额叶和顶叶几个部分组成。如图 2.1 所示大脑皮层结构，这些脑叶各有不同的功能。额叶是负责行为，智力，嗅觉，注意力，动作等。枕叶处理视觉，在人类阅读中起关键性作用。大脑的顶部是主运动皮层，位于额叶，当做运动或者只是想象做运动的时候这部分最活跃，就会被激活。




图 2.1 大脑皮层结构

2.1.2 EEG 信号的特点以及分类

为了理解和分析大脑是如何工作的，需要使用大脑状态数据提取方法。其中一种用于大脑扫描的方法是磁共振成像。该成像方式的主要缺点是扫描时间长、实时性差。所以为了提高空间和时间分辨率进行了研究，另一种测量大脑活动的方法是脑电信号。EEG 信号中包含患者身体特征相关的各种信息。因此，分析研究脑电信号特征具有非常重要的意义。下图 2.2 展示了一段脑电信号的波形图，从图中可以看出，脑电信号具有较强的非平稳性，这无疑为研究脑电信号增加了难度。




图 2.2 原始脑电信号

脑电信号的分类方式有很多种。一般以频率进行划分居多。脑电信号的频率范围比较广泛，但是用于产生思维活动的脑电信号大多处于低频段，30Hz 以下为主，但是一般也不低于 0.5Hz。其他的分类方式还有吉布斯分类法和以图形图像为主的分类法。按照不同频率来分可以分为以下几种波，波形如下图 2.3^[37,38]。




图 2.3 脑电波的特征图

δ 波：0.5-3Hz，在深度睡眠或无梦的状态下，经常出现较强的 δ 波，婴儿在睡醒状态下也会出现不规则的 δ 波活动。δ 波还会出现在一些事故或者病变而导致失去意识以及极其疲劳的状态下。

θ 波：4-7Hz，通常是人类有睡意或者浅睡眠时产生的脑电波。此时大脑的神经系统处于抑制状态，即情绪低落，所以一些患有精神疾病的人群中会有 θ 波。

α 波：8-13Hz，出现在深度放松时闭上眼睛，并且波幅呈波动状“一大一小”规律性变化，当接收到外界刺激的信号时，α 波会立刻消失。在运动皮层出现的 α 波又称为 μ 波，该波与人类的实际运动以及想象运动有密切的联系。

β 波：14-30Hz，出现在有意识的集中状态下，人在工作、思考问题、接收到外界的刺激以及开心、紧张、惊讶状态时出现的波，大脑处于警觉状态，此时 α 波会被抑制。


γ 波：大于 30Hz，通常出现在人极其兴奋状态下，在分析脑电图时通常被忽略。脑电波的范围并不严格地局限于所提及的区域，而且会发生变化和重叠。

由于信号分析和预处理只是构建 BCI 系统的关键模块之一，下面进一步讨论常用的信号预处理方法。


2.2 脑电信号数据集和采集流程

本文数据集使用第四届 BCI 大赛的数据集 2a^[39]。该数据集包含九名被试者 (A01~A09)，采样率为 250Hz，采集 22 通道 EEG 数据和 3 个眼电通道数据。电极分布如图 2.4 (a)。

数据集分为训练集和测试集，训练集与测试集均包含左手 (Left hand, L) 运动想象、右手 (Right hand, R) 运动想象、脚 (Foot, F) 运动想象和舌 (Tongue, T) 运动想象任务各 72 组实验数据。实验开始时有声音提示，然后前 2s 内显示固定十字，接下来的 3s 也就是 3~6s 记录与运动想象相关的 EEG 信号。该数据集的实验流程如图 2.4 (b) 所示。



(a) 电极分布示意图



(b) 单次实验流程

图 2.4 电极分布图和实验流程

2.3 信号预处理

EEG 信号极其微弱，其信号幅值一般在 50 微伏左右，极易被强背景噪声如眼电、肌电、滑移伪迹等干扰^[40]，为了获取较为纯净的脑电信号，一般需要对脑电信号进行预处理以去除伪迹干扰。在实际的 BCI 系统中，信号预处理方式的不同很有可能导致整个系统的输出结果产生较大的偏移，一般的科学研究文献都未对该部分进行详细介绍，该小节通过介绍详细、经典的信号预处理方式来描述信号处理过程中去噪的必要性和重要性。

2.2.1 数字滤波器

滤波器，即为按照所用需求对输入信号中各个频率分量进行不同程度的扩大或削减处理，甚至消除某些频率分量。滤波器按照不同分类方式可分为很多种，如果按照处理信号的性质分为模拟滤波器和数字滤波器。模拟滤波器通常用来处理连续的模拟信号，比如常见电路板中所使用的滤波电路。而数字滤波器是对数字信号通过特定的数值运算，对信号中各频率成分进行处理。模拟滤波和数字滤波信号的形式和实现滤波的方法不同，但具有相似的概念。如下图 2.5 展示了数字滤波器的原理。




图 2.5 数字滤波器的原理

数字滤波器具有精度高、灵活、稳定、体积小以及不存在阻抗匹配等优点，是由于其通过数值运算实现信号处理的特征，可以实现很多模拟滤波器难以实现甚至无法实现的功能。

选频滤波器是数字滤波器的一种，也是我们平时最常见的数字滤波器，其频率响应函数表示为：

$$H(e^{j\omega}) = |H(e^{j\omega})| e^{j\theta(\omega)} \quad (2-1)$$

其中， $|H(e^{j\omega})|$ 是幅频特性函数， $\theta(\omega)$ 是相频特性函数。幅频特性函数是指滤波器对于输入信号各个不同频率成分的衰减程度，相频特性函数表示的是各个频率分量通过该滤波器后的时间延迟。

因此,就算有两个滤波器具有相同的幅频特性,而相频特性存在差异,输入相同信号后,得到的输出信号仍不相同。

滤波器还可按照处理的信号性质进行分类、按滤波器的选频作用分类、“最佳逼近特性分类”标准分类以及根据滤波元件的性质进行分类。总体上又可分为经典滤波器和现代滤波器。

经典滤波器是指希望被滤除信号的部分和希望得到的信号部分具有不同的频率分量,从而获取意图获得的纯净脑电信号。但是信号中往往混杂和有用信号频谱相同的干扰信号,此时经典滤波器则不能去掉同频的干扰信号,现代滤波器,如维纳滤波器,自适应滤波器以及卡尔曼滤波器等则能较好的克服经典滤波器的缺陷。

在脑电信号的预处理过程中,与运动想象脑电频谱相重合的噪声较多,不能通过现代滤波器进行去除,因此本文在脑电信号的预处理部分仅仅采用经典滤波器进行特定频段的截取,在后续分析中将采用独立成分分析中去除伪迹所带来的频谱干扰。

经典滤波器按照不同的滤波特性,可以分为以下几大类,如图 2.6:

- (1) 低通滤波器, 只有频率小于某一阈值的部分才能通过。
- (2) 高通滤波器, 只有频率大于某一阈值的部分才能通过。
- (3) 带通滤波器, 频率介于某一频段内才能通过。
- (4) 带阻滤波器, 只有频率介于某一频段内不能通过。




图 2.6 四种不同的滤波器

本文选取 8-30Hz 之间的运动想象脑电信号进行后续分析,选择的带通滤波器为 Butterworth 带通滤波器。Butterworth 带通滤波器是一类较为常见的滤波方式,其数学定义式如式 2-2 所示:

$$|H(j\omega)|^2 = 1 / \left(1 + \left(\frac{\omega}{\omega_c} \right)^{2n} \right) \quad (2-2)$$

其中, n 为 Butterworth 的滤波阶数, 本文 $n=5$, ω_c 是通带截止频率。

选取一段脑电信号, 对其作带通滤波后的信号及对应的傅里叶变换频谱图如图 2.7 所示:




图 2.7 $x_1(t)$ 经 5 阶 Butterworth 带通滤波后的信号与频谱图

从图中可以看出, 带通滤波后的脑电信号较为平稳, 但依然包含较大的伪迹干扰。从其频谱图中则可以得知信号中包含的 EEG 信号成分为 8-32Hz 之间的脑电成分。如何有效去除带通滤波后信号中依然存在的各种同频伪迹一直是脑电信号预处理的经典问题, 接下来本文将通过以独立成分分析为主的方法来展示如何去除脑电信号中的眼电、心电、肌电、出汗等其它伪迹成分。

2.2.2 独立成分分析

独立成分分析 (Independent Component Analysis, ICA), 即盲源分离, 是脑电信号领域极具科研价值与实用性的脑电信号降噪算法。ICA 起源于鸡尾酒舞会问题, 在假设统计独立性的前提下根据已知信号去估计信号发生源。在独立成分分析求解未知源的过程中, 一旦源成分已知, 我们就能观测到信号中的噪声成分, 从而对噪声进行有效的去除。独立成分分析的具体分析流程如下。

给定一组观测的信号 $x_1(t)$ 、 $x_2(t)$ 、 $x_3(t)$, 其中 t 为时间序列采样时间戳。在独立成分分析中, $x_1(t)$ 、 $x_2(t)$ 、 $x_3(t)$ 具备统计独立性, 因此与对应的源信号

$s_1(t)$ 、 $s_2(t)$ 、 $s_3(t)$ 之间的关系表达式如式 2-3 所示。

$$\begin{cases} x_1(t) = a_{11}s_1(t) + a_{12}s_2(t) + a_{13}s_3(t) \\ x_2(t) = a_{21}s_1(t) + a_{22}s_2(t) + a_{23}s_3(t) \\ x_3(t) = a_{31}s_1(t) + a_{32}s_2(t) + a_{33}s_3(t) \end{cases} \quad (2-3)$$

式 2-3 中, $A = [a_{11}, a_{12}, a_{13}; \dots a_{33}]$ 反映了独立成分与观测到的信号的线性关系, 是一个有待求解的矩阵。在现实的工程环境中, 我们仅有已经获得的信号 $x_i(t)$ 。那么, 独立成分分析就要同时求解 A 和 $s_i(t)$ 。在实际问题中, 一个信号源仅能产生一个信号波形。因此, $x_i(t)$ 与 $s_i(t)$ 应具有同等的数据维度。

使用数学过程中的统计隐变量模型准确的描述 ICA, 假设从 n 个独立成分观察到 n 个线性混合信号 x_1, \dots, x_n :

$$x_j = a_{j1}s_1 + a_{j2}s_2 + \dots a_{jn}s_n \quad (2-4)$$

假设每一个 x_j 和每一个独立成分 s_k 是随机变量, 观测值 $x_j(t)$ 是随机变量的样本值。我们可以假设混合变量和独立变量都具有零均值, 如果不满足, 我们可以对观察变量 x_i 进行去中心化处理, 使得模型为零均值模型。

在对已观测信号继续独立成分分析之前, 应满足独立成分分析的两大前提条件, 即各个独立成份不得为高斯分布且相互独立。在基础模型中, 我们假设分布是未知的, 混合矩阵 A 也被假设是未知的。当我们估算了矩阵 A , 那么我们可以求得逆矩阵 W , 可以通过下式得到独立成分:

$$s = Wx \quad (2-5)$$

ICA 处理信号的流程是首先确定待分解信号是否满足以下条件:

- (1) 独立成分之间应该是相互独立的。
- (2) 独立成分的统计分布情况有且仅能有一个成分是高斯分布。
- (3) 反映观测源与记录信号的矩阵应该是可逆的, 并且是为方阵。

通过 ICA 算法对信号进行预处理和变量中心化, 当不满足零均值时, 通过中心化可实现。独立成分变为零均值的量, 混合矩阵可以保持不变, 完成独立成分估计后, 可以将独立成分加上均值, 之后是白化过程, 白化又叫球面化, 即给定一些随机变量采用线性变换, 将其转换为相互无关变量的方法。转换后的变量独立一定不相关、不相关不一定独立。需要注意的是, 与不相关分析的方法相比,

白化略强些，它可以通过线性操作完成，不是唯一的白化矩阵假定所有混合变量与独立成分都是零均值。

在 ICA 模型中，仍然有很多问题还没有解决，比如不能确定独立成分的方差和顺序。在实际应用中，我们应采用别的计算方式弥补以上分析方法的不足。

选取 22 通道中的 F3 通道一段脑电信号（带通滤波后的脑电信号），对该段原始信号作功率谱变换，如图 2.8 所示，原始 EEG 信号包含大量的低频伪迹。

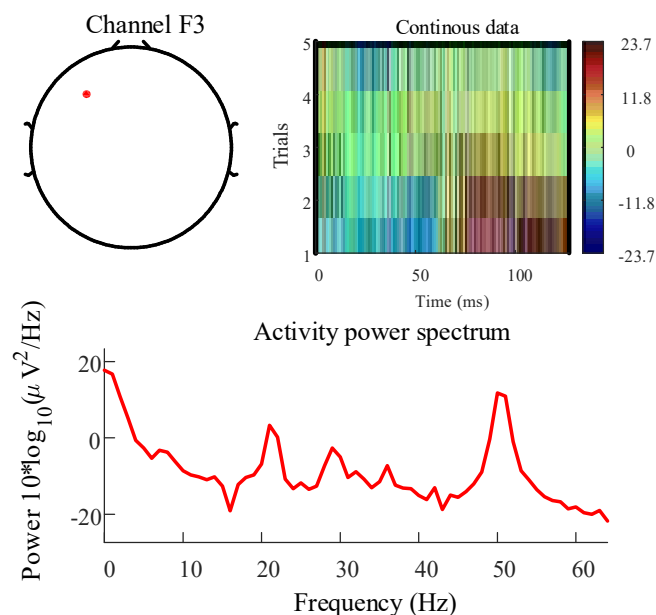


图 2.8 原始信号频谱图

进一步，对原始 22 通道的 EEG 信号作 ICA 变换，前 4 个脑电主成分的脑地形图如图所示。从图 2.9 中可以直观的看出，原始脑电信号第二主成分中包含丰富的眼电伪迹。但是在实际的脑电信号处理中，单纯的依靠这种人为观测方式去除脑电信号中的伪迹成分并不现实，需要浪费大量的人力和时间精力。因此迫切需要自动化的标定方式来有效去除脑电信号中的伪迹成分。

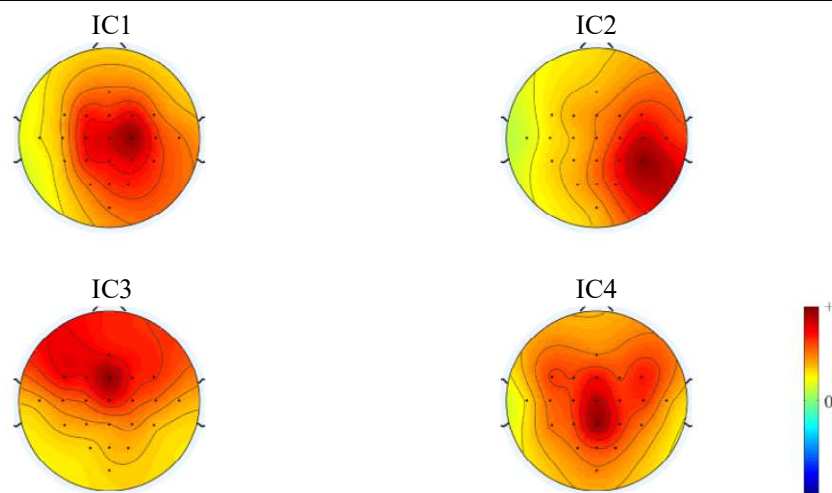


图 2.9 包含眼电伪迹的脑电信号示意图

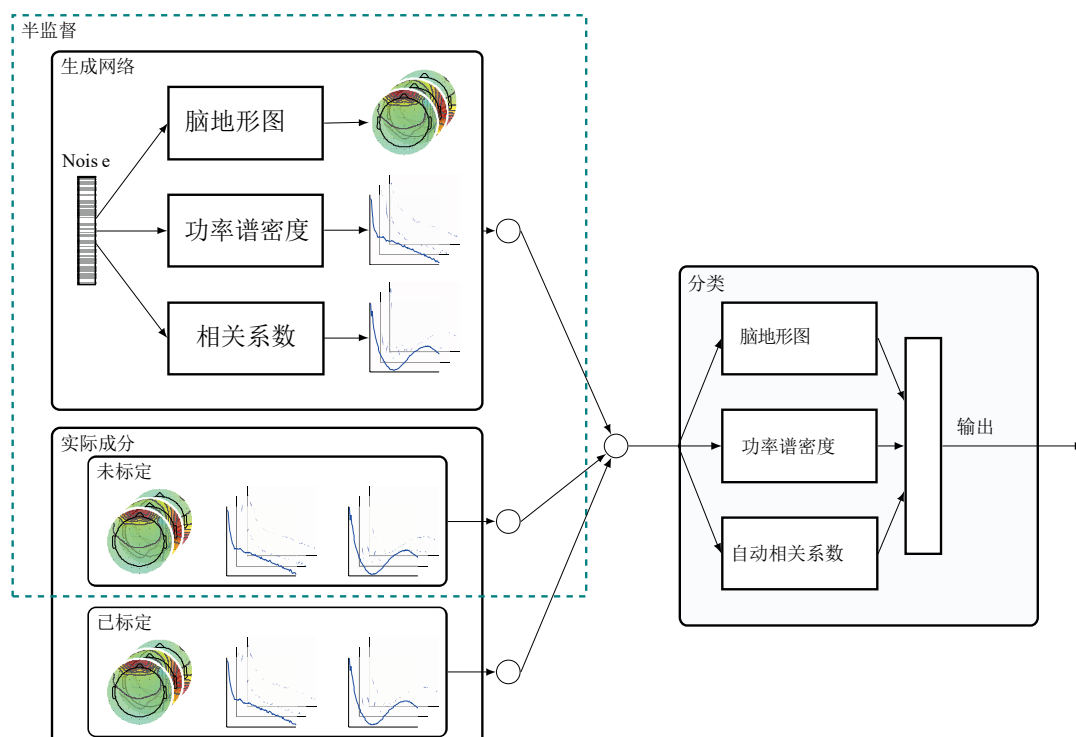


图 2.10 独立成分判别分析的流程框架图

因此本文采用了如图 2.10 所示的脑电独立成分判别分析流程来对脑电信号进行自动化的判别分析。在该分析流程中，我们首先依靠手动标记的方式对脑电信号的伪迹类型进行标记。之后，由于 EEG 信号的数据量不足，我们采取了生成对抗网络模拟生成了大量脑电数据。选取 EEG 信号的脑地形图、功率谱密度和相关系数作为特征训练神经网络，从而形成了可分析 7 类噪声的独立成分判别分析流程。

如图 2.11 展示了脑电信号前 4 主成分中占比最大的脑电信号成分分布以及

占比情况，图 2.12（a）展示了第 19 主成分中占比最大的信号成分占比情况，更详细的伪迹占比情况可通过图 2.12（b）获悉，

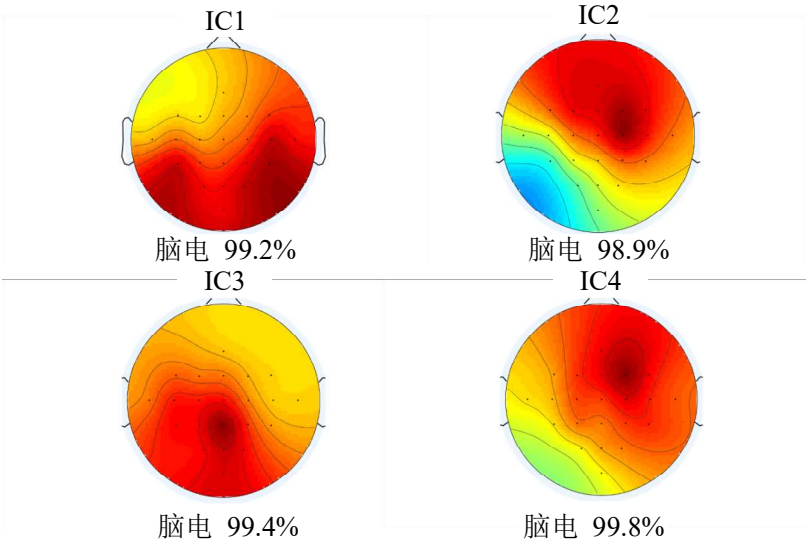



图 2.11 不同 IMF 的成分判别分析结果



(a) 第 19 主成分脑地形图分布情况

(b)各部分伪迹占比情况

图 2.12 原始脑电信号中各种成分的统计分布图

通过独立成分分析算法和独立成分判别分析流程将信号中各种伪迹去除之后进行重构，就可以得到纯净的脑电信号，如图 2.13 所示，从图中功率谱密度可以看出，脑电信号中几乎只包含 8-30Hz 之间的脑电成分。

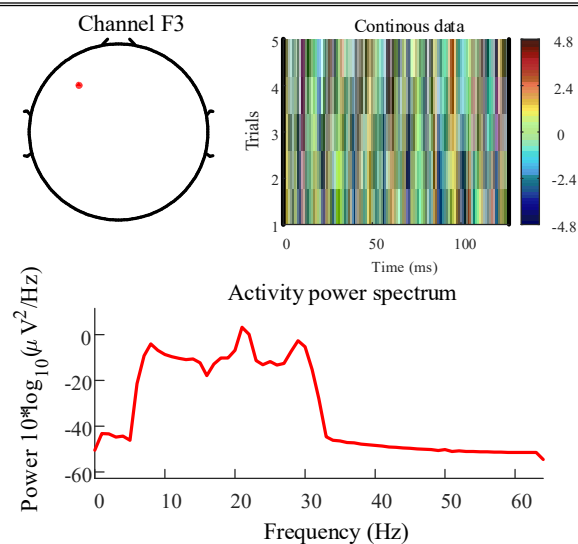


图 2.13 经带通滤波和独立成分分析分解后的脑电信号

2.4 本章小结

本章首先介绍了脑电信号的生理学背景，并对人脑中常见的波段进行了介绍。因为本文采用的数据集为公开数据集，因此介绍了公开数据集的数据详情和 EEG 的采集方式。最后介绍了数字滤波器的种类，并对本文所使用的 Butterworth 和 ICA 两种滤波去噪方法进行了介绍，经过对实际脑电信号的分析表明了本文所使用的脑电信号预处理方法的有效性。

第3章 基于黎曼空间的 EEG 信号特征提取方法研究

在 BCI 系统中, 脑电信号的特征提取是对关联信息的提取过程, 通过该过程, 将与类别无关的冗余信息去除, 通过将与类别相关联的信息进行简化表示, 可加强 BCI 系统中数据的可解释性, 进而利用不同的分类方法获得系统的最终解释输出。在本章节, 我们对 EEG 信号的本征模态函数进行筛选, 在黎曼空间中对本征模态函数进行叠加平均, 本文将该方法称之为黎曼空间本征模态函数平均法 (IMF averaging method in Riemannian space, IMFA-R)。本文对该方法的详细计算过程进行了推导并依据实验数据对该方法进行了实际的计算验证。

3.1 黎曼空间本征模态函数平均法

3.1.1 黎曼流形

点在空间位置的坐标系是研究几何对象的主要工具, 借助于坐标系就可以利用微积分的办法解决很多问题。在几何中研究这样的空间, 该空间允许有像可微函数或光滑函数, 微分运算以及积分运算这样的概念。

多维脑电信号 $x_i \in \Re^n$, 其中 x_i 为 $N \times M$ 的形式, N 代表信号的通道数, M 代表采样点数, \Re 表示欧式实数空间。脑电信号具有维度高的特点, 同样也会导致分类中的维度灾难问题。一段脑电信号 x_i 的样本协方差矩阵 $P_i \in R^{n \times n}$ 可通过式 3-1 求得:

$$P_i = \frac{1}{T_s - 1} x_i x_i^T \quad (3-1)$$

脑电信号的样本协方差矩阵具备对称正定矩阵的性质, 因而可在可微黎曼几何中应用流形的方式进行处理。如图 3.1 所示, 在微分流形-黎曼流形中, 对称正定矩阵定义于 P 和 P_i 两点, 在无限小的流形空间中, P 和 P_i 两点之间测地线 $\Gamma(t)$ 的距离可近似看作 $\Gamma(t)$ 的导数, 即 S_i :

$$P_i = EXP_P(S_i) \quad (3-2)$$

$$\text{Exp}_P(S_i) = P_i = P^{1/2} \exp(P^{-1/2} S_i P^{-1/2}) P^{1/2} \quad (3-3)$$

逆映射可以通过对数映射得到：

$$\text{Log}_P(P_i) = S_i = P^{1/2} \log(P^{-1/2} P_i P^{-1/2}) P^{1/2} \quad (3-4)$$

使用黎曼测地距离， $I > 1$ 个 SPD 矩阵的黎曼均值可由下式计算得到：

$$\mathfrak{I}(P_1, \dots, P_I) = \arg \min_{P \in P(n)} \sum_{i=1}^I \delta_R^2(P, P_i) \quad (3-5)$$

在黎曼流形中求训练集的均值，之后将每个样本协方差矩阵 P_i 映射至均值点对应的切平面 $P_{\mathfrak{I}} = \mathfrak{I}(P_i, i=1 \dots I)$ 上，产生维度为 $m = n(n+1)/2$ 的特征向量 S_i 。

$$S_i = \text{upper}(P_{\mathfrak{I}}^{-1/2} \text{Log}(P_i) P_{\mathfrak{I}}^{-1/2}) \quad (3-6)$$




图 3.1 黎曼流形与切平面向量

利用切空间对对称正定矩阵黎曼流形深入分析。运动想象脑电信号的协方差矩阵落在黎曼流形上，可用黎曼几何的工具进行分析处理，并且可绕过空域滤波器的设计和训练^[41]。

在图像处理领域，黎曼几何被用于行人检测和雷达图像处理等，黎曼几何处理协方差矩阵是非常有效的^[42,43]。BCI 领域的研究团队基于黎曼几何分析脑电信号用于睡眠状态检测，分析解码 P300 脑电信号和 SSVEP 信号^[44-46]。黎曼几何用于运动想象脑电信号的分类，Barachant 提出 MDRM、TS+LDA 和 TS+SVM 算法^[47-49]，这几种算法本文不做进一步的探讨。

3.1.2 经验模态分解

经验模态分解（Empirical Mode Decomposition, EMD）诞生于 1998 年，由 N. E. Huang 在美宇航局期间提出，适用于处理非线性、非平稳信号，在工程问题中应用广泛。EMD 能够自适应的对非线性、非平稳、随机性较强的脑电信号进

行自适应处理，从而得到一系列的本征模态函数（Intrinsic Mode Function, IMF）[50,51]。

对单个通道的脑电信号进行 EMD 分解，所获得的 n 个 IMF 分量表达式如式 3-7:

$$S(t) = \sum_{i=1}^n C_i(t) + R_n(t) \quad (3-7)$$

其中， $S(t)$ 表示原始 EEG 信号， $C_i(t)$ 表示第 i 次分解得到的 IMF 分量， $R_n(t)$ 为经过 n 次分解后的残留分量。

在经验模态的分解过程中，我们将指定分解次数或通过限制残余分量的标准差（Standard Deviation, SD）以避免过多或无限次的分解将信号分解为无意义的调频信号。在经验模态分解的过程中，标准差的定义如式 3-8:

$$SD = \sum_{t=0}^T \left[\frac{|h_{l(k-1)}(t) - h_{lk}(t)|^2}{h_{l(k-1)}^2(t)} \right] \quad (3-8)$$

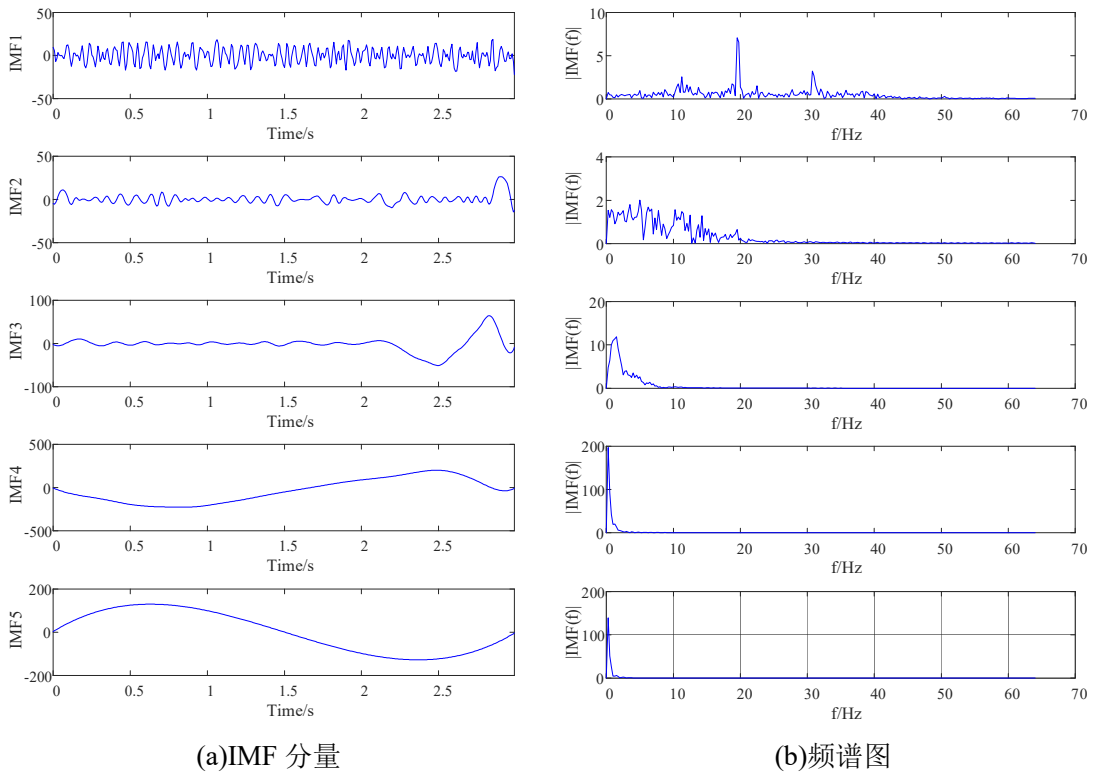


图 3.2 IMF 分量和频谱图

其中 T 为所选 EEG 信号的时间长度。根据经验，标准差的值最小可为 0.2，

最大可为 0.3, 在本文中令 $SD=0.25$ 。将预处理后的脑电信号进行经验模态分解, 如图 3.2 所示, 图 3.2 (b) 展示了 IMF 分量分幅频变化特性, 从图中可以看出, IMF 分量的频率分布从高到低, IMF_1 中包含较多的运动想象 EEG 信号信息。

3.1.3 黎曼空间本征模态函数平均法

本文所提出的黎曼空间本征模态函数函数平均法, 即 IMFA-R 法。其本质是将本征模态函数在黎曼空间中进行平均化处理, 以此获得更稳定的特征表达。具体的计算过程如下所示。

将本征模态函数以 $IMF_1, IMF_2, \dots, IMF_n$ 的形式表示, 则每个 IMF 分量的对称正定矩阵可表示为式 3-9:

$$P_i^{IMF} = \frac{1}{T_s - 1} IMF_n IMF_n^T \quad (3-9)$$

其中 T_s 表示本征模态函数的数据长度, P_i 是脑电信号的样本协方差矩阵。

之后采用 3.1.1 小节介绍的方法可求得黎曼空间本征模态函数平均值, 如式 3-10 所示。

$$\mathfrak{Z}(P_1^{IMF}, \dots, P_I^{IMF}) = \arg \min \sum_{i=1}^I \delta_R^2(P^{IMF}, P_i^{IMF}) \quad (3-10)$$

其中, I 表示 IMF 分量的个数。求得黎曼空间均值点之后, 对于单试次的小段 EEG 数据, 其黎曼空间切平面向量如式所示 3-11:

$$s_i = upper((P_3^{IMF})^{-1/2} \text{Log}(P_i^{IMF})(P_3^{IMF})^{-1/2}) \quad (3-11)$$

经黎曼空间本征模态函数平均之后, 如图所示, 该图展示了黎曼空间本征模态函数平均之后与原始信号直接映射于黎曼空间的数据点分布情况对比, 通过 IMF 平均, IMFA-R 方法能够获得更加稳定的特征表达。




图 3.3 黎曼空间叠加平均与直接映射对比图

面对高维的特征空间和特征向量 s_i ，通常采用正则化方法来避免过拟合和维度灾难。另一种方案是引入特征选择以降低变量的空间维度。在本文中，我们使用单向方差校验方法（one-way ANOVA）选择具有区分度的特征。为削弱变量之间的相关性，采用奇异值分解（Singular Value Decomposition, SVD）算法对向量 s_i 进行正交化处理，如式 3-12：

$$S = U\Lambda V^T \quad (3-12)$$

其中 $S=[s_1...s_I] \in \mathbb{R}^{m \times I}$ ，正交矩阵 $U \in \mathbb{R}^{m \times m}$ ， $V \in \mathbb{R}^{I \times I}$ ，对角矩阵 $\Lambda \in \mathbb{R}^{m \times I}$ 包含 S 的所有奇异值。

对原始向量空间 S 进行正交基变换，即主成分分解，可得正交切空间 S_o ，如式 3-13：

$$S_o = U^T S \quad (3-13)$$

在正交切空间 S_o 中，所有变量相互独立。采用单向方差校验方法对不同类别的向量进行 p -值排序，采用加权错误发现率（False discovery rate, FDR）方法自动选择最优的向量维度。在错误发现率的评价中，奇异值作为权值可优先选择出最能代表向量数据结构的特征集合。

3.2 实验验证

本文所使用的数据集 EEG 电极通道的数量为 22，由 3.1.1 公式 3-23 可知，本文所得到的原始特征向量的维度为 $N = 22 \times (22+1)/2 = 253$ 维。高维的特征向量固然携带大量的有用信息，但是信息中的冗余成分对于分类器却是维度灾难，且极易出现过拟合现象。本文使用 f_{raw} 表示原始信号经黎曼空间映射后的特征向量，而采用 f_{IMFA-R} 表示原始信号经 IMFA-R 方法处理后得到的特征向量。 f_{raw} 为 253 维的高维特征向量， f_{IMFA-R} 维数通过特征选择确定。

在切空间中，进行特征选择之前，首先需要对微分流形的近似形式进行误差计算，在黎曼流形和切空间中，误差计算的形式采用距离进行度量，如式 3-14：

$$\forall i, j \quad \delta_R(P_i^{IMF}, P_j^{IMF}) \approx \|s_i - s_j\|_2 \quad (3-14)$$

也可以通过规范化成对误差继续经验判别：

$$\varepsilon_{ij} = \frac{|\delta_R(P_i^{IMF}, P_j^{IMF}) - \|s_i - s_j\|_2|}{\delta_R(P_i^{IMF}, P_j^{IMF})} \quad (3-15)$$

采用规范化成对误差在九名被试者中进行误差计算, ε_{ij} 的均值和标准差分别是 1.85% 和 0.58%, 满足误差要求, 可进一步采用 3.1.3 描述的方法进行特征排序和选择。

应用 IMFA-R 算法对预处理后的脑电信号进行处理, 切空间正交化后, 单因素方差校验依据不同类别的样本对向量进行 p -值排序, 类别之间区分度较高的向量排序靠前。图展示了随着向量维数增加 p -值的变化情况。从图 3.4 中可以看出, 特征向量中仅有小部分变量区分性较为明显, 在该部分变量之后, p -值快速增长。使用加权 FDR 算法选择最小变量数, 设置 $q = 0.05$, 其中 q 为错误拒绝率相对于相对于全体拒绝样本的期望值。对于本文, 本文选择的特征维度为 8。




图 3.4 向量之间的 p 值评估图

图 3.5 展示了经 3.1.3 节所述方法处理后不同类别动作所对应的特征向量统计分布情况。从图中可以看出, 四类动作并没有得到较好的区分, 但是从图中可以看出, 左手和口两类动作得到了较好的区分, 左右手类别相对于脚、口两类区分度也较为显著。造成这种现象的原因主要是生理原因导致的。增加变量的维度能为动作之间的区分带来更多的补充信息。




图 3.6 不同动作 IMFA-R 后经特征选择后的向量统计分布情况

共空间模式算法在脑机接口运动想象中应用广泛。本文同样采用共空间模式算法构造空间滤波器来获得四类运动想象动作的特征向量,并得到四类特征向量的统计特性如图 3.6 所示。从图中可以看出,共空间模式算法所获得的特征表达类似于本文,这是因为共空间模式算法所构造的空间滤波器类似于黎曼几何中的正交空间所导致的。但是共空间模式算法的特征分离度并没有本文的方法效果好。




图 3.7 共空间模式算法所得的特征向量统计分布情况

图 3.8 展示了随着向量维度增加,总体分类错误率的变化情况。在该验证环节中,本文采用了多分类线性分类器,因此出现了过拟合的现象。在训练集上的错误率接近于 0 而测试集上的错误率在向量维度大于 8 之后开始增加。最小分类错误率的向量维度为 8,而加权 FDR 算法所选的向量维度也为 8。因此本文最终选择的向量维度为 8,在测试集上最小识别错误率为 18.85%。




图 3.8 选择的向量维度与分类错误率的情况

3.3 本章小结

本章对本文所采用的特征提取算法 IMFA-R 算法的计算过程进行了介绍，并介绍了本文所选择的特征选择算法。经过实际数据验证和比对，证明了本文所采用的特征选择算法的有效性。

第4章 脑电信号分类识别研究

在本章节，本文对脑电信号的分类算法进行了研究，在第三章所述的基于IMFA-R的特征提取方法的基础上，第4章4.1节提出了基于决策树分类框架（Decision Tree Framework, DTF）的四类运动想象分类方法，因决策树分类框架需结合其他分类器使用，在4.2节和4.3节中，本文还对常用的分类器支持向量机（Support Vector Machine, SVM）和费舍尔线性分类器（Fisher Linear Discriminant Analysis, FLDA）在决策树分类框架中的应用进行了介绍。为对比传统机器学习方法与深度学习在EEG上面的表现，本章在4.4节设计了一个浅层神经网络，进一步的，通过数据增强技术提高了卷积神经网络的分类识别率。最后，本章4.5节综合各种分类方法进行了分类结果的对比展示以及论证分析以证实本文所提出的分类算法的有效性。

4.1 决策树分类框架

在BCI的研究过程中，对EEG进行特征提取后，需要对其进行分类，即模式识别，模式识别在BCI系统中占据着重要的地位，它的作用是学习和识别脑电信号的特征，并将识别出来的信号转化为控制命令输出^[52]。分类过程中选用的分类方法对最后的分类结果起着关键性作用，分类方法越优，分类结果越准确。为了达到更高水平的分类精度，在上一节的基础上，本文提出了一种组合分类方法，即决策树分类框架。

针对具体的四分类任务，本文设计的决策树分类框架是一种可将误判样本进行重新分类的分类框架，该分类框架的优势在于可结合不同的分类器进行分类任务，且分类准确率高于一强分类器。

为引入决策树分类框架的概念，首先对决策树的分类方式进行介绍。决策树的决策划分方式有错误率和信息熵等，在决策树的分类过程中，需要注意的是决策树的过拟合和欠拟合现象，通过采用剪枝策略即可避免。近年来，将决策树这

种树结构与分类器相结合的方式越来越适用于复杂的分类系统中。决策树中所有内部节点都表示自己一个属性上的判断,叶节点就是分类结果,输出其判断结果。如,Guo 等提出的一种方法,将神经网络与决策树相结合,该方法在决策树的每个节点嵌入一个多层神经网络^[53]。建立最优二叉树是决策树分类框架的关键,节点越靠近上层,对整个数据集的分类精度影响越大^[54]。为解决多类分类问题,本文根据最优分离原则建立了决策树分类框架,如图 4.1 所示,其中 $C.i$ 代表类别 i , $N.i$ 代表树节点 i ^[55]。

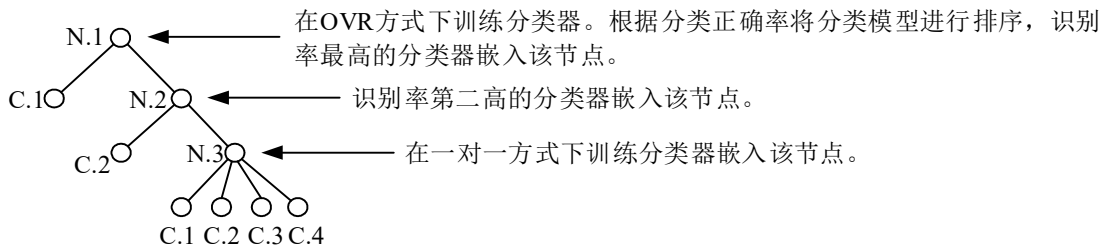


图 4.1 基于最优分离原则构建的四分类决策树分类框架

本文提出的决策树分类框架训练和测试分类框图如图 4.2 所示。

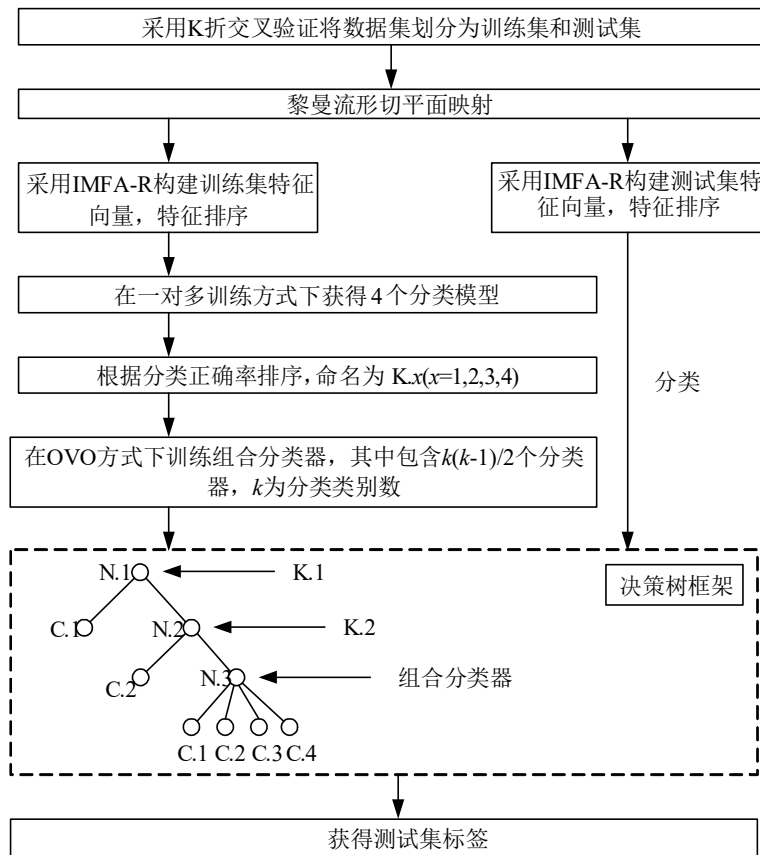


图 4.2 决策树分类框架训练和分类框图

本论文构建的决策树分类框架有两个优点：

(1) 分类识别率最高的两类运动想象任务, 可被该模型在前两层中以一对多 (One Versus Rest, OVR) 最大程度的分离出来。

(2) 在最后一个节点, 将前两个节点中的误分类样本以及全部待分类样本进行分类, 这里可运用一对一 (One Versus One, OVO) 的分类方式, 提高分类器的分类精度。

基于决策树分类框架, 本文将支持向量机和线性分类器应用于该分类框架形成了决策树框架-支持向量机 (Decision Tree framework- Support Vector Machine, DT-SVM) 和决策树框架-费舍尔线性分类器 (Decision Tree framework-Fisher Linear Discriminant Analysis, FLDA, DT-FLDA), 4.2 节和 4.3 节分别对二者在多样运动想象中的应用进行了描述。

4.2 决策树框架-支持向量机

支持向量机最初是为二分类问题设计, 在小样本的数据集中, 其表现效果往往优于神经网络。同时它也是数据挖掘算法中最健壮的, 也是最准确的方法之一。SVM 可以支持线性的分类和非线性的分类。

SVM 线性可分时, 如下图 4.3 是 SVM 进行分类时的示意图, 图中分别用圆和正方形表示两类线性可分的样本。 H 代表分类线, H_1 和 H_2 平行于 H , 且两类样本中离 H 最近的点分别在 H_1 和 H_2 上。此时 H_1 到 H_2 的距离就是分类间隔。将两类样本正确分开, 且使分类间隔最大时的直线就是最优分类线。




图 4.3 线性可分时分类示意图

实际上, 很多分类是非线性的, 处理这些问题时, 需要用到非线性 SVM,

其原理是：假设新特征空间 F 比原空间维度高，将非线性数据转变到新特征空间 F 中，在 F 中使用线性 SVM，如图 4.4 所示。 $F = \{\phi(x) : x \in X\}$ ， X 是输入空间， ϕ 表示从 X 到 F 的映射。则在非线性情况下，超平面如式 4-1：

$$\Omega \bullet \phi(x) + b = 0 \quad (4-1)$$

决策函数如式 4-2：

$$f(x) = \text{sign}[\omega \bullet \phi(x) + b] \quad (4-2)$$




图 4.4 非线性 SVM 特征空间的选择

在非线性支持向量机中，测试集和训练集的样本都采用相同的支持向量，其内积可表示为 $\langle x_i, x_i \rangle$ 、训练集的样本内积可以表示为 $\langle x_i, x_j \rangle$ ，在高维的空间 F 中，存在映射关系反映着二者内积的某种联系。这种关系可以采用核函数表示，核函数的意义即在将复杂的样本计算映射为简单计算。对于核函数 K ，存在 $x_i, x_j \in X$ ，核函数定义为： $\langle x_i, x_j \rangle = \langle \phi(x_i), \phi(x_j) \rangle$ ， ϕ 表示样本到 F 空间的映射关系。

核函数将低维空间映射至高维空间，而在映射的过程中，线性不可分的样本在高维空间中得到了有效的分离，大大简化了分离不同样本的计算量和难度，常用的核函数定义如下：

- (1) 线性核函数： $k(x, x_i) = x \cdot x_i$
- (2) 多项式核函数： $k(x, x_i) = (x \cdot x_i + 1)^d$
- (3) 径向基核函数： $k(x, x_i) = \exp\left(-\frac{\|x - x_i\|^2}{2\sigma^2}\right)$
- (4) Sigmoid 核函数： $k(x, x_i) = \tanh(v(x \cdot x_i) + c)$

在非线性 SVM 中涉及到核函数的优化问题，本文采用遗传算法 (Genetic algorithm, GA) 对单个非线性 SVM 的惩罚因子 c 和核函数宽度 σ 进行寻优。在

结合决策树分类框架使用时，为减少参数寻优的计算量，对应 OVO 的训练方式固定一组参数 c_1 , σ_1 ，对应 OVR 的训练方式固定另一组参数 c_2 , σ_2 ，参数选取的标准为依据最高平均识别率进行选取。

表 4-1 展示了遗传算法设定的初始参数范围，表 4-2 展示了惩罚因子和核函数的范围。首先，分别按照 OVO 和 OVR 的分类方式在九名被试中进行 10 折交叉验证以确定最佳核函数。

表 4-1 GA 参数设置

参数	名称	设定值
PS	种群大小	100
EG	进化代数	200
CP	交叉率	0.9
MP	变异率	0.1

表 4-2 SVM 参数范围

参数	名称	下限	上限
c	惩罚因子	0.01	8
δ	核函数	0.001	8

选择不同的核函数在 OVO 方式下依次训练 9 名被试四类运动想象任务，采取 10 折交叉验证平均识别率作为核函数选择的依据。表 4-3 展示了不同核函数支持向量机在 9 名被试中 OVO 方式下的平均识别率。从表中可以看出，径向基函数 SVM 平均识别率最高，达到了 69.19%，但是各个非线性函数之间的差异并不明显，线性核函数 SVM 表现最差，基本验证了 SVM 关于核函数的基础理论。对应 OVO 分类方式下径向基函数 SVM 的参数为 $c=5.5317$ ， $\sigma=2.7618$ 。

表 4-3 OVO 方式下 9 名被试 4 类运动想象任务 10 折交叉平均识别率 (%)

核函数	S1	S2	S3	S4	S5	S6	S7	S8	S9	均值
Poly	81.52	44.32	86.78	53.41	47.24	50.24	79.6	81.34	82.67	67.46
Rbf	79.34	50.41	85.42	56.32	46.67	54.31	81.64	83.24	85.34	69.19
Sigmoid	77.52	49.6	79.62	57.34	47.68	56.79	81.34	82.79	86.73	68.82
Linear	76.53	44.32	80.52	49.53	44.5	50.94	75.38	77.46	79.62	64.31

表 4-4 展示了不同核函数支持向量机在 9 名被试中 OVR 方式下的平均识别率。从表中可以看出，径向基函数 SVM 在 OVR 分类方式下依然达到了最高的平均识别率,69.77%。对应 OVR 分类方式下径向基函数 SVM 的参数为 $c = 7.5324$ ， $\sigma = 4.2892$ 。

表 4-4 OVR 方式下 9 名被试 4 类运动想象任务 10 折交叉平均识别率 (%)

核函数	S1	S2	S3	S4	S5	S6	S7	S8	S9	均值
Poly	84.53	45.62	77.64	55.68	46.73	46.52	80.34	83.24	79.61	66.66
Rbf	80.32	52.34	83.24	57.63	47.52	55.34	82.64	84.63	84.31	69.77
Sigmoid	75.62	46.37	80.38	54.32	44.67	53.24	81.63	81.34	82.46	66.67
Linear	77.84	43.85	79.62	50.62	43.25	51.34	76.45	74.3	76.32	63.73

因此，依据决策树分类框架，本文构建的 DT-SVM 如图 4.5 所示，有关于 DT-SVM 的分类效果将在 4.5 节进行讨论。




图 4.5 DT-SVM 分类框架

4.3 决策树框架-费舍尔线性分类器

线性判别分析是一种对高维向量进行投影的分类方法，因而也适用于脑电信号分类中高维特征向量的降维及分类过程。但是简单的基于投影规则的线性判别分析会在低维空间中，如一维空间带来类别重合现象。而费舍尔线性判别分析

(Fisher Linear Discriminant Analysis, FLDA) 基于 Fisher 判别准则最大化类间间距, 最小化类内间距, 从而使类别重合现象得到缓解。

FLDA 在两类样本空间 x_1, x_2 中寻求一个最优权向量 w 使得投影后的值 $y_1 = w^T x_1$ 和 $y_2 = w^T x_2$ 之间的类别间距最大化, 从而达到区分两类信号的目的。如图 4.6 展示了 FLDA 分类过程的主要思想, 图 4.6 (a) 展示了简单的线性判别分析所带来的类别重合现象, 图 4.6 (b) 展示了基于 Fisher 线性判别分析的分类投影效果图。从图中可以看出 Fisher 准则对类别切分起到了较大的提升。

FLDA 的计算过程如下:

计算样本均值向量如式 4-3:

$$m_k = \frac{1}{N_k} \sum_{i \in C_k} x_i \quad (4-3)$$

计算样本类间散度矩阵和类内散度矩阵如式 4-4:

$$S_B = (m_1 - m_2)(m_1 - m_2)^T \quad (4-4)$$

Fisher 线性判别分析如式 4-5:

$$S_W = \sum_{k=1}^2 \sum_{i \in C_k} (x_i - m_k)(x_i - m_k)^T \quad (4-5)$$

投影向量最优解如式 4-6:

$$\max J(w) = \frac{w^T S_B w}{w^T S_W w} = \frac{(\mu_1 - \mu_2)^2}{\sigma_1^2 + \sigma_2^2} \quad (4-6)$$

分类器响应如式 4-7:

$$w \in S_W^{-1}(m_1 - m_2) \quad (4-7)$$

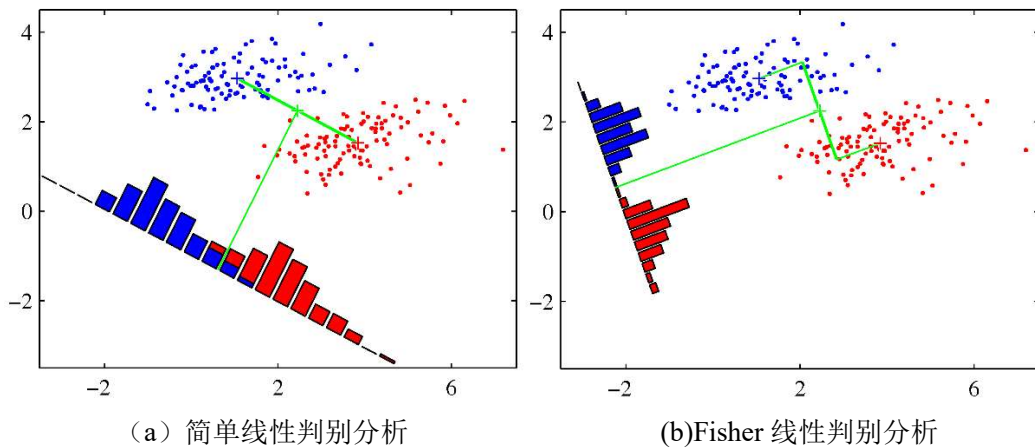


图 4.6 费舍尔线性判别分析示意图

结合决策树分类框架, 形成了 DT-FLDA。在 DT-FLDA 的构建过程中, 前两层节点依然按照 OVR 的方式进行分类, 因此, 前两层节点需要明确最佳可分离

类别。基于此,表 4-8 展示了在 OVR 方式下使用 IMFA-R 和 FLDA 十折交叉验证得到的分类结果。从表 4-5 中可以看出,在四类运动想象任务中,口运动想象组别较其他组别具有更高的可区分度,右手运动想象组别次之。

表 4-5 在 OVR 方式下使用 IMFA-R 和 FLDA 分类器 10 折交叉验证结果 (%)

被试者	左/其余	右/其余	脚/其余	口/其余
A01	91.45	91.75	84.56	88.90
A02	75.32	76.52	84.56	77.80
A03	82.35	93.46	85.43	89.50
A04	76.01	78.46	77.89	84.92
A05	75.31	74.86	76.95	76.52
A06	77.14	77.32	77.51	77.04
A07	86.54	81.89	89.16	90.27
A08	92.45	94.53	83.43	92.08
A09	95.42	88.53	84.37	92.48
均值	83.55	84.15	82.65	85.5
标准差	7.65	7.45	3.98	6.27

表 4-6 展示了在 OVO 方式下使用本文所提出的特征提取方法十折交叉验证获得的识别结果。该表展示了 4 类动作共 6 组运动想象任务识别率。从平均识别率上可知,左/脚和右/口组别是识别率最高的组别,左/右则为平均识别率最低的组别,说明不同肢体动作具有较高的可区分性。

表 4-6 在 OVO 方式下使用 IMFA-R 和 FLDA 分类器 10 折交叉验证结果 (%)

被试者	左/右	左/脚	左/脚	右/脚	右/口	脚/口
A01	90.62	95.43	97.53	96.82	100.00	84.96
A02	68.35	88.95	65.26	86.43	80.95	85.27
A03	93.78	94.13	96.73	95.65	97.50	83.32
A04	64.58	82.15	84.14	85.90	80.12	76.63
A05	65.44	69.43	75.62	67.80	72.36	63.72

续表 (4-6)

被试者	左/右	左/脚	左/脚	右/脚	右/口	脚/口
A06	71.25	78.24	68.34	73.81	72.46	75.31
A07	74.29	97.64	97.95	98.56	96.98	89.42
A08	95.85	89.30	98.63	91.99	94.95	94.35
A09	95.43	94.45	100.00	89.64	93.82	92.82
均值	79.95	87.75	87.13	87.40	87.68	82.87
标准差	12.85	8.84	13.28	9.89	10.51	9.11

因此, 依据决策树分类框架, 本文构建的 DT-FLDA 如图 4.7 所示, 有关于 DT-FLDA 的分类效果将在 4.5 节进行讨论。




图 4.7 DT-FLDA 分类框架

4.4 浅层卷积神经网络

在前面的内容分析中可以得知, 线性分析方法和其他常用的非线性分析方法通常需要特征提取和分类两个过程, 并且并不能为四类运动想象提供精度足够高的识别率。因此, 迫切需要能够减少特征工程的工作量并在一定程度上提高识别率的方法。

深度学习受到了前所未有的关注, 且在各行各业产生了巨大的效益。而深度学习本身也在不断进化以完善自身理论, 各个国家的科研人员被此吸引, 并且都进行了大量的研究。深度学习在很大程度上缓解了手工特征提取的工作量, 在计算机视觉和语音识别等方面取得了较高的识别率。深度学习之所以能够取得成功, 是因为其超越手工特征提取的方法解决了很多具有挑战性的图像识别问题。虽然大多数的 BCI 系统仍然依赖于手工特征工程, 但是近期已有很多关于深度学习方法在 EEG 中的应用研究。例如说, 采用卷积神经网络 (Convolutional Neural

Networks, CNN) 进行癫痫疾病诊断和监测、听觉音乐检索、视觉诱发监测和运动想象分类。作为机器学习的一个分支, CNN 是一种识别率较高的 EEG 信号识别方法。CNN 具有强大的非线性特性以及特征自学习能力, 因此为 EEG 信号解码提供了一种新思路。

目前, 深度学习算法已经扩充发展了很多不同类型的神经网络, 如卷积神经网络、深度玻尔兹曼机、长短期记忆网络等。

神经网络的每一层都有自己的作用, 卷积层由线性滤波器和非线性激活函数组成, 主要用于特征提取。对于大于 1 个的输入数据, 则应用多个滤波器, 并采用输入参数的方式进行多个类型的特征提取。在上一层输入的基础上, 可得到下一层的输入特征, 如式 4-8:

$$x_j^l = f \left(\sum_{i \in M_j} x_i^{l-1} \times k_{ij}^l + b_j^l \right) \quad (4-8)$$

其中, x_j^l 为卷积层 l 层第 j 个通道的输出; M_j 为输入的数据, x_i^{l-1} 为卷积层 $l-1$ 层第 i 个通道的输出。

本课题根据脑电信号的特点选择了 CNN 进行 EEG 信号的分类模型构建, 共构建了 4 种不同类型的 CNN 网络, 前三种 CNN 的网络模型参数如表 4-7 所示, 表格还展示了 9 名被试者的 4 类运动想象任务的最高识别率。从表格中可以看出, 简单的卷积神经网络模型即可达到较高的识别率, 反映了深度学习模型的传统机器学习相比的优越性。

表 4-7 三个 CNN 模型参数表以及对应的最高识别率

CNN	卷积层数	卷积核	全连接层数	全连接大小	识别率(%)
CNN-1	2	(64,64)	3	(1024,512,128)	58.00
CNN-2	3	(32,32,32)	2	(512,256)	70.00
CNN-3	2	(64,64)	3	(1024,512,256)	60.00

图 4.7 展示了本文建立的第一个卷积神经网络模型 CNN-1 的模型训练和测试识别率以及对应的损失函数变化情况, 模型最高识别率为 58.00%。

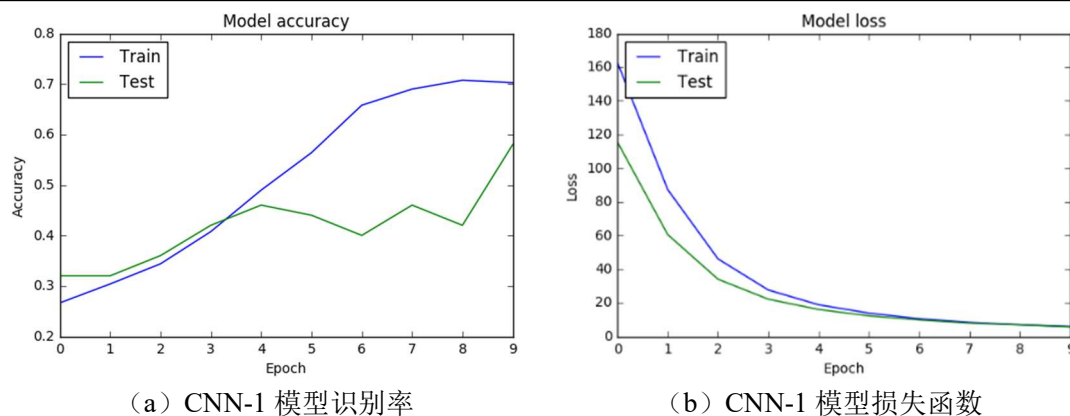


图 4.8 conv_layers=2,conv_sizes=(64,64),fc_layers=3,fc_sizes=(1024,512,256)

图 4.9 展示了本文建立的第二个卷积神经网络模型 CNN-2 的模型训练和测试识别率以及对应的损失函数，模型最高识别率为 72%。

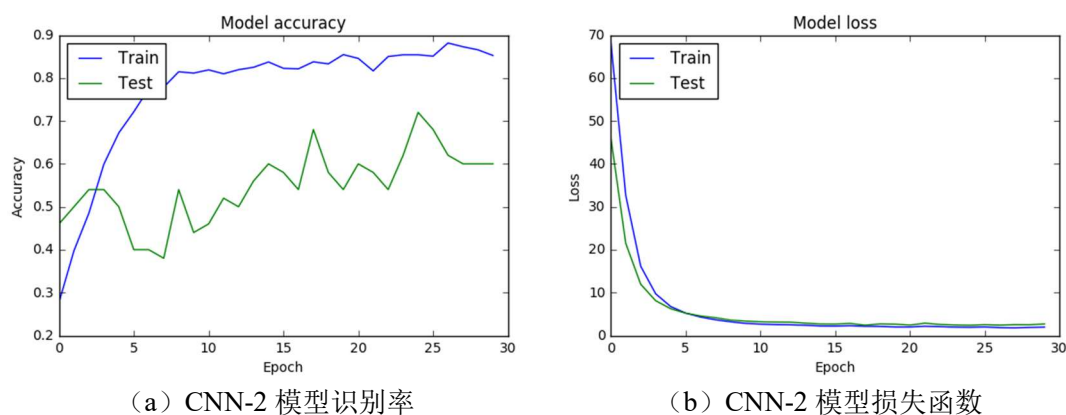


图 4.9 conv_layers=3,conv_sizes=(32,32,32),fc_layers=2,fc_sizes=(512,256)

图 4.10 展示了本文建立的第三个卷积神经网络模型 CNN-3 的模型训练和测试识别率以及对应的损失函数，模型最高识别率为 60.00%。

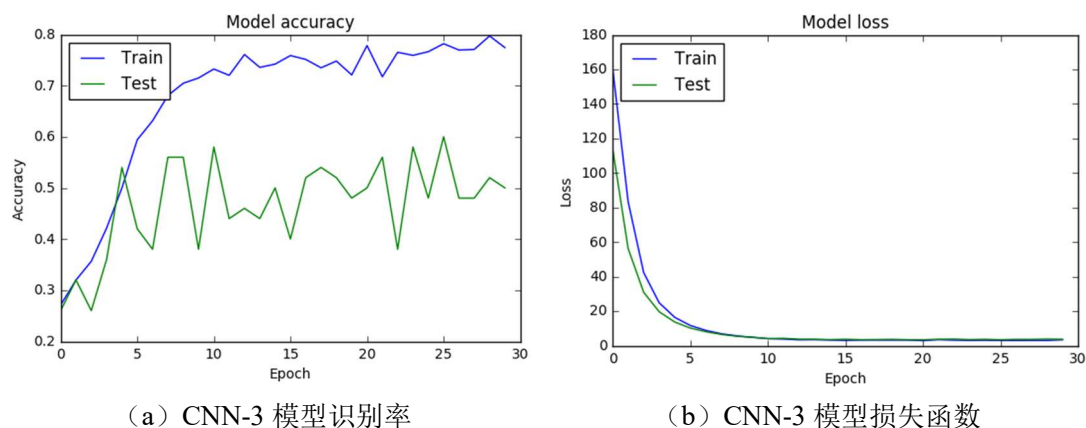


图 4.10 conv_layers=2,conv_sizes=(64,64),fc_layers=3,fc_sizes=(1024,512,256)

从以上分类结果中可以看出，简单的浅层卷积神经网络亦能满足 BCI 系统的实际应用需求，展示了卷积神经网络在 EEG 信号分类中的强大能力。本文还

构建了 CNN-4，将网络结构进一步压缩，CNN-4 网络结构图如图 4.11 所示。

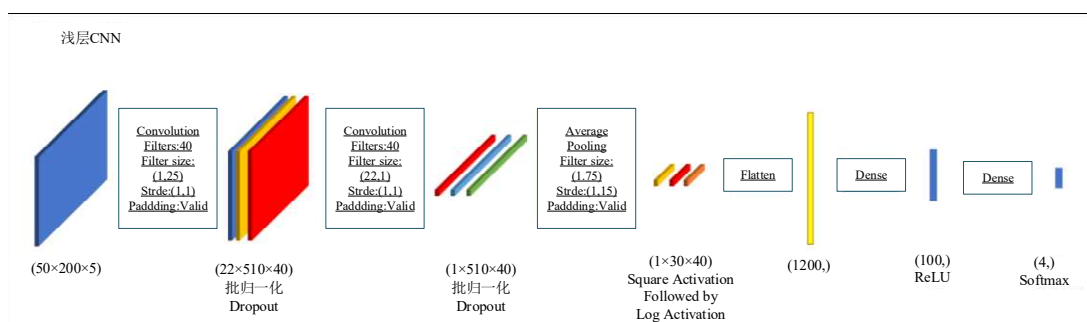


图 4.11 神经网络结构图

将 CNN-4 应用于 4 类运动想象 EEG 信号分类中，在 9 名被试者中取得了平均 70.45% 的识别正确率，如图 4.12(a) 所示。从 4.12(b) 中可以看出，左右手两类运动想象任务为最易辨识度的运动想象类型。虽然 CNN-4 的平均识别率较 CNN-2 的最高识别率低 1.55%，但是 CNN-4 的网络结构更为精简，更进一步展示了深度学习相比于机器学习无需特征构建即可达到较高识别率的优势。在不同的任务情境下，我们可根据实际的计算需求灵活选用 CNN-2 或 CNN-4 模型。




图 4.12 CNN-4 识别准确率及混淆矩阵图

4.5 不同分类方法的结果对比

将 DT-SVM 和 DT-FLDA 分别应用于 4 类运动想象脑电信号分类中，两种分类方法分类结果如表 4-8 所示。从表中可以看出，DT-SVM 识别准确率大幅领先 DT-FLDA，显示了 SVM 在小样本数据中的分类优势。

表 4-8DT-FLDA 和 DT-SVM 的分类准确率比较(%)

分类方法	S1	S2	S3	S4	S5	S6	S7	S8	S9	均值
DT-FLDA	84.4	42.3	82.4	55.6	40.3	39.9	81.3	69.5	80.3	64.03
DT-SVM	85.7	60.6	87.8	58.6	47.5	55.2	85.9	84.5	87.6	72.61

为验证本文分类方法的有效性, 本文还采用了 FLDA、SVM、DT 三种方法对多类运动想象任务进行识别, 识别结果同 DT-SVM、DT-FLDA、CNN-2 和 CNN-4 四种分类方法进行了对比, 结果如图 4.13 所示。




图 4.13 七种分类方法的识别结果比较

从图 4.13 中可以看出, IMFA-R 结合 DT-SVM 的 EEG 信号识别方法以微弱的优势胜于 CNN-2, DT-SVM 的分类识别率为 72.61%, 而 CNN-2 的分类识别率为 71.99%。但是通过对比 DT-SVM、DT-FLDA 和 SVM、FLDA 的结果可以发现, 本文提出的决策树分类框架对单分类器的分类结果具有较为显著的提升作用, 分别平均提升了 3.42% 和 0.28%。值得指出的是, 本文设计的 CNN-2 (71.99%) 和 CNN-4 (70.45%) 两种浅层网络模型都取得了较高的识别结果。由此可知, 深度学习在 EEG 信号处理中仍然具有较大的进步空间, 经过合理设计的卷积神经网络不需手动进行特征提取, 进而避免了信息损失, 因可取得更高的识别结果。

表 4-9 使用 kappa 系数展示本文方法的最终识别精度。由结果可得, 运用本文算法数据集的平均 kappa 系数提高到了 0.60。对比近期的文献, 本文得到的结果也是最高的, 证明本文所提出方法的有效性。文献[56] 和文献[57] 提出的两种方法也得到了最高 kappa 系数 0.60, 分别是 SS-MEMDBF 方法和一种将高维 SPD 矩阵降维至低维空间并保持矩阵之间差异性的方法。文献[47]提出 TSLDA

方法以及文献[58]提出 FBCSP 和 OVR 分类器用于四类运动想象任务识别, 平均 kappa 系数达到了 0.57。文献[59]提出一种新的非线性降维技术, 最终 kappa 系数达到了 0.571。

表 4-9 不同文献同一数据集的 kappa 系数

被试者	本文方法	文献[56]	文献[47]	文献[58]	文献[59]	文献[57]
A01	90.62	95.43	97.53	96.82	100.00	84.96
A02	68.35	88.95	65.26	86.43	80.95	85.27
A03	93.78	94.13	96.73	95.65	97.50	83.32
A04	64.58	82.15	84.14	85.90	80.12	76.63
A05	65.44	69.43	75.62	67.80	72.36	63.72
A06	0.39	0.34	0.34	0.27	0.3679	0.36
A07	0.69	0.66	0.69	0.77	0.7887	0.68
A08	0.83	0.75	0.71	0.75	0.7479	0.76
A09	0.76	0.82	0.76	0.61	0.6127	0.76
平均值	0.60	0.60	0.567	0.57	0.5716	0.60

4.6 本章小结

本章节对脑电信号进行分类, 提出了一种决策树分类框架, 通过结合 SVM 和 FLDA 证明了该分类框架对于分类器的提升作用。进一步的, 本章还通过 DT-SVM、DT-FLDA 与其它分类方法的比较证明了 DT-SVM 的分类性能。在人工智能的时代, 不能忽视深度学习的巨大潜力。因此, 本章还设计了四种浅层神经网络对 EEG 信号进行分类识别。CNN 识别结果几乎与 DT-SVM 持平。说明在 EEG 信号分类这种小样本任务中, 传统的机器学习方法依然具有优势。

第5章 总结与展望

5.1 总结

作为新兴的交叉学科,脑机接口具有较高的科研价值和广阔的发展前景。它涉及计算机、生物医学工程、自动化等学科,加上各国政府的纷纷布局与投入,脑机接口距离现实越来越近。本文正是在这样的背景下进行选题并对脑机接口中的核心问题-脑电信号解码进行了研究。本文所做的主要工作如下:

首先,本文展望了脑机接口信号解码发展概况以及现实中的工程应用,介绍了常用的脑电信号分析方法以及一些研究机构所进行的实物效果展示,对脑电信号中的常见伪迹进行了介绍,并采用图像展现了伪迹对于 EEG 信号的巨大影响、采用独立成分分析进行不同脑电源成分的筛选与剔除,获取了信噪比较高的脑电信号。

其次,提出了一种黎曼空间本征模态函数平均法,通过对脑电信号进行经验模态分解获取其本征模态函数,进而选取本征模态函数在黎曼空间中进行本征模态函数平均。本文将该方法称之为 IMFA-R 方法。经 IMFA-R 方法获得的脑电信号高维向量通过单因素方差校验和加权 FDR 方法进行特征选择,通过与经典 CSP 方法的对比证明了该方法的有效性。

最后,本文采用 DT-FLDA、DT-SVM、FLDA、SVM、DT 和 CNN 对多类运动想象脑电信号进行识别。比对分析结果可得,DT-SVM 方法在四类运动想象 EEG 信号识别中表现出色。浅层 CNN 取得了接近 DT-SVM 的识别效果,考虑到未来更大数据量的脑电数据即将出现,因而,基于深度学习的脑电信号识别方法具有较大的发展潜力,但在现阶段,传统机器学习在小样本数据中依然具有优势。

5.2 展望

本文所做的研究工作仍有很多不足的地方。相比于各种同行论文中的识别结

果仍有较大不足。作为一名在职人员，我仍将在工作中继续探索脑机接口这个课题并希望取得更大的成果。未来的工作主要围绕以下两方面展开：

首先，深度学习方法已展现出较大的优势，后续将聚焦深度学习方法在脑机接口中的应用研究，希望借由脑科学研究启发类脑神经网络，或全新设计神经网络，借此一窥脑科学的神经机制，做到相互启发、相互借鉴，努力做到更高的信号解码精度。

其次是本文的工作都是理论与建模计算工作，今后将更加注重工程实践，早日将脑机接口走入大众的视线中。

参考文献

- [1] 姜丽. 东北农村残疾人社会保障供需矛盾研究[D]. 吉林大学, 2013.
- [2] Wolpaw J R, Birbaumer N, McFarland D J, et al. Brain-computer interfaces for communication and control[J]. Clinical neurophysiology, 2002, 113(6): 767-791.
- [3] Birbaumer N. Breaking the silence: brain-computer interfaces (BCI) for communication and motor control.[J]. Psychophysiology, 2010, 43(6):517-532.
- [4] 赵婧. 电动轮椅操纵杆设计[D]. 哈尔滨工业大学, 2009.
- [5] 周春雨, 张毅. 脑机接口在机器人控制中的研究现状[J]. 数字通信, 2013, 40(4): 1-4.
- [6] Song W, Wang X, Zheng S, et al. Mobile robot control by BCI based on motor imagery[C]//2014 Sixth International Conference on Intelligent Human-Machine Systems and Cybernetics. IEEE, 2014, 2: 383-387.
- [7] Royer A S, Doud A J, Rose M L, et al. EEG control of a virtual helicopter in 3-dimensional space using intelligent control strategies[J]. IEEE Transactions on neural systems and rehabilitation engineering, 2010, 18(6): 581-589.
- [8] van de Laar B, Gürkök H, Bos D P O, et al. Experiencing BCI control in a popular computer game[J]. IEEE Transactions on Computational Intelligence and AI in Games, 2013, 5(2): 176-184.
- [9] Wolpaw J R. Brain-computer interfaces as new brain output pathways[J]. The Journal of physiology, 2007, 579(3): 613-619.
- [10] Konrad P, Shanks T. Implantable brain computer interface: Challenges to neurotechnology translation[J]. Neurobiology of disease, 2010, 38(3): 369-375.
- [11] 崔燕. 基于运动想象脑电的手臂运动功能康复研究[D]. 北京工业大学, 2013.
- [12] 袁盛. 基于运动想象的人脑意念操控大鼠研究[D]. 浙江大学, 2018.
- [13] Arfaras G, Athanasiou A, Pandria N, et al. Visual Versus Kinesthetic Motor

- Imagery for BCI Control of Robotic Arms[A]. In : 2017 IEEE 30th International Symposium on Computer-Based Medical Systems[C]. Washington : Institute of Electrical and Electronics Engineers Inc, 2017: 440~445.
- [14]Donati A R C, Shokur S, Morya E, et al. Long-term training with a brain-machine interface-based gait protocol induces partial neurological recovery in paraplegic patients[J]. Scientific reports, 2016, 6: 30383.
- [15]赵凯. 多类运动想象脑电信号识别及其在 BCI 中的应用研究[D]. 吉林, 东北电力大学, 2019: 20-25.
- [16]罗志增, 曹铭. 基于最大信噪比盲源分离的脑电信号伪迹滤波算法[J]. 电子学报, 2011, 039(012):2926-2931.
- [17]Hsu W Y. EEG-based motor imagery classification using neuro-fuzzy prediction and wavelet fractal features[J]. Journal of Neuroscience Methods, 2010, 189(2): 295-302.
- [18]李松, 伏云发, 陈健, 等. 五种 SVM 参数寻优识别运动想象脑电比较研究[J]. 传感器与微系统, 2017, 36(4): 42-45.
- [19]李洁, 张丽清. 多模态脑电信号分析及脑机接口应用[D]. 上海: 上海交通大学, 2009: 19-26.
- [20]Rodríguez-Bermúdez G, García-Laencina P J, Roca-González J, et al. Efficient feature selection and linear discrimination of EEG signals[J]. Neurocomputing, 2013, 115: 161-165.
- [21]Hsu W Y. Assembling a multi-feature EEG classifier for left-right motor imagery data using wavelet-based fuzzy approximate entropy for improved accuracy[J]. International journal of neural systems, 2015, 25(08): 1550037.
- [22]张毅, 杨柳, 李敏, 等. 基于 AR 和 SVM 的运动想象脑电信号识别[J]. 华中科技大学学报: 自然科学版, 2011 (S2): 103-106.
- [23]Hsu W Y, Sun Y N. EEG-based motor imagery analysis using weighted wavelet transform features[J]. Journal of neuroscience methods, 2009, 176(2): 310-318.

- [24]余青山, 陈希豪, 席旭刚, 等. 基于 DTCWT 和 CSP 的脑电信号特征提取[J]. 大连理工大学学报, 2016 (2016 年 01): 70-76.
- [25]孙会文, 伏云发, 熊馨,等. 基于 HHT 运动想象脑电模式识别研究[J]. 自动化学报, 2015, 41(9): 1686-1692.
- [26]Blankertz B, Kawanabe M, Tomioka R, et al. Invariant common spatial patterns: Alleviating nonstationarities in brain-computer interfacing[C]//Advances in neural information processing systems. 2008: 113-120.
- [27]Kumar S, Mamun K, Sharma A. CSP-TSM: optimizing the performance of Riemannian tangent space mapping using common spatial pattern for MI-BCI[J]. Computers in biology and medicine, 2017, 91: 231-242.
- [28]Roweis S T, Saul L K. Nonlinear dimensionality reduction by locally linear embedding[J]. science, 2000, 290(5500): 2323-2326.
- [29]Kramer O, Lücke D. Visualization of evolutionary runs with isometric mapping[C]//Evolutionary Computation (CEC), 2015 IEEE Congress on. IEEE, 2015: 1359-1363.
- [30]Weinberger K Q, Sha F, Saul L K. Learning a kernel matrix for nonlinear dimensionality reduction[C]//Proceedings of the twenty-first international conference on Machine learning. ACM, 2004: 106.
- [31]Maaten L. Learning a parametric embedding by preserving local structure[C]//Artificial Intelligence and Statistics. 2009: 384-391.
- [32]Van Der Maaten L. Accelerating t-SNE using tree-based algorithms[J]. The Journal of Machine Learning Research, 2014, 15(1): 3221-3245.
- [33]Yamawaki N, Wilke C, Liu Z, et al. An enhanced time-frequency-spatial approach for motor imagery classification[J]. IEEE transactions on neural systems and rehabilitation engineering, 2006, 14(2): 250-254.
- [34]李红利, 王江, 邓斌, 等. 基于 AAR 模型和累积频带能量的特征提取方法[J]. 天津大学学报: 自然科学与工程技术版, 2013, 46(9): 784-790.

- [35]姚志彬. 临床神经解剖学[M]. 世界图书出版公司, 2001.1~330.
- [36]闫铮. 基于脑电节律的脑网络研究及应用[D]. 清华大学, 2012.
- [37]Li Y ., Guan C ., Qin J .,Cichocki A., Enhancing Feature Extraction with Sparse Component Aanalysis for Brain-Computer Interface[A].Proceeding of the 2005 IEEE Engineering in Medicine and Biology 27th Annual Conference.Shanghai,Chian:IEEE,2005:5335-5338.
- [38]Müller K R, Anderson C W,Birch G E. Linear and nonlinear methods for brain-computer interfaces[J].IEEE Transactions on Rehabilitation Engineering,2003,11(2):165-169.
- [39]Brunner C, Leeb R, Müller-Putz G, et al. BCI Competition 2008–Graz data set A[J]. Institute for Knowledge Discovery (Laboratory of Brain-Computer Interfaces), Graz University of Technology, 2008, 16.
- [40]Lotte F , Congedo M , Lecuyer A , et al. A review of classification algorithms for EEG-based brain-computer interfaces[J]. Journal of neural engineering, 2007, 4(2):p.R1-R13.
- [41]Barachant A , Bonnet S , Congedo M , et al. Multiclass Brain–Computer Interface Classification by Riemannian Geometry[J]. Biomedical Engineering, IEEE Transactions on, 2012, 59(4):p.920-928.
- [42]Tuzel O, Porikli F, Meer P. Pedestrian detection via classification on riemannian manifolds[J]. IEEE transactions on pattern analysis and machine intelligence, 2008, 30(10): 1713-1727.
- [43]Barbaresco F. Innovative tools for radar signal processing based on Cartan’s geometry of SPD matrices & information geometry[C]//2008 IEEE Radar Conference. IEEE, 2008: 1-6.
- [44]Li Y, Wong K M, deBruin H. EEG signal classification based on a Riemannian distance measure[C]//2009 IEEE Toronto International Conference Science and Technology for Humanity (TIC-STH). IEEE, 2009: 268-273.

- [45] Congedo M, Barachant A, Andreev A. A new generation of brain-computer interface based on riemannian geometry[J]. arXiv preprint arXiv:1310.8115, 2013.
- [46] Korczowski L, Congedo M, Jutten C. Single-trial classification of multi-user P300-based Brain-Computer Interface using riemannian geometry[C]//2015 37th annual international conference of the IEEE engineering in medicine and biology society (EMBC). IEEE, 2015: 1769-1772.
- [47] Barachant A, Bonnet S, Congedo M, et al. Classification of covariance matrices using a Riemannian-based kernel for BCI applications[J]. Neurocomputing, 2013, 112: 172-178.
- [48] Barachant A, Bonnet S, Congedo M, et al. Multiclass Brain-Computer Interface Classification by Riemannian Geometry[J]. Biomedical Engineering, IEEE Transactions on, 2012, 59(4):p.920-928.
- [49] Congedo M, Barachant A, Bhatia R. Riemannian geometry for EEG-based brain-computer interfaces; a primer and a review[J]. Brain-Computer Interfaces, 2017, 4(3): 155-174.
- [50] Huang N E, Shen Z, Long S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings A, 1998, 454(1971):903-995.
- [51] Huang N E, Shen Z, Long S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings Mathematical Physical & Engineering Sciences, 1998, 454(1971):903-995.
- [52] 陆盛林. 基于脑机接口的虚拟现实三维目标的控制研究及应用[D].华南理工大学,2016.
- [53] Guo H, Gelfand S B. Classification trees with neural network feature extraction[J]. IEEE Transactions on Neural Networks, 1992, 3(6): 923-933.
- [54] Safavian S R, Landgrebe D. A survey of decision tree classifier methodology [J].

- IEEE transactions on systems, man, and cybernetics, 1991, 21(3): 660-674.
- [55]Safavian S R, Landgrebe D. A survey of decision tree classifier methodology [J].
IEEE transactions on systems, man, and cybernetics, 1991, 21(3): 660-674.
- [56]Gaur P, Pachori R B, Wang H, et al. A multi-class EEG-based BCI classification
using multivariate empirical mode decomposition based filtering and Riemannian
geometry[J]. Expert Systems with Applications, 2018, 95: 201-211.
- [57]Davoudi A, Ghidary S S, Sadatnejad K. Dimensionality reduction based on
distance preservation to local mean for symmetric positive definite matrices and its
application in brain-computer interfaces[J]. Journal of neural engineering, 2017,
14(3): 1-13.
- [58]Ang K K, Chin Z Y, Wang C, et al. Filter bank common spatial pattern algorithm
on BCI competition IV datasets 2a and 2b[J]. Frontiers in neuroscience, 2012, 6:
1-9.
- [59]Sadatnejad K, Ghidary S S. Kernel learning over the manifold of symmetric
positive definite matrices for dimensionality reduction in a BCI application[J].
Neurocomputing, 2016, 179: 152-160.

致 谢

时光荏苒，又是一年毕业季，与往年不同的是，这个毕业季亦是我研究生生涯的结束。三年的点点滴滴仿佛如昨日般出现在眼前，想起和同学们一起上课、一起做实验以及老师们敦敦教导的场景，心中的不舍与留恋转化为了感激与喜悦。三年来，我不仅收获了专业知识和技能，还得到很多良师益友。在此，我想对指导、支持和鼓励过我的老师和朋友们表示诚挚的谢意！

首先，我要感谢我的导师杜育根教授，杜教授勤于工作与科研，严谨、高效的求学态度令人佩服。感谢杜教授对我课题的指点与帮助，他每次对我耐心的指导以及极强的责任心让我深深感动。杜教授一直鼓励我要勇于创新，善于发现问题以及开拓思维，并且培养我独立思考和解决问题的能力。杜教授是我科研道路上的指引者，再次向杜教授表达我最真挚的谢意！同时祝愿杜教授身体健康，万事如意，科研事业更进一步！

其次，感谢课题组各位老师对我耐心的指点与教导。还要感谢课题组小伙伴的建议与帮助，感谢朋友陈香宇在课题入门阶段的指点，感谢同窗刘倩在读研期间来对我的关心与鼓励。当然，在此也非常感谢我的家人这么多年来对我的无私奉献与支持，没有你们就没有今天的我。不管我成功还是失败，感谢你们陪伴在我身边，鼓励我信任我。我会加倍努力，成为你们的骄傲！

最后，向本文的评审专家以及答辩组专家表示深深的感谢！感谢你们抽出宝贵的时间审阅本文。